

大型语言模型能否从相关性推断因果关系？

志京金^{1,2}, ‡刘嘉瑞³, 吕志恒⁴ Spencer Poff⁵ Mrinmaya Sachan² Rada Mihalcea⁶ Mona Diab³, †, ‡ Bernhard Schölkopf¹, † ¹德国图宾根根马克斯·普朗克智能系统研究所²苏黎世联邦理工学院³卡内基梅隆大学⁴香港大学⁵Meta AI ⁶密歇根大学 jinzhi@ethz.ch jiarui@cmu.edu zhihengyu.cs@gmail.com

抽象的

因果推理是人类智能的标志性特征之一。近年来,因果自然语言处理 (NLP)领域备受关注,但现有的NLP因果推理数据集主要依赖于从经验知识 (例如常识)中发现因果关系。本文提出了首个基准数据集,用于测试大型语言模型 (LLM) 的纯因果推理能力。具体而言,我们设计了一个新的任务CORR2CAUSE,该任务接收一组相关性语句,并确定变量之间的因果关系。我们构建了一个包含超过20万个样本的大规模数据集,并在此基础上评估了17个现有的LLM。实验结果表明, LLM在因果推理能力方面存在一个关键缺陷,并且这些模型在该任务上的表现几乎与随机水平相当。当我们尝试通过微调LLM重新用于这项技能时,这种缺陷有所缓解,但我们发现这些模型仍然无法泛化 它们只能在分布内设置下进行因果推理,即查询中使用的变量名和文本表达式与训练集中的变量名和文本表达式相似,但在通过扰动这些查询生成的分布外设置下则失败。CORR2CAUSE对LLM来说是一项具有挑战性的任务,并且有助于指导未来关于提高LLM纯推理能力和泛化能力的研究。¹

1引言

因果推理,即建立变量或事件之间正确因果关系的能力,是人类智能的基础。这种因果推理能力可以通过两种截然不同的方式获得:一种是通过经验知识,例如,我们凭常识就知道触摸滚烫的炉子会被烫伤;另一种是通过纯粹的因果推理,因为因果关系可以通过因果推理中已知的程序和规则进行正式的论证和推理 (Spirtes et al., 2000; Pearl, 2009; Peters et al., 2017)。例如,我们先验地知道A和B之间的相关性并不一定意味着因果关系。这是一条形式规则,无论变量A和B的具体取值如何,这条规则都成立。

随着大型语言模型 (LLM)的兴起 (Radford et al., 2019; Devlin et al., 2019; Ouyang et al., 2022; Zhang et al., 2022; OpenAI, 2023 等),一个关键的研究问题是它们能否有效地进行因果推理。最近的研究指出,LLM 就像“因果鹦鹉”,只会复述训练数据中的因果知识 (Zecevic et al., 2023)。此外,绝大多数研究将因果推理视为一种驾驭经验知识的技能 (Gordon et al., 2012; Sap et al., 2019a;b; Qin et al., 2019; Bhagavatula et al., 2020),并且在评估逻辑学习模型 (LLM)的因果推理能力时,也将LLM视为知识库 (K c man et al., 2023; Tu et al., 2023; Xie et al., 2023)。然而,上述所有研究都将因果关系视为经验知识,因此严重依赖训练数据的质量和覆盖范围,忽略了形式化因果推理技能在处理相关信息并得出因果结论方面的巨大潜力。

*贡献相同。 †指导相同。 ‡这项工作最初是Zhijing、Mona和Spencer参与的Meta AI实习项目。

1我们的数据位于<https://huggingface.co/datasets/causalNlp/corr2cause>。
我们的代码位于<https://github.com/causalNLP/corr2cause>。

306.05836v3




图 1:我们任务和数据集背后的动机示意图。

借鉴因果发现方面的技术研究 (Spirtes et al., 2000; Spirtes & Zhang, 2016; Glymour et al., 2019), 我们提出了一种新的自然语言处理任务 相关性到因果关系推断 (CORR2CAUSE), 这对于语言学习模型 (LLM) 而言是一项重要的技能。如图1所示, 训练语料库并非详尽地涵盖所有因果关系, 而是更广泛地探讨相关性, 例如哪些事件倾向于同时发生。学习良好的CORR2CAUSE技能能够使语言学习模型从表面的相关性信息中挖掘出更深层次的因果关系。例如, 几十年前, 人们可能观察到女大学生往往表现更佳, 但在相关性统计背后, 隐藏着一个因果图: 女大学生必须取得格外优异的成绩才能名列大学录取名单。

为此, 我们收集了CORR2CAUSE数据集, 这是首个用于测试逻辑学习模型 (LLM) 纯因果推理能力的数据集。该数据集集中的所有问题都围绕着测试何时能够从相关性推断出因果关系。为了系统地构建该数据集, 我们将泛化过程建立在因果发现的形式化框架之上 (Spirtes 等人, 1993; 2000; Glymour 等人, 2016; Spirtes 和 Zhang, 2016), 该框架提供了关于如何根据观测数据中变量的统计相关性推断其因果关系的规则。我们生成了超过 20 万个数据点, 并将相关性-因果关系陈述对标记为有效, 当且仅当统计相关性与其潜在因果关系之间存在双射关系。

基于我们包含 20 万个样本的CORR2CAUSE数据集, 我们研究了两个主要问题: (1) 现有逻辑线性模型 (LLM) 在此任务上的表现如何? (2) 现有 LLM 能否通过重新训练或重新利用来应用于此任务, 并获得稳健的因果推理能力? 通过大量的实验, 我们实证表明, 在我们研究的 17 个现有 LLM 中, 没有一个能在此纯因果推理任务上表现良好。我们还发现, 尽管 LLM 在经过微调后可以展现出更好的性能, 但它们所获得的因果推理能力并不稳健。总而言之, 我们的贡献如下:

- 1. 我们提出了 CORR2CAUSE 这一新颖的任务, 以探究 LLM 推理能力的一个方面, 即纯粹的因果推理;
- 2. 我们利用因果发现的洞见, 构建了一个包含超过 20 万个样本的数据集;
- 3. 我们评估了 17 种 LLM 模型在该数据集上的性能, 发现它们都表现良好。较差, 接近随机基线;
- 4. 我们进一步探讨了 LLM 是否可以通过微调来学习这项技能, 结果发现 LLM 在分布外场景下无法稳健地习得这项技能。最后, 我们建议未来的工作应探索更多方法来增强 LLM 的纯因果推理能力。

2预备知识:因果推断

2.1有向图因果模型 (DGCM)

有向图因果模型 (DGCM) 是一种常用的表示方法, 用于表达一组变量之间的因果关系。给定一组 N 个变量 $X = \{X_1, \dots, X_N\}$, 我们可以使用有向图 $G := (X, E)$ 来编码它们之间的因果关系, 其中 E 是有向边的集合。每条边 $e_{ij} \in E$ 表示一条因果链接 $X_i \rightarrow X_j$, 这意味着 X_i 是 X_j 的直接原因。

在本研究中, 我们采用有向无环图 (DAG) 的常见假设, 大多数因果发现方法都使用这种假设 (Glymour 等人, 2019), 因为有环图会使因果发现过程变得任意困难。

沿用图论术语,我们用祖先树的类比来表示两个变量之间的关系。例如,如果图中存在一条有向边 $X_i \rightarrow X_j$,则称 X_i 为 X_j 的父节点,因此 X_j 是 X_i 的子节点。类似地,如果存在一条从 X_i 到 X_j 的有向路径,则称 X_i 为 X_j 的祖先节点,因此 X_j 是 X_i 的后代节点。需要注意的是,父节点是祖先节点的一种特殊情况,即有向路径的长度为 1。

为方便起见,我们还引入了一些特殊三变量关系的概念。给定两个变量 X_i 和 X_j ,如果第三个变量 X_k 同时是 X_i 和 X_j 的父变量,则称 X_k 为混淆变量(即共同原因);如果 X_k 同时是 X_i 和 X_j 的子变量,则称 X_k 为碰撞变量(即共同效应);如果 X_k 既是 X_i 的子变量,又是 X_j 的父变量,则称 X_k 为中介变量。

2.2 D-分离和马尔可夫性质

D-分离 (Pearl, 1988) 是图模型中的一个基本概念,用于判断有向无环图 G 中的两个节点集 X 和 Y 在给定第三个节点集 Z 的情况下是否条件独立,其中这三个节点集互不相交。我们称 X 和 Y 被 Z d-分离,如果 X 中任意节点与 Y 中任意节点之间的所有路径都被条件集 Z 阻塞。 X 和 Y 之间的路径被 Z 阻塞,当且仅当存在节点 $A \in Z$, 满足以下条件之一: A 是路径上分支结构中的父节点(即, $\cdot \leftarrow A \rightarrow \cdot$); A 是路径上链结构中的中介节点(即, $\cdot \rightarrow A \rightarrow \cdot$); 或者在路径上的任何碰撞结构中(即, $\cdot \rightarrow A \leftarrow \cdot$), Z 不包含 A 或其后代节点。

马尔可夫性质在有向无环图 G 中,每个节点 X_i 与其非后代节点条件独立,给定其父节点,即 $X_i \perp\!\!\!\perp \text{NonDe}(X_i) \mid \text{Pa}(X_i)$, 其中 $\text{NonDe}(X_i)$ 表示 X_i 的非后代节点(不包括自身), $\text{Pa}(X_i)$ 表示 X_i 的父节点。利用马尔可夫性质,我们可以将图中所有节点的联合分布分解为 $P(X_1, \dots, X_N) = \prod_{i=1}^N P(X_i \mid \text{Pa}(X_i))$ 。为了从概率分布推断因果图,一个常见的假设是忠实性,即能够从概率分布中的独立关系推断出图中所有 d-分离集。在我们的工作中,我们也采用了这一适用于大多数实际场景的广泛假设。

图的马尔可夫等价性如果两个有向无环图 (DAG) 导出相同的联合分布 $P(X)$, 则称它们马尔可夫等价。彼此马尔可夫等价的 DAG 的集合称为马尔可夫等价类 (MEC)。同一个 MEC 中的因果图很容易识别,因为它们具有相同的骨架(即无向边)和 V 结构(即形如 $A \rightarrow B \leftarrow C$ 的结构,其中 A 和 C 不连通)。

显然,因果图与统计分布之间存在一对多的映射关系(即满射)。也就是说,每个因果图都能充分确定一个统计分布,但我们未必能从一个统计分布推导出唯一的因果图。这就是我们常说的“相关性并不一定意味着因果关系”。

2.3 因果发现

因果发现旨在通过分析观测数据的统计特性来了解因果关系 (Spirtes et al., 1993; 2000; Glymour et al., 2016; Spirtes & Zhang, 2016; Glymour et al., 2019)。它可以通过基于约束的方法 (Spirtes et al., 2000)、基于评分的方法 (Chickering, 2002) 或其他利用函数因果模型的方法 (Shimizu et al., 2006; Hoyer et al., 2008; Zhang & Hyvärinen, 2009) 来实现。

为了符合本文从相关性(用自然语言表达)推断因果关系的精神,我们基于广泛使用的 Peter-Clark (PC) 算法 (Spirtes 等人, 2000 年) 设计了我们的数据集。PC 算法基于条件独立性和因果马尔可夫假设的原理,能够高效地识别给定数据集中的变量之间的因果关系。该算法首先构建一个包含所有变量的完全连通无向图。

然后,如果两个变量之间存在无条件或条件独立关系,则移除它们之间的边。之后,当存在 V 形结构时,调整有向边的方向。最后,迭代地检查其他边的方向,直到整个因果图与所有统计相关性一致。




图 2:数据构建过程的管道。

3数据集构建

本节介绍数据集的构建过程。首先,我们阐述CORR2CAUSE 的任务定义,然后简要概述数据生成过程,并详细描述每个步骤。最后,我们给出数据集的总体统计信息。

3.1任务制定

给定一组 N 个变量 $X = \{X_1, \dots, X_N\}$, 我们有一个关于变量之间所有相关性的陈述 s , 以及一个描述变量 X 之间因果关系的假设 h 。任务是学习一个函数 $f: (s, h) \rightarrow v$, 该函数将相关性陈述 s 和 h 映射到它们的有效性 $v \in \{0, 1\}$, 如果此推断无效, 则 v 取值为 0, 如果此推断有效, 则 v 取值为 1。

3.2数据生成过程概述

我们基于因果推断的几个概念构建了我们的数据集,包括第 2 节中介绍的 DGCM、d-分离和 MEC。

如图 2 所示,我们首先选择变量数 N (步骤 1), 然后生成所有具有 N 个节点的唯一 DGCM (步骤 2), 这将在 3.3 节中详细介绍。接下来,我们从这些图中收集所有 d-分离集,以识别 MEC (步骤 3), 这将在 3.4 节中介绍。然后,在步骤 4 中,我们创建数据的形式化形式,这将在 3.5 节中介绍。对于 MEC 与因果图的每个对应关系,我们基于 MEC 中的统计关系构建相关性陈述,并假设两个变量之间存在因果关系。如果该假设是 MEC 中所有因果图的共同属性,则赋值为 $v = 1$; 如果该假设不一定对所有 MEC 图都成立,则赋值为 $v = 0$ 。最后,我们将在 3.6 节中介绍数据表述过程。

3.3构建具有同构性检查的图

数据生成的第一步是构建因果图,如图 2 的步骤 1 和 2 所示。

对于包含 N 个变量的集合 $X = \{X_1, \dots, X_N\}$, 由于每个节点可以连接到除自身以外的任何节点, 因此存在 $N(N - 1)$ 条可能的有向边。为了消除图中的环, 我们按照拓扑顺序排列节点, 这样就只允许存在 $X_i \rightarrow X_j$ 这样的边, 其中 $i < j$ 。我们通过限制图的邻接矩阵, 使其对角线以上的元素均为非零值来实现这一点, 最终得到的有向无环图 (DAG) 共有 $N(N - 1)/2$ 条可能的有向边。

乍一看, 对于 N 个节点, 应该有 $2 N(N - 1)/2$ 个可能的有向无环图 (即所有边的幂集)。然而, 这个集合中可能存在同构图。为了避免这种情况, 我们进行图分析。

# 节点 # 独特的 DAG # 边/DAG # MEC # DAG/MEC					
2	2/2	0.50	3	2	1.0
3	6/2			5	1.2
4	31/2	6			1.55
5	302 分 (满分 2 分)	10		20142	2.13
6	5,984 分 (满分 2 分)	15		2,207	2.71
全部的	6,325			2,376	2.66

表 1:我们数据集中的源因果图的统计信息。根据节点数量,我们报告……
唯一DAG的数量、每个DAG的平均边数、MEC的数量和平均值
每个 MEC 的 DAG 数量。

检查同构性 (McKay & Piperno,2014) ,并缩减集合,使之仅包含唯一的DAG。
保留了这些数据,我们在表 1 中展示了它们的统计数据。虽然我们可以处理大型图表,但我们主要
我们专注于能够产生合理规模数据集的较小图,因此我们根据经验将N 设置为6。
但未来的工作可以利用我们的开源代码扩展到更多节点。

3.4通过程序生成D分离集

基于唯一的DAG集合,我们通过编程方式生成d分离集。
如图 2 步骤 3 所示,图论条件。为了实现这一步骤,我们编写了一个高效的程序。
使用图论算法自动检查所有链状、分叉状和碰撞状结构。
确定每对节点之间d-分离的节点集合。利用d-分离集合和
在忠实性假设下,我们按如下方式构建统计相关性。对于每一对节点,它们
在给定d分离集中的变量的情况下,它们是条件独立的。如果d分离集是
如果为空,则这两个节点无条件独立。如果找不到 d-分离集,则
如果这两个节点直接相关,那么它们就是相关的。

此外,利用d-分离集,我们能够将因果图聚类为MEC。我们通过以下方式实现这一点:
追踪因果图与统计相关性集合之间的映射关系,并进行回溯
我们将具有相同 d 分离集的图归为同一 MEC 组。如表 1 所示,
每个 MEC 平均包含 2.66 个 DAG。

3.5假设的形成和标签的标注

在基于d分离集生成相关性集合之后,我们现在生成因果关系。
假设。对于因果关系r,我们重点关注两个节点之间的六种常见因果关系。
第 2.1 节引入:Is-Parent,Is-Child,Is-Ancestor (不包括父母)、Is-Descendant
(不包括儿童)存在混杂因素 (即,存在混杂因素或共同原因)
(两个节点),以及 Has-Collider (即,存在一个碰撞器,或者说两个节点的共同效应) 。在此
也就是说,假设集包含了每对变量之间所有六种有意义的因果关系。
结果,对于具有 N 个变量的图,总共有 $6 \cdot N(N - 1)/2 = 3N(N - 1)$ 个假设。

为了生成真实有效性标签,我们从步骤 3 中的相关集开始,然后查找
在同一 MEC 中,针对给定的相关性集合,绘制所有因果图,并检查
假设的因果关系的必要性。如果假设中提出的因果关系成立,则该因果关系必然成立。
如果对于 MEC 内的所有因果图都有效,则我们生成有效性v = 1;否则,我们
生成v = 0。有效样本的一个特例是,当 MEC 的大小为 1 时,存在一个
因果图与d-分离集之间存在双射映射,因此任何陈述以下情况的假设
该唯一因果图的因果属性是有效的。

3.6用语言表达

最后,如同图 2 的最后一步,我们将以上所有信息转换为文本数据,以便我们进行分析。
CORR2CAUSE任务。对于相关性陈述,我们将步骤 3 中的相关性集合用文字表达出来。
自然语言语句。当两个变量不能用 d 分隔时,即 $A \perp\!\!\!\perp B$,那么我们
将它们描述为“ A 与 B 相关”,因为它们直接相关且不可能独立存在。
在任何条件下。如果两个变量具有有效的 d-分离集C,则我们称它们为“ A ”。
在给定C 的情况下,与B无关。”在 d-分离集为空的特殊情况下,我们直接
假设“ A 与 B 无关”。此外,我们通过开始相关性分析来消除歧义。
假设有一个封闭系统,其中包含给定的变量,且没有隐藏变量:“假设
存在一个由N 个变量 $A, B, \dots$ 组成的封闭系统。这N个变量之间的所有统计关系
具体如下:”。最后,为了将假设表述出来,我们输入因果关系三元组 (X_i, r, X_j) 。

因果关系假设模板
Is-Parent {Var i} 直接导致 {Var j}。
Is-Anccestor {Var i} 导致其他事情,进而导致 {Var j}。
Is-Child {Var j} 直接导致 {Var i}。
Is-Descendant {Var j} 是 {Var i} 的原因,但不是直接原因。
Has-Collider 存在 {Var i} 和 {Var j} 的至少一个碰撞体 (即共同效应)。
Has-Confounder 存在 {Var i} 和 {Var j} 的至少一个混杂因素 (即共同原因)。

表 2:假设中每种因果关系的模板。我们使用{Var i}和{Var j}作为两个变量的占位符。

将三元组 (A, Is-Parent, B)转换为表 2 中的假设模板。例如,我们将三元组(A, Is-Parent, B) 转换为 “A 直接导致 B” ,如图 2 所示。

3.7结果数据的统计

我们在表 3 中展示了CORR2CAUSE数据集的统计信息。总体而言,我们的数据集包含 207,972 个数据点。样本中,18.57% 的样本被标记为阳性 (即有效性=1) 。平均值前提的长度为 424.11 个词元,假设的长度为 10.83 个词元。我们将数据拆分为 205,734 个部分。训练样本 1,076 个,开发样本 1,162 个,测试样本 1,162 个。由于该数据集的主要目的是……

为了对LLM的性能进行基准测试,我们优先考虑测试集和开发集,以确保它们具有良好的性能。全面覆盖所有规模的图。具体来说,我们遍历我们的子集。

对于每个N 值,如果数据量小于 1K,则将其完全拆分为测试集和开发集。

对于N = 2和3的情况正是如此。对于其他更大的子集,我们随机抽取样本,最多抽取……

我们将1000个数据或总数据的10% (以较小者为准)分配到测试集和开发集中。我们设定上限为1000个数据。

为了制定合理的计算预算,因为查询许多LLM的成本很高。

推理模式。除了测试集和验证集之外,所有剩余数据都放入训练集中。

	全面的	按节点数 N 统计				
		N=2	N=3	N=4	N=5	N=6
# 示例	207,972	12	90	720	8,520	198,630
# 测试	1,162	6	48	72	514	522
# 开发	1,076	6	42	72	482	474
# 火车	205,734	0	0	576	7,524	197,634
# 代币/前提	424.11	31.5	52.0	104.0	212.61	434.54
# 代币/假设	10.83	10.83	10.83	10.83	10.83	7.50
正面标签百分比	18.57	0.00	3.33	13.01	55	57
词汇量	65	49	53			61

表 3: CORR2CAUSE数据集及其子集的统计数据。我们报告了总数样本数 (# Samples) ;测试集 (# Test) 、开发集 (# Dev)和训练集 (# Train)的划分;每个前提的令牌数 (#令牌/前提)和假设的令牌数 (#令牌/假设) ;百分比正面标签的百分比 (% 正面标签)和词汇量 (以唯一词元数衡量)规模)。请注意,唯一图和 MEC 的数量见表 1。

4 项实验

4.1实验装置

我们为在CORR2CAUSE数据集上进行的实验设置了多种 LLM 列表。为了测试现有的 LLM,我们首先在Transformer库中引入六种常用的基于BERT的NL模型 (Wolf) 。

等人,2020) :BERT (Devlin 等人,2019) 、RoBERTa (Liu 等人,2019) 、BART (Lewis 等人,2020) 、DeBERTa (He 等人,2021 年) 、DistilBERT (Sanh 等人,2019 年)和 DistilBART (Shleifer 和 Rush,2020 年) 。

除了这些基于 BERT 的 NLI 模型之外,我们还评估了通用自回归模型。

基于 GPT 的法学硕士 (Radford 等人,2019) :GPT-3 Ada,Babbage,Curie,Davinci (Brown 等人,2020) ;其指令调整版本 (Ouyang等人,2022) ,text-davinci-001,text-davinci-002,以及 text-davinci-003;以及 GPT-3.5 (即 ChatGPT) ,并在 2023 年 4 月之前发布最新的 GPT-4 (OpenAI,2023) 。

2. 关于我们数据集 v2.0 的说明:我们注意到,由于对称关系,我们的原始数据 (v1.0) 存在重复数据。以及对假设的口头表述。例如,Is-Parent(A, B) 与 Is-Child(B, A) 因此,对于我们的数据 v2.0,我们进行了仔细的去重处理,并更新了表 3 中的数据统计信息。参见更多版本对比详情请参见附录 D。请注意,由于对称性,当前版本是随机生成的。样本大小为原版本的一半,因此实验部分的建模结果大致成立。

F1 精确率 召回率 准确率				
随机基线				
始终多数	0.0	0.0	0.0	84.77
随机 (比例)	13.5	12.53	14.62	71.46
随机 (均匀)	20.38	15.11	31.29	62.78
基于BERT的模型				
BERT MNLI	2.82	7.23	1.75	81.61
RoBERTa MNLI	22.79	34.73	16.96	82.50
DeBERTa MNLI	14.52	14.71	14.33	74.31
DistilBERT MNLI	20.70	24.12	18.13	78.85
DistilBART MNLI	26.74	15.92	83.63	30.23
BART MNLI	33.38	31.59	35.38	78.50
基于LLaMa的模型				
LLaMa-7B	26.81	15.50	99.42	17.36
Alpaca-7B基于	27.37	15.93	97.37	21.33
GPT 的型号				
GPT-3 Ada 0.00 GPT-3 Babbage 27.45 GPT-3 Curie 26.43	0.00		0.00	84.77
GPT-3 Davinci 27.82 GPT-3 Instruct (text-davinci-001)	15.96		97.95	21.15
17.99 GPT-3 Instruct (text-davinci-002) 21.87 GPT-3	15.23		100.00	15.23
Instruct (text-davinci-003) 15.72 GPT-3.5 21.69 GPT-4 29.08	16.57		86.55	31.61
	11.84		37.43	48.04
	13.46		58.19	36.69
	13.4		19.01	68.97
	17.79		27.78	69.46
	20.92		47.66	64.60

表 4:总体性能。我们报告了 F1 值（主要指标）、精确率、召回率和准确率。
主要指标,即 F1 分数,我们使用粗体字突出显示整体最佳表现,并用下划线标出。
突出展示各类模型中的最佳性能。

使用 OpenAI API (<https://openai.com/api/>)温度为0。我们还评估了最近,更高效的模型有 LLaMa (Touvron 等人,2023 年)和 Alpaca (Taori 等人,2023 年)。

在检查微调模型的行为时,我们采用了大量模型,包括基于 GPT 的模型 (GPT-3 Ada,Babbage,Curie 和 Davinci) ,并使用 OpenAI 微调 API 进行微调。

分类信息请参见<https://platform.openai.com/docs/guides/fine-tuning>开源
仅解码器模型 (GPT2,GPT2-Large,GPT2-XL,LLaMA-7B 和 LLaMA2-7B) 、基于 BERT 的模型
从零开始构建的模型 (BERT-Base,BERT-Large,RoBERTa-Base 和 RoBERTa-Large) ,以及使用 transformers 库
构建的基于 BERT 的 NLI 模型 (BERT-Base MNLI,BERT-Large MNLI,RoBERTa-Base MNLI 和 RoBERTa- Large
MNLI) (Wolf 等人,2020) 。训练详情见附录 A。

对于随机基线,我们提供 “始终多数”选项,以 100% 的时间预测多数类。
“random (uniform)”表示均匀抽取标签 (即每个标签各占50%) , “random (proportional)”表示……
从与开发集标签分布成比例的伯努利分布中抽取一个标签样本。

4.2现有LLMs中的CORR2CAUSE技能

表4展示了17个LLM的性能。我们可以看到,纯粹的因果推断是
在所有现有的LLM模型中,这都是一项极具挑战性的任务。在所有LLM模型中,最佳性能为33.38%。
F1 by BART MNLI 甚至高于最新的基于 GPT 的模型 GPT-4。值得注意的是,许多
模型甚至不如随机猜测,这意味着它们在纯粹的因果推断方面完全失败。
任务。该观察结果对于附录 G 中测试的少量思维链提示仍然成立。

4.3性能优化

接下来,我们将探讨以下问题:能否将LLM模型重新用于学习这项任务?实验结果
表 5a 中基于我们的CORR2CAUSE 模型微调的 17 个模型乍一看似乎非常强大。大多数模型
可以看到显著增长,其中经过微调的基于BERT的NLI模型表现出色
表现最佳。表现最佳的模型 RoBERTa-Large MNLI 的 F1 分数达到了 94.74%。
在该任务中,准确率、召回率和精确率都非常高。

F1 精度召回率					F1 (释义)F1 (变体参考)	
使用 OpenAI API 对基于 GPT 的模型进行微调						
GPT-3 Ada 79.85 70.47 92.11 GPT-3 Babbage 78.19 69.98 88.60 GPT-3				92.92	61.73	41.57
Curie 81.23 75.00 88.60 GPT-3 Davinci 85.52 80.26 91.52				92.48	62.34	43.28
				93.77	64.93	45.32
				95.28	65.01	46.96
经过微调的开源解码器专用模型						
GPT2 88.03 90.35 GPT2-大 92.18 95.19 GPT2-XL 91.94 96.78				96.66	56.76	31.70
LLaMA-7B 88.62 95.61 LLaMA2-7B 90.11 95.91				98.22	55.95	31.99
				94.30	60.32	43.95
				91.98	56.41	53.92
				92.92	52.24	49.47
基于 BERT 的微调模型						
BERT-Base 69.29 54.42 95.32 87.13					61.13	35.20
RoBERTa-Base 85.26 BERT-Large 87.60 77.51 94.74 95.01					63.64	38.54
89.10 RoBERTa-Large 78.47 99.12 95.73					65.58	53.12
				82.54 96.78 96.39	65.05	60.20
基于 BERT 的 NLI 模型的微调						
BERT-Base MNLI 89.88 85.49 BERT-Large MNLI 90.19				94.74 86.51	65.56	31.50
84.44 90.35 RoBERTa-Base MNLI 94.27 92.24				96.78 96.79	67.24	52.04
				98.54 98.17	57.42	62.83
RoBERTa-Large MNLI 94.74				97.37 98.35	55.45	67.87

(a)微调模型在原始测试集上的性能。

(b)微调模型的 F1 分数
在经过改述 (Paraph.)和变量处理的
扰动测试集上
重构 (Var. Ref.) 。

表 5:微调模型在原始测试集和扰动测试集上的性能。

关系类型	F1 精确率	召回率	准确率	
Is-Parent 96.18 Is-Anccestor	95.45	96.92	98.67	
93.94 Is-Child 95.73 Is-	93.94	93.94	98.93	
Descendant 96.55 Has-	94.92	96.56	98.67	
Collider 92.19 Has-Confounder	93.33	100	99.47	
98.67	87.41	97.52	94.64	
	97.37	100	99.73	

F1 精确率	召回率	准确率	
74.80	79.31	70.77	91.73
45.45	90.91	30.30	93.60
73.39	78.43	68.97	92.27
29.41	83.33	17.86	93.60
70.70	75.00	66.90	82.04
70.42	73.53	67.57	94.37

(a) 通过因果关系对 RoBERTa-Large 进行细粒度性能评估
在原始测试集上键入。

(b)其通过关系实现的精细化性能
变量重构后的类型。

表 6:对性能最佳的模型 RoBERTa-Large MNLI 进行精细分析。

4.4基于因果关系的精细化性能分析

除了上述总体结果外,我们还进行了细致的分析以检查:
通过我们的六个因果关系,我们评估了最强微调模型 RoBERTa-Large MNLI 的性能。
类型。如表 6a 所示,该模型非常擅长判断诸如“是否为父级”、“是否为子级”之类的关系。
Has-Confounder 模型的 F1 分数均超过 96%,而 Has-Confounder 模型则稍逊一筹。
Has-对撞机关系。这可能是因为对撞机关系是最特殊的类型。
需要基于无条件独立性来识别V结构
仅两个变量,并在给定共同后代的情况下计算相关性。我们还进行了
附录 F 中对未进行微调的模型进行了误差分析。

4.5稳健性分析

鉴于微调模型的出色性能,我们提出下一个问题:是否……
模型真的能很好地学习因果推理能力吗?

我们设计了两种简单的稳健性检验:(1)释义检验,以及 (2)变量检验。
重构。对于 (1)释义,我们只需通过改变文本来释义假设。
附录 C 中给出了每种因果关系及其一些语义等价替代方案的模板。对于 (2)
变量重构中,我们将变量名的字母顺序颠倒过来,即将 A.B.C 翻转为 Z。
Y.X 等等。这两个稳健性检验的灵感来源于虚假相关性。
分析方法详见附录 E。

具体而言,我们采用文本对抗攻击的常用设置 (Morris et al., 2020; Jin et al., 2020),保留训练集并沿用已保存的模型,但对扰动后的测试集进行推理。这样,我们就能区分模型仅对训练数据过拟合和掌握推理能力这两种可能性。

扰动后的结果从表 5b 可以看出,所有模型的性能均大幅下降,在释义测试集上下降幅度高达39.29%,在变量重构后下降幅度高达 62.30%。性能最佳的模型 RoBERTa-Large MNLI 对释义尤其敏感,其性能下降幅度在所有模型中最大;然而,它对变量重构的鲁棒性最强,保持了 67.87 的高 F1 分数。我们在表 6b 中对 RoBERTa-Large MNLI 在扰动下的性能进行了更细致的分析。可以看出,模型性能下降的主要原因是“祖先”(Is-Ancestor)类别(下降至 45.45%)和“后代”(Is-Descendant)类别(下降至29.41%)的性能下降,而其他类别的性能则相对稳定,F1 分数保持在 70% 以上。

基于以上分析,我们对未来研究LLM的CORR2CAUSE能力提出以下建议。首先,由于我们生成的数据与现有LLM的训练数据分布不同,因此可以安全地将其用作测试集来评估现有LLM的性能。其次,在测试微调后的模型时,务必将对抗攻击与独立同分布 (iid)测试集结合使用。我们开源了扰动后的测试集,供未来研究测试模型的泛化能力。

4.6向自然故事的延伸

我们设想CORR2CAUSE数据集将成为未来扩展到各种场景的基础,例如用实际现象实例化变量,并将故事置于更自然的语境中。例如,相关性并不意味着因果关系,我们可以用冰淇淋销量和游泳池客流量这两个变量来实例化,并论证冰淇淋销量未必会影响游泳池客流量,因为它们的相关性可能源于第三个变量,例如炎热的天气。我们提供了一个案例研究,说明如何将数据集中的符号表达式实例化为更自然的故事,并发现像 GPT-4 这样的语言学习模型 (LLM) 可以生成逼真的日常生活故事,这些故事具有可预见的广泛应用前景。更多详情请参见附录 B。

5相关工作

现有的因果推理任务自然语言处理 (NLP)中大量的因果推理研究侧重于利用经验知识来完成诸如推断智能体执行特定任务的原因和结果 (Sap et al., 2019a)、社会情境中的动机和情绪反应 (Sap et al., 2019b)、人们如何通过一系列具体步骤实现特定目标 (Zhang et al., 2020)、在不同的开头下故事的发展 (Qin et al., 2019),以及逻辑逻辑模型 (LLM) 通常如何作为因果关系的知识库 (Willig et al., 2023; K c man et al., 2023)等任务。相比之下,我们的CORR2CAUSE任务侧重于模型的纯粹因果推理能力,这是一种基于形式上正确的因果推理规则的知识依赖型推理能力。

现有逻辑推理任务另一个相关文献领域是逻辑推理任务,其中较为成熟的任务是自然语言推理 (NLI),用于识别一对句子之间的语义关系 (MacCartney & Manning, 2008; Bowman et al., 2015)。NLI数据集主要关注集合关系和释义关系。例如,“一群男孩正在踢足球”可以蕴含“一些家伙正在踢足球”,其中“男孩”是“家伙”的子概念,“一群”和“一些”是释义。近年来,人们越来越致力于将推理任务扩展到各种逻辑推理技能,例如演绎逻辑和宣传技巧 (Jin et al., 2022; Alhindi et al., 2022)。我们的CORR2CAUSE数据集是第一个测试相关性到因果关系推理技能的数据集,这在同类数据集中独树一帜。

6结论

在这项工作中,我们引入了一个新的任务CORR2CAUSE,用于从相关性中推断因果关系,并收集了一个包含超过 20 万个样本的大规模数据集。我们评估了大量 LLM 在该新任务上的性能,结果表明,现成的 LLM 在该任务上的表现不佳。我们也证明,可以通过微调来重新利用 LLM 来处理该任务,但未来的工作需要注意分布外泛化问题。为了避免 Goodhart 定律的影响,我们建议使用该数据集来评估那些尚未接触过该数据集的 LLM 的纯因果推理能力。鉴于当前 LLM 的推理能力有限,以及难以将实际推理与训练语料库衍生的知识区分开来,我们的社区必须致力于准确地分离和衡量这两种能力。我们相信,目前的工作是迈出的第一步。

局限性和未来工作

我们指出这项工作的几个局限性,并提出了未来的研究方向:首先,在本研究中,我们将因果图的节点数限制在两到六个,但未来的研究可以自由地探索更大的图。其次,我们并未假设该推断问题中存在隐藏的混杂因素,因此我们欢迎未来的研究生成更具挑战性的数据集,以推断是否存在隐藏的混杂因素,这类似于快速因果推断 (FCI) 的因果发现算法 (Spirtes 等人, 2000)。此外,我们也欢迎对其他因果发现算法的探索。

最后,提出这项任务的很大一部分动机源于我们日常推理中无效推理模式的问题 (Jin et al., 2022),这可能为虚假新闻的广泛传播提供温床。我们认为错误的因果推断是一种普遍存在的谬误信念,并欢迎未来的研究将这一基准概念与更多基于混淆相关性和因果关系的现实世界错误信念联系起来。

致谢

我们感谢 Riley Goodside 为改进 LLM 的提问提示提出的宝贵建议。我们感谢 Luigi Gresele 和 Amir Hossein Karimi 为我们改进因果发现问题的表述提出的建议。

本文部分内容基于德国联邦教育与研究部 (BMBF) 的资助项目:图宾根人工智能中心,项目编号:01IS18039B;卓越机器学习集群,项目编号:EXC 2064/1 – 项目编号:390727645;美国国家科学基金会 (NSF) 资助项目 (#2306372);瑞士国家科学基金会 (NSF) 资助项目 (#201009);以及哈斯勒基金会 (Haslerstiftung) 的“负责任人工智能”资助项目。金志静 (Zhijing Jin) 获得生命未来研究所 (Future of Life Institute) 和开放慈善基金会 (Open Philanthropy) 的博士奖学金资助。我们还要感谢 OpenAI 通过研究人员访问计划 (Researcher Access Program) 为金志静授予其 GPT 系列 API 的使用权限。

参考

Tariq Alhindi, Tuhin Chakrabarty, Elena Musi 和 Smaranda Muresan. “基于多任务指令的谬误识别提示”。载于 2022 年自然语言处理实证方法会议论文集,第 8172–8187 页,阿联酋阿布扎比,2022 年 12 月。计算语言学协会。网址: <https://aclanthology.org/2022.emnlp-main.560>。

Chandra Bhagavatula, Ronan Le Bras, Chaitanya Malaviya, Keisuke Sakaguchi, Ari Holtzman, Hannah Rashkin, Doug Downey, Wen-tau Yih 和 Yejin Choi. 归纳常识推理。

第八届国际学习表征会议 (ICLR 2020), 埃塞俄比亚的斯亚巴巴, 2020 年 4 月 26–30 日。OpenReview.net, 2020。网址: <https://openreview.net/forum?id=Byg1v1HKDB.1>

Samuel R. Bowman, Gabor Angeli, Christopher Potts 和 Christopher D. Manning. “用于学习自然语言推理的大型标注语料库”。载于 2015 年自然语言处理实证方法会议论文集,第 632–642 页,葡萄牙里斯本,2015 年 9 月。计算语言学协会。doi:10.18653/v1/D15-1075。URL: <https://aclanthology.org/D15-1075>。

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever 和 Dario Amodei. 语言模型是少样本学习者。H. Larochelle, M. Ranzato, R. Hadsell, MF Balcan 和 H. Lin (编),《神经信息处理系统进展》,第 33 卷,第 1877–1901 页。Curran Associates, Inc., 2020 年。网址: <https://proceedings.neurips.cc/paper/2020/file/1457c0d6bfc4967418bfb8ac142f64a-Paper.pdf>。6

David Maxwell Chickering. 基于贪婪搜索的最优结构识别。机器学习杂志。

研究,3:507–554,2002 年。URL <http://jmlr.org/papers/v3/chickering02b.html>。3

Jacob Devlin, Ming-Wei Chang, Kenton Lee 和 Kristina Toutanova. “BERT :用于语言理解的深度双向 Transformer 的预训练” 。载于《2019 年北美计算语言学协会年会论文集 :人类语言技术》,第 1 卷 (长篇和短篇论文) ,第 4171–4186 页,明尼苏达州明尼阿波利斯,2019 年 6 月。计算语言学协会。doi:10.18653/v1/N19-1423。URL: <https://aclanthology.org/N19-1423>。1, 6

Clark Glymour, Kun Zhang 和 Peter Spirtes. 基于图模型的因果发现方法综述。《遗传学前沿》,10:524,2019。ISSN 1664-8021。doi: 10.3389/fgene.2019.00524。URL <https://www.frontiersin.org/article/10.3389/fgene.2019.00524>。2, 3

Madelyn Glymour, Judea Pearl 和 Nicholas P Jewell. 《统计学中的因果推断:入门》。约翰 Wiley and Sons 出版社,2016 年,第 2.3 页

Andrew Gordon, Zornitsa Kozareva 和 Melissa Roemmele. “SemEval-2012 任务 7:合理选项的选择:常识因果推理的评估” 。载于《*SEM 2012:第一届词汇与计算语义学联合会议 第一卷:主会议及共享任务论文集,以及第二卷:第六届国际语义评估研讨会 (SemEval 2012) 论文集》,第 394-398 页,加拿大蒙特利尔,2012 年 6 月 7-8 日。计算语言学协会。网址: <https://aclanthology.org/S12-1052>。

何鹏程、刘晓东、高建峰、陈伟柱。 “DeBERTa:基于解耦注意力机制的解码增强型BERT” 。第九届国际学习表征会议 (ICLR 2021) ,线上会议,奥地利,2021 年 5 月 3-7 日。OpenReview.net,2021。网址: <https://openreview.net/forum?id=XPZlaotutsD.6>

Patrik O. Hoyer, Dominik Janzing, Joris M. Mooij, Jonas Peters 和 Bernhard Schölkopf. “基于加性噪声模型的非线性因果发现” 。载于 Daphne Koller, Dale Schuurmans, Yoshua Bengio 和 Léon Bottou (编),《神经信息处理系统进展 21:第二十二届神经信息处理系统年会论文集》,加拿大不列颠哥伦比亚省温哥华,2008 年 12 月 8-11 日,第 689-696 页。Curran Associates, Inc., 2008 年。网址: <https://proceedings.neurips.cc/paper/2008/hash/f7664060cc52bc6f3d620bcedc94a4b6-Abstract.html>。

Di Jin, Zhijing Jin, Joey Tianyi Zhou 和 Peter Szolovits. “BERT 真的鲁棒吗?用于文本分类和蕴含自然语言攻击的强基线” 。载于《第三十四届 AAAI 人工智能大会 (AAAI 2020)、第三十二届人工智能创新应用大会 (IAAI 2020) 和第十届 AAAI 人工智能教育进展研讨会 (EAAI 2020)》,美国纽约,2020 年 2 月 7-12 日,第 8018-8025 页。AAAI 出版社,2020 年。网址: <https://aaai.org/ojs/index.php/AAAI/article/view/6311.9>

Zhijing Jin, Abhinav Lalwani, Tejas Vaidhya, Xiaoyu Shen, Yiwen Ding, Zhiheng Lyu, Mrinmaya Sachan, Rada Mihalcea 和 Bernhard Schölkopf. “逻辑谬误检测” 。载于《计算语言学协会研究成果:EMNLP 2022》,第 7180–7198 页,阿联酋阿布扎比,2022 年 12 月。计算语言学协会。网址: <https://arxiv.org/abs/2202.13758>。9, 10

Emre Kıcıman, Robert Ness, Amit Sharma 和 Chenhao Tan. “因果推理和大型语言模型:开辟因果关系的新领域” 。arXiv 预印本 arXiv:2305.00050, 2023 年,第 1 卷,第 9 页。

Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov 和 Luke Zettlemoyer. “BART:用于自然语言生成、翻译和理解的序列到序列预训练去噪” 。载于第 58 届计算语言学协会年会论文集,第 7871–7880 页,在线,2020 年 7 月。计算语言学协会。doi:10.18653/v1/2020.acl-main.703。网址: <https://aclanthology.org/2020.acl-main.703>。

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer 和 Veselin Stoyanov. “RoBERTa:一种鲁棒优化的 BERT 预训练方法” 。CoRR, abs/1907.11692, 2019。URL: <http://arxiv.org/abs/1907.11692>。6

Bill MacCartney 和 Christopher D. Manning。“自然语言推理中语义包含与排除的建模”。载于第22届国际计算语言学会议 (Coling 2008)论文集,第 521-528页,英国曼彻斯特,2008年8月。Coling 2008组委会。网址: <https://aclanthology.org/C08-1066>。

Brendan D. McKay 和 Adolfo Piperno. 实用图同构,II. 符号计算杂志, 60: 94–112, 2014. doi: 10.1016/j.jsc.2013.09.003. URL <https://doi.org/10.1016/j.jsc.2013.09.003>

John Morris, Eli Lifland, Jin Yong Yoo, Jake Grigsby, Di Jin 和 Yanjun Qi。“TextAttack:自然语言处理中对抗攻击、数据增强和对抗训练的框架”。载于《2020 年自然语言处理实证方法会议:系统演示论文集》,第 119-126 页,2020 年 10 月在线发表。计算语言学协会。doi:10.18653/v1/2020.emnlp-demos.16。网址: <https://aclanthology.org/2020.emnlp-demos.16>。 9

OpenAI. GPT-4 技术报告。CoRR,abs/2303.08774,2023。doi:10.48550/arXiv.2303.08774。
URL <https://doi.org/10.48550/arXiv.2303.08774>。 1, 6

Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul F. Christiano, Jan Leike 和 Ryan Lowe。训练语言模型以根据人类反馈遵循指令。

CoRR,abs/2203.02155,2022。doi:10.48550/arXiv.2203.02155。网址<https://doi.org/10.48550/arXiv.2203.02155>。 1, 6

朱迪亚·珀尔。《智能系统中的概率推理:似然推理网络》。摩根出版社。
Kaufmann,1988年。3

Judea Pearl. 因果关系:模型、推理和推断 (第二版)。剑桥大学出版社。
2009年1月

Jonas Peters, Dominik Janzing 和 Bernhard Schölkopf。《因果推理要素:基础与学习算法》。麻省理工学院出版社,2017 年。网址: <https://mitpress.mit.edu/books/elements-causal-inference>。

秦连辉, Antoine Bosselut, Ari Holtzman, Chandra Bhagavatula, Elizabeth Clark 和 Yejin Choi。“反事实故事推理与生成”。载于 2019 年自然语言处理实证方法会议暨第九届自然语言处理国际联合会议 (EMNLP-IJCNLP) 论文集,第 5043–5053 页,中国香港, 2019 年 11 月。计算语言学协会。
doi:10.18653/v1/D19-1509。URL: <https://aclanthology.org/D19-1509>。 1, 9

Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei 和 Ilya Sutskever。语言
模型是无监督多任务学习器。OpenAI Blog,1(8),2019。1,6

Victor Sanh, Lysandre Debut, Julien Chaumond 和 Thomas Wolf。“DistilBERT, BERT 的精简版:更小、更快、更便宜、更轻”。CoRR,abs/1910.01108,2019。URL: <http://arxiv.org/abs/1910.01108>。6

Maarten Sap, Ronan Le Bras, Emily Allaway, Chandra Bhagavatula, Nicholas Lourie, Hannah Rashkin, Brendan Roof, Noah A. Smith 和 Yejin Choi。ATOMIC:用于 if-then 推理的机器常识图集。第三十三届 AAAI 人工智能大会, AAAI 2019, 人工智能第三十一次创新应用大会, IAAI 2019, 第九届 AAAI 人工智能教育进展研讨会, EAAI 2019, 美国夏威夷檀香山, 2019 年 1 月 27 日至 2 月 1 日, 第 3027-3035 页。AAAI 出版社, 2019a。doi:10.1609/aaai.v33i01.33013027。URL <https://doi.org/10.1609/aaai.v33i01.33013027>。 1, 9

Maarten Sap, Hannah Rashkin, Derek Chen, Ronan Le Bras 和 Yejin Choi。“社会 IQA:关于社会互动的常识推理”。载于 EMNLP 2019, 2019b, 1, 9

Shohei Shimizu, Patrik O. Hoyer, Aapo Hyvärinen 和 Antti J. Kerminen. 用于因果发现的线性非高斯非循环模型。J. 机器学习, 7:2003–2030, 2006. URL <http://jmlr.org/papers/v7/shimizu06a.html>。3

Sam Shleifer 和 Alexander M. Rush. 预训练摘要蒸馏。CoRR, abs/2010.13002, 2020. URL <https://arxiv.org/abs/2010.13002>。6

Peter Spirtes 和 Kun Zhang. 因果发现与推断: 概念与最新方法论进展。载于《应用信息学》, 第3卷, 第1-28页。SpringerOpen出版社, 2016年。2, 3

Peter Spirtes, Clark Glymour 和 Richard Scheines. 《因果关系、预测和搜索》。1993年, 第2卷, 第3期。

Peter Spirtes, Clark Glymour 和 Richard Scheines. 《因果关系、预测与搜索》(第二版)。自适应计算与机器学习。麻省理工学院出版社, 2000年。ISBN 978-0-262-19440-2。1.2.3.10

Rohan Taori, Ishaan Gulrajani, Tianyi 张, Yann Dubois, Xuechen Li, Carlos Guestrin, Percy Liang 和 Tatsunori B. Hashimoto. 斯坦福羊驼: 遵循指令的美洲驼模型。 https://github.com/tatsu-lab/stanford_alpaca, 2023年7月

雨果·图夫龙、蒂博·拉夫里尔、戈蒂埃·伊扎卡尔、泽维尔·马丁内特、玛丽-安妮·拉肖、蒂莫西·拉克鲁瓦、巴蒂斯特·罗齐埃、纳曼·戈亚尔、埃里克·汉布罗、费萨尔·阿扎尔、奥雷利安·罗德里格斯、阿曼德·朱兰、爱德华·格雷夫和纪尧姆·兰普尔。Llama: 开放高效的基座语言模型。CoRR, abs/2302.13971, 2023. doi:10.48550/arXiv.2302.13971. 网址 <https://doi.org/10.48550/arXiv.2302.13971>。7

Ruibo Tu, Chao Ma 和 Cheng Zhang. chatgpt 在上下文中的因果发现性能: 神经性疼痛诊断。arXiv 预印本 arXiv:2301.13819, 2023年。1

Moritz Willig, Matej Zecevic, Devendra Singh Dhami 和 Kristian Kersting. 《探究因果事实的相关性: 大型语言模型与因果关系》, 2023年。网址: <https://openreview.net/forum?id=UPwzqPOs4-.9>

Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest 和 Alexander Rush. “Transformers: 最先进的自然语言处理”。载于《2020年自然语言处理实证方法会议: 系统演示论文集》, 第38-45页, 在线, 2020年10月。

计算语言学协会。doi:10.18653/v1/2020.emnlp-demos.6。URL: <https://aclanthology.org/2020.emnlp-demos.6.6.7.14>

Yuxi Xie, Guanzhen Li 和 Min-Yen Kan. Echo: 通过以人为中心的事件因果关系推断推理。arXiv 预印本 arXiv:2305.14740, 2023年。1

Matej Zecevic, Moritz Willig, Devendra Singh Dhami 和 Kristian Kersting. “因果鹦鹉: 大型语言模型可能谈论因果关系, 但并非真正具有因果性。” arXiv 预印本 arXiv:2308.13067, 2023年。1

张坤和阿波·海瓦里宁. “基于加性扰动的因果关系发现: 信息论视角”。载于《机器学习与数据库知识发现: 欧洲会议论文集 (ECML PKDD 2009)》, 斯洛文尼亚布莱德, 2009年9月7-11日, 第二部分20》, 第570-585页。Springer出版社, 2009年。3

李章、吕青和克里斯·卡利森-伯奇. “使用 WikiHow 进行目标、步骤和时间顺序推理”。载于 2020 年自然语言处理实证方法会议 (EMNLP) 会议录, 第 4630–4639 页, 2020 年 11 月在线发表。计算语言学协会。doi:10.18653/v1/2020.emnlp-main.374。网址: <https://aclanthology.org/2020.emnlp-main.374>。

Susan Zhang, Stephen Roller, Naman Goyal, Mikel Artetxe, Moya Chen, Shuohui Chen, Christopher Dewan, Mona T. Diab, Xian Li, Xi Victoria Lin, Todor Mihaylov, Myle Ott, Sam Shleifer, Kurt Shuster, Daniel Simig, Punit Singh Koura, Anjali Sridhar, Tianlu Wang 和 Luke Zettlemoyer. OPT: 开放预训练 Transformer 语言模型。CoRR, abs/2205.01068, 2022. doi:10.48550/arXiv.2205.01068. URL: <https://doi.org/10.48550/arXiv.2205.01068>。

实施细节

在使用我们的数据对基于 GPT 的模型进行微调时,我们使用 OpenAI 的默认设置。我们使用微调 API;对于基于 BERT 的模型,我们使用transformers库 (Wolf 等人,2020)。并在配备 40G 显存的 NVIDIA Tesla A100 GPU 的服务器上训练模型。为了适应对于GPU内存,我们将批大小设置为8。我们使用验证集来调整学习率。取值范围为 {2e-6, 5e-6, 1e-5, 2e-5, 5e-5};辍学率取值范围为 {0, 0.1, 0.2, 0.3};以及权重衰减,其取值范围为{1e-4, 1e-5}。我们训练模型直至收敛。通常约为十个纪元。

查询自回归线性模型时,我们按如下方式提出提示:

问题:[前提]

我们能否得出以下结论:[假设]?请回答“是”或“否”。

回答:

B生成自然故事

为了根据我们的符号表达生成自然的故事,我们利用了最先进的LLM技术。GPT-4 非常擅长故事生成。我们在提示中设计了详细的说明,并且在我们的案例研究中,我们生成了大约 200 个故事。表 7 展示了两个示例故事。表 8 中报告了总体统计数据。

	示例 1 (标签=负面)	示例 2 (标签=阳性)
象征性的形式	前提:假设存在一个封闭系统 两个变量 A 和 B。所有统计 这两个变量之间的关系如下:A 与 B 相关。 假设:A 直接影响 B。 承诺与假设的关系:前提不是假设的必要条件。	前提:假设存在一个封闭系统 包含三个变量 A、B 和 C。这三个变量之间的所有统计关系如下。 具体来说:A 与 C 相关。B 与……相关。 与 C 有关。然而,A 与 B 无关。 假设:A 直接影响 C。 承诺与假设的关系:前提是必要条件 对于假设而言,如果前提为真, 这个假设必然是正确的。
自然的故事	前提:假设存在一个封闭系统 两个变量:冰淇淋销量和游泳池客流量。所有统计 这两个变量之间的关系如下:冰淇淋销量与游泳池到访人数相关。 假设:冰淇淋销量直接影响 游泳池出勤率。 前提与假设的关系:前提并非假设的必要条件。 冰淇淋销量与 游泳池使用率可能源于 第三个变量,例如炎热的天气, 它既能增加冰淇淋销量,又能增加游泳池的客流量。因此, 它并非 冰淇淋销售直接 影响游泳池的客流量。	前提:我们考虑三个因素:吃垃圾食品 (A)、肥胖 (C)和看电视 (B)。它们之间存在相关性。 食用垃圾食品与肥胖之间的关系,以及 看电视和肥胖之间有什么关系? 然而,吃垃圾食品和看 电视节目之间是相互独立的。 假设:食用垃圾食品会直接影响肥胖。 前提与假设的关系:前提提供了必要的信息。 该假设成立的条件。它确立了 自变量 A (吃垃圾食品) 食物)和 B (看电视)以及他们的 与肥胖的相关性。鉴于这些 如果属实,则支持了食用垃圾食品直接导致肥胖的假设。

表 7:基于我们CORR2CAUSE中的符号形式生成的自然故事示例数据集,表明我们的数据集具有广泛的应用价值,可作为各种相关性到因果关系推理任务的起点。

测试集大小 102
开发集大小 102
代币/场所 64.88
Tokens/Hypothesis 13.54
标记/说明 64.66
正面标签占比 1.67%

表 8:我们生成的自然故事的统计数据。我们报告了测试集和开发集中的样本数量;每个前提的词元数 (#词元/前提),假设的词元数 (#词元/假设)。
以及解释 (# Tokens/Explanation);以及正面标签的百分比 (% Positive Labels)。

如需了解更多信息,我们使用的确切提示是“以下是一条因果推理规则: [符号]
请提供一个体现此现象的真实案例。格式如下:
“前提:”、“假设:”以及“承诺与假设之间的关系:”。

C模板和释义

我们使用表 9 中的语言化模板来构建所有六个因果关系的假设。

因果关系假设模板
Is-Parent {Var i} 直接导致 {Var j}。 Is-Ancestor {Var i} 导致其他事情,进而导致 {Var j}。 Is-Child {Var j} 直接导致 {Var i}。 Is-Descendant {Var j} 是 {Var i} 的原因,但不是直接原因。 Has-Collider 存在 {Var i} 和 {Var j} 的至少一个碰撞体 (即共同效应)。 Has-Confounder 存在 {Var i} 和 {Var j} 的至少一个混杂因素 (即共同原因)。
释义
Is-Parent {Var i} 直接影响 {Var j}。 祖先变量 {Var i} 通过某些中介变量影响 {Var j}。 Is-Child {Var j} 直接影响 {Var i}。 Is-Descendant {Var j} 通过某些中介影响 {Var i}。 Has-Collider {Var i} 和 {Var j} 共同导致其他一些变量。 Has-Confounder 某些变量同时导致 {Var i} 和 {Var j}。

表 9:假设中每个因果关系的模板及其释义。我们使用{Var {i} 和 {Var j} 分别作为两个变量的占位符。

D数据集版本更新变更日志

两种等价形式	复制属性	去重方法
β IsParent(i, j)	两个完全相同的字符串	通过强制 $i < j$,只保留一个。
β IsAncestor(j, i) (原文)	两个不同的字符串,但语义相同	从这两个样本中随机抽取一个。
β IsAncestor(j, i) (释义) β	两个完全相同的字符串	通过强制 $i < j$,只保留一个。
HasCollider(i, j)	两个不同的字符串,但语义相同	从这两个样本中随机抽取一个。
β HasConfounder(i, j)	两个不同的字符串,但语义相同	从这两个样本中随机抽取一个。

表 10:六种因果关系类型的去重方法及其表述。

去重策略如主论文第 3.7 节所述,我们的原始数据集 (v1.0)
由于对称关系和表述方式,存在重复。我们在表 10 中列出了几个例子。
我们原始数据中存在重复假设的原因之一,是其对称性。
诸如 Is-Parent(A, B) 和 Is-Child(B, A) 之类的关系,以及类似地,以下是其释义版本:

Is-Ancestor(A, B) 和 Is-Descendent(B, A)。另一个典型原因是语义等价性。这些语言表达模板适用于“存在碰撞者”和“存在混淆者”关系。例如,Has-Collider(A, B) 和 Collider(B, A) 的文本表述为“至少存在一个分别是{A和B,B和A}的碰撞体(即共同效应),它们在语义上是等价的。两者意思相近,所以我们随机保留其中一个。

去重后数据集统计结果

既然重复的根本原因在于因果关系的对称性,或者经过口头描述,最终得到的新数据CORR2CAUSE v2.0 正好是原始数据的一半。正如我们所说如前文第 3.7 节表 3 所述,样本总数减少了一半,而标签分布和其他所有属性都相同。为了构建每个分割,我们应用相同的方法。对测试集、训练集和开发集进行去重。我们注意到一些重复项是因此,我们优先保持测试集和训练集不变(以尽量减少对测试集和训练集的影响)。实验结果),然后通过去除交叉拆分的重复项来减少开发集,具体而言:

```
· test_2.0 = deduplicate(test_1.0)
· train_2.0 = deduplicate(train_1.0)
· dev_2.0 = deduplicate(dev_1.0) \ {test_2.0, train_2.0}
```

我们预计实验结果几乎不会发生变化。万一出现轻微的可能性,也请告知我们。开发集的这种变化可能会影响训练过程中的模型选择,未来工作人员可以随时重新训练模型并更新确切的性能数据。

虚假相关性分析

我们的两项鲁棒性测试(释义和变量重构)的灵感来源于我们的数据分析。我们通过在表 11 中报告逐点结果来检查数据中是否存在虚假相关性。标签与任何不超过四个词元的 n-gram 之间的互信息 (PMI)。此外,我们还在表 11 的|Diff|列中报告了 PMI 与两个标签之间的差异,并报告前 10 个 n-gram。我们稳健性测试的设计理念是,如果模型的正确判断依赖于利用那么,这些虚假的关联性,在我们的扰动中就会打破这种依赖关系。

N-Gram	PMI (非企业标签)	PMI (企业标签)	差异
一个原因	1.692209	-1.025611	2.717820
原因	1.663640	-0.983790	2.647430
A 原因	1.640679	-0.951610	2.592289
A 对 D 造成直接影响,但对 E 造成直	1.621820	-0.926075	2.547895
接影响,但	1.606052	-0.905316	2.511369
	1.592673	-0.888107	2.480781
	1.584826	-0.878180	2.463006
	1.583897	-0.877014	2.460911
	1.582980	-0.875864	2.458844
	1.582074	-0.874728	2.456802

表 11:标签和 n-gram 之间的 PMI。标签包括非蕴含 (Non-Ent.)和蕴含 (Ent.)。n-gram 包括所有不超过四个单词的词。|Diff|列显示的是两个标签的 PMI 值之差的绝对值。我们展示前 10 名。在 |Diff| 列中,PMI 与两类差异最大的 n-gram。

我们可以看到,一些虚假相关性源于假设的构建方式,例如“a “原因(为了)”和“直接的(一个)”(我们用释义任务来打破这种表达方式),以及其他一些表达方式。与变量名关联,例如“对于 D (但是)”和“对于 E (但是)”(我们使用变量重构以打破常规)。

细粒度误差分析

除了表 6a 中按因果关系类型进行的精细分析(针对微调模型)之外,我们还表 12 也报告了未微调模型的此类误差分析。

选定模型	关系类型	GPT-3.5	GPT-3.5	GPT-3.5	F1	精确率	召回率	准确率
GPT-3.5	全部	21.69	17.79	是父级	8.82	100	是祖先	0 0 是
GPT-3.5	子级	9.84	100	是后代	14.29	11.9	有碰撞因子	4.62
GPT-3.5	34.24	25.51	有混杂因子	15.33	8.86	全部	0	90.67
GPT-4	29.08	20.92	0 0 是父级	是祖先	30.77	31.25	是	5.17
GPT-4	子级	0 0 是后代	26.98	17.35	有碰撞因子	44.1	17.86	84
GPT-4	30.18	有混杂因子	20.67	11.53	52.07	35.12	56.76	37.8
GPT-4					47.66	64.6	0	82.67
GPT-4					30.3	88	0	84.53
					60.71	75.47	81.82	32.71
					100	23.86		
RoBERTa MNLI	所有				22.79	34.73	16.96	82.5
RoBERTa MNLI	是父母				0	0	0	82.67
RoBERTa MNLI	是祖先				0	0	0	91.2
RoBERTa MNLI	是儿童				0	0	0	84.53
RoBERTa MNLI	是后代				0	0	0	92.53
RoBERTa MNLI	Has-Collider				43.45	39.73	47.93	59.52
RoBERTa MNLI	混杂因素				0	0	0	84.45

表 12:一些选定的非微调模型的细粒度评估结果。

这些结果尤其具有启发性,展示了现成模型在识别方面的表现。
具体来说,GPT-3.5 无法识别祖先关系,而 GPT-4 则无法识别祖先关系。
所有与父母和子女之间的直接因果关系都得到了认可。而RoBERTa MNLI只做了碰撞器实验。
关系相对正确。请注意,当 F1 分数为零时,准确率是……的结果。
总是预测该关系的否定类别。

G LLM性能优化

由于我们在第 4.2 节中的实验是基于简单的、零样本提示,我们探索是否有更好的方法。
提示策略可以提高性能。我们通过结合以下方式增强查询提示:
几种策略:(1)利用系统提示,明确模型的专业技能 (“您是一位高度专业化的专家”)。
(1)具备深厚因果推理知识的智能问答机器人。”);(2)包括
两个样本量较小的例子,一个正面例子和一个反面例子;(3)实施思维链
通过 “让我们一步一步地思考”来引导语言模型生成逐步语句。
推理。表 13 展示了相对经济实惠的模型 GPT-3.5 的评估结果,
优化后的提示使 F1 性能比原始性能提高了 4 个百分点。
然而,我们可以看到,尽管部署了所有三种策略,该模型仍然……
努力完成这项艰巨的任务。

	F1	精确率	召回率	准确率
GPT-3.5 (普通查询;原始)	21.69	17.79	27.78	17.29
GPT-3.5 (增强型查询)	25.44	48.11		52.01

表 13:GPT-3.5 在不同查询下的性能。我们引用了原始性能数据。
表4。