

CausalFlip:超越LLM因果判断的基准

语义匹配

王雨哲
弗吉尼亚大学
美国夏洛茨维尔
srq3da@virginia.edu

朱耀辰
弗吉尼亚大学
美国夏洛茨维尔
uqp4qh@virginia.edu

李俊东
弗吉尼亚大学
美国夏洛茨维尔
jl6qk@virginia.edu

抽象的

随着大型语言模型 (LLM)在以下领域的部署日益增多:
在复杂且高风险的决策情境中,必须将推理建立在因果关系而非虚假理由之上。
相关性。然而,在传统推理方面表现出色。
基准测试并不能保证真正的因果推理能力
即使使用逻辑学习方法,高精度仍然可能源于对语义的记忆。
关注模式而不是分析其背后的真正因果结构。
为了弥合这一关键差距,我们提出了一种新的因果推理方法。
基准测试CausalFlip旨在鼓励开发
新的LLM范式或训练算法奠定了LLM的基础
基于因果关系而非语义相关性的推理。CausalFlip
由基于事件三元组的因果判断问题组成,
可能形成不同的混杂因素、链式关系和碰撞因素关系。基于
基于此,对于每个事件三元组,我们构建语义相似的成对问题,这些问题重用相同的事件,但产生相反的因果关系。
答案中,那些严重依赖语义匹配模型是
系统性地导致错误预测。为了进一步探究
鉴于模型对语义模式的依赖性,我们引入了噪声前缀。
这种评估方法在中间因果推理步骤之前添加与因果关系无关的文本,
但并不改变潜在的因果关系。
关系或推理过程的逻辑。我们评估LLM。
在多种训练模式下,包括仅答案训练,
本文提出了一种显式的思维链 (CoT)监督方法,以及一种旨在减轻推理过程中对相关显式依赖的内部化因果推理方法。结果表明:

显式CoT仍然可能被虚假的语义关联所误导,
将推理步骤内化可显著提高
因果基础表明,它有望更好地引出
基础LLM的潜在因果推理能力。代码和
基准测试可在<https://github.com/Yuzhe-W/CausalFlip> 获取。

CCS概念

·计算方法论→自然语言处理;
因果推理和诊断。

关键词

大型语言模型、因果推理、基准测试、数据集

1 引言

凭借前所未有的知识和推理能力,
近年来,语言模型 (LLM)的发展日益迅猛。
在关键领域 (例如医疗诊断)的部署[23, 27]
财务分析[35, 36]和法律体系[16]。然而,这些
人们经常质疑LLM在推理和决策方面的可靠性,因为幻觉可能会造成毁灭性的后果。
结果[12, 19, 21]。传统自回归线性模型[2, 6, 24]




图 1:训练样本的一个典型示例
可能会与错误的语义产生虚假关联。
导致LLM做出错误因果判断的答案。

通过预测下一个标记并给定条件来优化模型。
上下文本质上是利用相关的语义模式。
利用训练数据进行推理并回答新问题
[17, 31] (见图 1)。此外,传统的推理基准
[18, 25, 28, 30]可能无法可靠地揭示 LLM 的因果推理局限性,因为模型
通常可以通过利用语义相关性而不是进行更深层次的因果推理来获得高分。
推理。因此,传统推理与现代推理之间存在着显著差距。
基准测试和LLM的因果推理能力严重阻碍了新的LLM范式或培训的发展。

算法从根本上说是基于因果关系进行推理的。
在传统的自回归学习模型范式中,思维链 (CoT)提示可能是最接近策略的形式。
为了提高LLM在因果推理任务上的性能[14, 34],
其中后几个推理步骤和最终答案“因果”
取决于之前的推理步骤。基于传统推理
基准测试明确鼓励逻辑推理模型生成中间推理步骤,这通常可以提高准确性并做出预测。
更容易检查。然而,显式CoT会导致更高的延迟,并且
代币使用[4, 26]。此外,本质上,CoT结构
它们本身可以被视为对条件分布的建模
根据问题的背景进行下一步推理,并
先前的推理步骤仍然依赖于语义模式
该模型旨在记忆而非因果关系。近期关于隐式认知理论的研究。
提出了一种不同的方法[5]:对于像多位数这样的数学任务
在乘法过程中,该方法逐渐移除 CoT 步骤。
在模型训练过程中,通过引导模型将CoT编码到其内部权重中,使得LLM
能够解决这些数学任务。
准确率很高。然而,这种内化是否能更好地促使模型内化因果推理,目前尚不清楚。
前向传播过程中的模型权重。
本文率先通过建立一种新的方法来弥合这一差距。
基准测试,即CausalFlip,旨在鼓励开发
新的LLM范式或训练算法从根本上说

王宇哲、朱耀辰、李俊东

他们的推理基于因果关系。其核心原则是,那些设计或训练为基于语义相似性(例如,使用自回归的下一个词元预测)生成答案的逻辑学习模型(LLM)会受到虚假语义相关性的影响,即问题中的语义与错误的因果答案之间存在相关性;而那些能够真正利用因果关系进行推理的模型则更胜一筹。如图2顶部所示,我们的基准数据集包含三个子数据集,分别是混淆因素、链式因素和碰撞因素。每个子数据集都包含具有两种因果结构的因果问题:基本结构和相反结构。具体来说,“基本结构”指的是问题中的事件包含与子数据集名称一致的因果结构(例如,在混淆因素数据集中,“基本结构”指的是包含事件构成混淆因素结构的问题),而“相反结构”则指的是事件构成不同因果结构的问题。对于每种结构,我们收集了成对的因果查询,其中两个语义相似的问题基于相同的事件,但标签不同(尽管基础/对立结构的事件集可能不同)。如图2蓝色部分所示的基础对示例:Q1和Q2构成两种类型的因果问题,它们基于相同的事件三元组(雨伞销售、交通堵塞、季风季节),并且具有语义相似的固定模板,这些模板在图2的图注中指定。从基础因果结构(混杂因素)来看,成对问题的标签不同。因此,当我们把Q1/Q2划分为训练集/测试集时,会在问题语义和标签之间引入虚假的语义相关性,而依赖于语义相关性的逻辑学习模型(LLM)将失效。对于结构相反的题对(图2中的橙色部分),Q1和Q2针对不同的事件三元组(打字练习、打字速度、城市预算周)提出相同的两种类型的因果问题,并使用与基础题对相同的模板。但在相反因果结构下,与基础结构具有相同模板的问题的答案却相反。这可以防止可能出现的虚假正相关(即问题中的语义模式与正确标签相关),因为如果每个子数据集仅包含基础结构,则Q1的标签始终为“否”,Q2的标签始终为“是”,模型可能会依赖于特定的问题模板来预测标签。

为了进一步降低查询中任何措辞模式可能导致的答案正相关性,我们提供了两个模板:默认(默认措辞)和替代(基于相同因果结构的替代措辞)。由此产生了四个类别:基本-默认(BD)、基本-替代(BA)、相反-默认(OD)和相反-替代(OA)。每个类别包含相同数量的因果问题对。最后,我们采用成对训练集/测试集划分:对于每一对问题,一个问题用于训练,而其语义相似但标签相反的对问题则用于评估。这样,过度依赖语义模式匹配的方法会受到系统性的惩罚,而优异的性能必须建立在因果结构之上。

作为对基于因果关系的逻辑学习模型(LLM)的初步探索,我们提出了一种名为隐式因果推理的新型LLM训练策略。该策略通过逐步掩盖监督式中间因果推理步骤的标记,将因果推理步骤内化,并在CausalFlip数据集上作为强有力的基线模型。在这种逐步掩盖标记的机制下,模型被鼓励将因果推理编码到其参数中,而不是依赖于显式生成。

步骤。为了进一步探究隐式因果推理是否促使模型更关注因果推理而非语义,我们扩展了CausalFlip数据集,在词干词干(CoT)前添加一个通用的、与因果关系无关的前缀作为语义噪声,同时保持CoT的内容和底层因果结构不变。如果显式CoT依赖语义模式而非因果关系进行推理,那么它应该更容易受到注入噪声的影响。相比之下,隐式CoT的词元移除机制可能教会模型“忽略”此类前缀,从而减轻由此产生的推理缺陷中显式虚假相关性的影响。

在CausalFlip基准测试上进行的大量实验突显了两个主要发现。首先,标准LLM训练策略(无CoT)性能有限,这表明在CausalFlip上取得成功需要将预测建立在因果结构之上,而不是依赖于虚假的语义相关性。

此外,与预训练策略基线和无CoT微调相比,对中间因果推理步骤(显式CoT和隐式因果推理)的监督提高了因果任务的准确率。这表明中间因果推理步骤是CausalFlip任务中因果判断性能提升的主要驱动因素,说明回答这些问题需要基于因果结构的推理。其次,当在不改变底层因果结构的情况下添加一个固定的噪声前缀时,显式CoT的性能下降更为显著,而隐式因果推理则表现出更强的鲁棒性,并取得了比显式CoT更高的准确率。这表明,将推理过程内化可以减少对显式生成的中间因果推理步骤中虚假语义关联的依赖,并更好地保持对因果问题的决策。这项工作的贡献可以概括为以下三点:

·我们引入了CausalFlip,这是一个因果关系基准,由成对的、语义相似的问题组成,这些问题涉及相同的事件,但被赋予相反的标签。

·本设计旨在促进逻辑推理模型(LLM)的开发和训练,使其推理明确地锚定于因果结构而非肤浅的语义线索。我们提出了一种隐式因果推理训练策略,该策略逐步减弱对中间推理标记的监督,以促进内化。我们证明,在噪声前缀干扰下,该策略始终比显式认知训练(CoT)更稳健,表明其对虚假语义相关性的依赖性降低,从而更好地完成因果任务。

·我们引入了一种新颖的噪声前缀评估方法,以测试训练策略是否鼓励因果推理,而不是像传统的自回归语言建模那样依赖语义模式匹配。

2 预赛

2.1 法学硕士基础知识

我们遵循标准的语言建模公式,并将语言学习模型(LLM)视为离散词元序列上的参数化概率模型[1, 2, 24]。令V表示LLM的词汇集,令一个词元化序列为 $x = (1, \dots)$,其中 $x \in V$ 。具有参数的自回归LLM定义了一个联合分布

CausalFlip:超越语义匹配的LLM因果判断基准




图 2:基准测试中使用的因果结构概览以及基本对立对示例。顶行显示三个子数据集（混杂因素、链式效应、碰撞因素）的因果结构；底部扩展了混杂因素的情况并突出显示基本问题对与反义问题对：在基本问题对和反义问题对中，问题1都询问X到……的因果关系。Y 存在于 Z 的背景下，其固定模板为：在 Z 期间，X 的增加是否会导致 Y？问题 2 询问：Z 与 X / Y 之间存在因果关系，其固定模板为：Z 是否会导致 X 和 Y 的增加。

利用链式法则分解法,对 x 进行如下分解:

$$(x)= \quad (|<), \tag{1}$$

其中 $(1, \dots, -1)$ 是前缀上下文。自回归生成过程通过解码 $(\cdot | <)$ 从左到右依次生成标记。在实践中, $(| <)$ 通常

由基于自注意力机制的Transformer架构实例化[32]。具体而言,令表示最后一层的隐藏表示。在前缀<的最后一个位置。下一个标记的分布是然后通过词汇表logits应用softmax函数得到,

$$(|<)= \frac{\exp((;))}{\sum_{i \in V} \exp((';))}, \tag{2}$$

中 $(\cdot;)$ 表示分配给每个词汇表的分数 (logit)。标记。在生成过程中,模型会根据给定的上下文 $c =$ 进行条件判断。 $(1, \dots,)$ 并生成一个延续 $y = (1, \dots,)$ 。这诱导条件分布遵循相同的自回归规律:

$$(y | c) = \quad (|c, <), \tag{3}$$

在哪里 $< = (1, \dots, -1)$ 。标准培训目标是 LLMs 是对语料库D 的最大似然估计 (等价地,最小化词级交叉熵):

$$\text{最大值} \sum_{x \in D} \sum_{i=1}^{|x|} \text{日志} (|<). \tag{4}$$

这种下一个词元预测目标会奖励上下文中任何能够提高预测可能性的统计规律,这可以包括与下游标签的虚假语义相关性[2]。在推理阶段,通过解码生成补全结果。例如,通过贪婪解码或随机采样,公式 (3) [8, 29]。特别是,基于采样的解码,例如 top-,通常是用于在生成的文本中权衡多样性和连贯性[7]。由式(3)可知,采用自回归语言模型训练语言学习模型依赖于条件分布。而不是对这些问题进行因果分析,因为因果分析容易受到影响。基于虚假的语义关联给出错误的回答。

2.2 链式推理

在本部分中,我们将显式思维链 (CoT)形式化,为所提出的隐式因果推理奠定了基础以及鲁棒性评估。CoT推理指的是生成在生成结果之前,需要进行中间自然语言推理步骤。最终答案已被证明可以提高性能多步骤推理任务[14, 34]。形式上,令输入/提示设 x 为给定的条件。在 CoT 下,模型的输出是一个单一序列 z ,该序列我们将中间推理步骤 (CoT)标记s和 (ii) 最终答案标记 y 表示为 $z = [s; y]$ 。自回归语言该模型将完整输出的条件似然定义为

$$(z | x) = \prod_{i=1}^{|z|} (|x, z<), \tag{5}$$

其中 $z_{<}$ 是先前生成的输出标记的前缀。

将 z 视为 $z = [s; y]$, 则等价于:

$$(s, y \mid x) = (s \mid x) (y \mid x, s).$$
 (6)

从这个角度来看, s 充当了中间推理步骤。

最终决策 y 取决于 [34]。在推理阶段

时间, CoT 通常会生成单个推理步骤。

通过解码过程 $\text{Dec}(\cdot)$ 展开 s (例如, 贪婪解码或

(抽样) , 然后根据抽样结果预测答案 y :

$$s = \text{Dec}(x), y = \text{Dec}([x; s]).$$
 (7)

然而, CoT 本质上是相关性的而非因果性的, 因为每个

中间步骤仍然基于给定的条件分布。

问题和先前生成的推理步骤, 因此依赖于虚假的语义关联, 而不是基于事实。

真正的潜在因果结构中的推理。

2.3 问题描述

为了解决传统自回归 LLM 的局限性,

我们研究显式 CoT 下的因果判断问答问题。

LLM。令 Q 表示自然语言因果疑问句的空间,

令 A 表示答案空间, 其中 $A = \{\text{是}, \text{否}\}$ 表示

二元因果答案。我们假设每个问题 $\in Q$ 都是

与底层因果图和目标因果图相关联

标签 $\in A$ 反映了在给定条件下的正确因果判断。

我们将基准数据集表示为 $D = \{(\text{这里, 我们假设 LLM 具有参数的一般形式},)\}_{i=1}^n$ 。

式

, 它定义了答案的概率 (以文本格式)。

给定问题 (i) , $\in A$, 并预测答案

$(i) = \arg \max_{\in A} (i)$ 。

3 基准设计

该基准测试的目的是解决传统方法的局限性。

全面评估 LLM 能力的国际基准

为了做出可靠的因果判断。CausalFlip 由事件驱动构建而成。

三元组 $(, ,)$ 并构建二元因果判断问题

跨越三个子数据集: 混杂因素、链式效应和碰撞因素。对于每个

在子数据集中, 我们定义了基本因果结构和相反因果结构,

构建语义相似的问题对, 其正确标签

根据潜在的因果结构进行翻转。结合

通过成对训练集和测试集划分, 这种设计可以惩罚模型对训练集和测试集的依赖性。

关于预测中虚假语义相关性的问题。此外,

我们通过默认和备选方案来控制问题模板。

使用模板来减少模板驱动的正向虚假相关性。

3.1 语义相似但标签互换的词对

采用成对训练集-测试集划分

开发 CausalFlip 数据集的总体原则是:

引入语义上具有虚假相关性的成对问题,

也就是说, 语义相似但结果不同的问题

因果关系答案。这两个问题的主要区别在于因果关系。

它们查询的关系, 因此具有相反的标签, 分别对应于第 3.2 小节中定义的两

问题类型 (i) 和 (ii)。

例如, 在混杂因素数据集中, 一对数据对比了直接效应。

问题: 期间原因会增加吗?

一个语义上类似的混淆因素问题, 会导致

增加

以及?。为了进行评估, 我们采用成对比较。

训练集-测试集划分。在每个数据集中, 对于每一对问题, 我们将一个

问题分配给训练集, 另一个问题分配给测试集, 同时保留

训练集和测试集之间的 Q1/Q2 数量平衡。

这样可以确保每个测试题在培训中都有对应的题目。

它共享相同的事件三元组和类似的语义, 但携带

相反的标签。因此, 如果模型严重依赖语义模式, 它将预测与相应标签

相同的标签。

训练实例, 因此在配对测试问题上失败

其中正确的标签被翻转了。因此, 这方面表现出色。

基准测试需要理解因果结构, 而不是

而不是依赖语义匹配。

3.2 因果结构和引出问题

已建立的 CausalFlip 基准测试由三个子数据集组成, 即 confounder、chain

和 collider, 其中每个数据集类型

研究 $(, ,)$ 之间的典型因果结构。具体而言,

在每种数据集类型中, 我们定义了两种因果结构: 基础 (B)

和相反的 (O)。基础遵循规范因果图

数据集类型, 而 Opposite 则使用另一种因果图, 即

构造目的是为了对同一组问题给出相反的标签

与基础款相比, 该模型无法满足以下需求。采用这种设计, 该模型无法

依赖于问题之间的正向虚假相关性

模板和标签 (例如, 仅包含碱基对, 问题 1 的标签)

第一个问题的答案始终为“否”, 而第二个问题的答案始终为“是”。这迫使我们做出正确的选择。

预测取决于潜在的因果结构。为了保持

为了平衡基准, 我们也构建了相同数量的

每个数据集中基本因果结构和相反因果结构下的配对。

3.2.1 混杂因素数据集。基准 (B) 代表混杂因素。

基本结构, 其中 $\rightarrow$ 和 $\rightarrow$ 没有定向因果关系, ,

从 $\rightarrow$ 到的路径。此数据集中的每个问题对都包含两个

问题类型: (i) 是直接影响问题, 询问是否

在以下背景下, 增加的原因 (我们将背景包括

保持这个问题在语义上与问题 (ii) 接近, 并且 (ii) 是一个

混淆因素问题, 询问是否同时导致和。

基本结构中, 问题 (i) 标记为“否”, 问题 (ii) 是

标记为“是”。相反 (O) 表示相反的结构。

混杂因素数据集, 如下 $\rightarrow$, 并且不存在因果路径

从两者到两者, 这意味着对于两者而言是非因果关系。

并且, 题型 i 和 ii 保持不变, 但由于……

因果结构相反, 标签也随之翻转: 问题 (i) 被分配

是的, 问题 (ii) 已分配编号。

3.2.2 链数据集。基础 (B) 表示链的基本结构如下 $\rightarrow \rightarrow$

, 没有直接的因果路径 $\rightarrow$, ,

这意味着任何影响都是通过 $\rightarrow$ 来介导的。

此数据集中的问题对包含两种问题类型: (i) 是

直接效应问题, 询问增加是否直接导致

在以下背景下 (我们将其作为背景信息, 以保持此问题不变)

在语义上与问题 (ii) 接近, 并且 (ii) 是一条中介路径

问题, 询问增加是否会促进增长, 而这反过来又会如何。

增加。在基础结构下, 问题 (i) 被标记为“否”和“否”。

问题 (ii) 标记为“是”。相反 (O) 表示链式数据集下的相反结构, 遵循 $\rightarrow$, 并且没有因果关系。

, ,

从 $\rightarrow$ 到 $\rightarrow$ 的路径。问题类型保持不变。

CausalFlip:超越语义匹配的LLM因果判断基准

但由于因果结构相反,标签也会翻转:问题 (i)是问题 (ii)被分配为“是”,问题被分配为“否”。

3.2.3对撞机数据集.基准 (B)表示对撞机基准。结构遵循→和→,且 和之间没有定向路径;是一个具有两个独立父节点的碰撞体。每个

实例包含两种问题类型:(i)是直接效应问题,询问在 (我们)的背景下,增加是否会导致
请提供上下文信息,以使此问题在语义上与……接近
问题 (ii)),以及 (ii)是一个碰撞问题,询问增加原因和增加原因是否。在基础结构下,
问题 (i) 标记为“否”,问题 (ii) 标记为“是”。相反
(O)代表碰撞数据集下的相反结构,如下
→ ,不存在从到的因果路径,也不存在因果路径
从到。问题类型保持不变,但标签互换:
问题 (i)的答案是“是”,问题 (ii)的答案是“否”。

3.3 问题模板

成对分割的设计引入了一个强烈的虚假 (负面)
问题语义与因果答案之间的相关性,
理想情况下,这应该会导致LLM培训策略的失败,即
完全依赖语义关联来生成答案,然而,
我们发现自回归线性模型仍然可能利用捷径。
与问题中的短语模式相关,即与答案存在某些剩余的肯定语义关联。为了进一步减少此类关联。
为了简化措辞,我们构建了两组句式。
模板作为随机化手段来减少正向虚假相关性:默认值 (D)和备选方案 (A)。

- Default (D)是 CausalFlip 中的默认问题措辞。它将每个数据集的两种问题类型表示为直接问题。二元问题 (例如,增加……是否会……?)。对于原因在链式碰撞器过 每种数据集类型的混杂因素,程中,我们使用生成一组成对的问题默认模板。
- 备选方案 (A)是另一种表达相同意思的措辞。因果疑问句的类型。它是一种陈述句形式 (例如, An 增加。), 导致增加。该模型会判断该陈述是否正确。答案为二元 (是,否) 。对于每种数据集类型,我们使用以下方法生成另一组配对问题:备选模板。在每个数据集内,我们平衡通过确保样本数量相同,对不同模板类型进行样本抽样。默认配对和备选配对。合并模板具有因果结构 (基础)的家族 (默认与替代)与相反)产生四类: BD、BA、OD和OA。

由于每个数据集都包含相同数量的基准和相反数对数以及相同数量的默认对和备选对, BD、BA、OD 和 OA 中的样本数量相匹配。平衡性阻止了任何结构模板类别 (BD/BA/OD/OA) 避免过度代表,并有助于确保预测结果的准确性。基于因果结构而非模板捷径。

4. 内隐因果推理

在前一节中,我们提出了CausalFlip基准测试。这会在因果问题语义和标签之间引入虚假的语义相关性,使得基于语义训练的模型出现问题。

模式匹配未能促进新型LLM的发展
训练人们运用因果结构推理的策略。在本节中,我们提出一种新的策略,即隐式因果推理,以减少显式 CoT 依赖于因果问题中虚假和显式的语义关联。

4.1 动机与概述

CausalFlip旨在惩罚那些性能不佳的模型。依赖语义进行预测。这激发了训练策略的发展。降低模型对语义相关性的依赖性
在进行因果判断时。作为初步探索,从根本上说,LLM推理建立在因果关系之上,我们采纳了一种渐进式因果推理步骤掩蔽策略,即我们逐步掩蔽因果推理步骤,将其从分析中移除。
训练损失专门用于减轻其对虚假损失的依赖
显式生成的因果推理步骤中的语义关联
并鼓励建立在因果结构基础上的世代发展。

4.2 渐进式因果推理步骤掩蔽

在本部分,我们考虑由输入组成的训练样本。
问题 x,二元答案∈ {是,否},以及显式因果关系推理步骤= (1, … ,)。在我们的设定中,是中间体从相应的因果图中推导出的因果推理步骤,它阐明了关键的结构条件,并引出了答案。

4.2.1显式因果推理步骤监督。我们开始从显式CoT出发,其中所有因果推理步骤的标记都是包含在训练损失中。标准的自回归下一个标记。目标函数应用于所有中间因果推理步骤的符号= (1, … ,) 以及最终答案,如下所示:

$$L_{explicit}() = - \sum_{(x,s_i) \in D} \log(s_i | x), \tag{8}$$

等价地,逐词元似然度由公式(9)给出。这里表示因果推理步骤中的词元数,并且
∈ {1, … , } 表示标记在以下位置的索引:

$$L_{explicit}() = - \sum_{(x,s_i) \in D} \sum_{i=1}^{|s|} \log(p(s_i | x, s_{<i})) \tag{9}$$

4.2.2逐步消除因果推理步骤。对于隐式因果推理,我们逐步掩盖最早的因果关系。
从监督信息中移除推理步骤的标记。在训练步骤中,从监督信息中移除 我们前 ()个标记,仅计算
剩余部分的损失。形式上,我们应用基于步骤的方法。
掩码函数() ∈ {0, 1},基于因果推理步骤标记
职位如下:

$$L_{mask} (;) = - \sum_{(x,s_i) \in D} \sum_{i=1}^{|s|} (()) \log(p(s_i | x, s_{<i})) + \log(p(s_i | x, s_i)) \tag{10}$$

其中 ()= 0 表示损失被屏蔽,并且
(())= 1 表示标准监督 (公式 (10))。因此,第一个
(因果推理步骤的标记{ 1, … , }, ())不接收直接

王宇哲、朱耀辰、李俊东

监督部分,剩余的后缀 $s(i+1)$ 仍然包含在损失函数中。我们始终基于最终答案计算训练损失,以在显式因果推理步骤监督减少的情况下保持任务性能。

5 实证研究本节中,我们在CausalFlip

基准测试集上评估了四种策略(即朴素预训练策略、无因果关系理论 (coT)、显式因果关系理论 (coT) 和隐式因果推理微调)。我们首先发现朴素预训练策略和无因果关系理论 (coT) 策略表现不佳,证实了逻辑逻辑模型(LLM) 需要将其预测建立在因果结构而非语义模式之上才能在CausalFlip 基准测试集中取得成功。此外,我们发现包含中间因果推理步骤的训练策略能够获得更强的因果判断性能。最后,我们进一步证明,当注入噪声语义前缀时,隐式因果推理比显式因果推理理论 (coT) 保持更高的鲁棒性,表明它对虚假语义相关性的依赖性更低,并且能够可靠地建立在因果结构之上。

5.1 研究问题RQ1:与朴素的预训练策略相比,无 CoT、显式 CoT 和隐式因果推理训练策略在我们的因果基准上表现如何?

这个问题比较了各种策略在因果判断方面的能力,因为在CausalFlip中,由于成对分割设计,虚假的语义相关性并不是一个可靠的捷径。

所有策略均采用相同的训练/测试集划分和相同的评估协议,我们报告每个模型的总体准确率。

研究问题 2:隐式因果推理模型能否通过减少对语义模式的依赖,在因果推理任务中表现得比显式因果推理模型更稳健?

正如我们在2.1节分析的那样,自回归线性逻辑模型 (ALM)经过优化以拟合条件分布,因此可能会利用虚假的正语义相关性进行预测,而不是基于潜在的因果结构[17, 31]。基于此,我们进一步检验隐式因果推理是否能减少对语义模式的依赖,方法是在噪声前缀评估条件下将其与显式因果推理 (CoT)进行比较。具体而言,我们在中间因果推理步骤之前注入相同的因果无关前缀,并测量每个模型准确率的变化,以性能下降作为对语义模式而非因果结构依赖程度的指标。

5.2 基线和训练策略我们比较了四种策略来回答本文提出的两个研究问题。在所有实验中,我们都使用Llama-3.2-3B-Instruct作为基础模型。

- 朴素预训练策略(不进行微调):这是未经任何数据集CausalFlip 训练的基础模型。
- 它衡量基线预训练在单独预训练下的因果判断性能,并作为评估微调策略(无 CoT、显式 CoT和隐式因果推理)的参考。

- 无CoT微调:这是标准的仅基于答案的监督式微调基线,其中模型训练

直接预测 CausalFlip中给定因果问题的最终答案。在这种设置下,训练过程中不提供中间因果推理步骤,因此监督仅应用于最终的“是/否”决策。·显式 CoT 微调:与无 CoT 模型不同,该模型使用完整的中间因果推理进行训练。

先进行一系列步骤,然后得出最终答案,并对中间因果推理标记和最终答案都进行监督。

- 隐式因果推理微调:我们逐步屏蔽训练损失中越来越多的中间推理标记的前缀,同时始终监督最终决策。这使得预测的依赖性从显式语义转移到潜在的因果结构。

这四种训练策略能够评估不同的监督策略如何影响我们提出的因果问题数据集上的模型性能。

5.3 训练和评估设置在训练和评估过程中,所有策略均使用相同的固定训练/测试集划分,并采用第3节中定义的相同因果问题,以确保公平比较。以下部分将更详细地介绍训练协议和评估协议。

5.3.1训练。每个微调实例由以下两部分组成:(i)如第 3 节所述,来自CausalFlip的因果问题;(ii)该问题的答案,即二元答案{是,否}。对于无因果关系 (no-CoT),实例结构与之前所述相同,即问题后跟答案。对于显式因果关系 (explicit-CoT) 和隐式因果推理,我们在因果问题和答案之间添加了中间因果推理步骤(参见4.2 小节)。例如,对于混杂因素数据集集中的基本因果结构对,我们采用以下因果推理步骤:

由于不存在从 X 到 Y 的定向因果路径,并且调整 Z 后,X 和 Y 之间的后门就被关闭了,因此

最终答案紧随其后。

5.3.2评估。在测试时,模型会收到一个仅包含问题的提示,并根据其生成的响应进行评估。每个提示包含两部分:(i)格式指令,该指令将模型输出的最终答案限制为二元决策{是,否},这使得即使在显式因果推理和隐式因果推理的设置下(在最终答案之前会生成中间因果推理步骤),也能对其进行解析和评估;(ii)来自CausalFlip的因果问题(定义见第 3 节)。对于每个提示,模型都会生成一个响应,我们提取该响应的最终答案并用它来计算任务准确率。

5.3.3指标。我们仅根据最终的“是/否”答案对生成结果进行评分,而不考虑任何中间的因果推理步骤。具体来说,对于每个测试样本,我们取模型的最终答案(即预测标签)并将其与真实标签进行比较。准确率计算如下:

$$\text{准确率} = \frac{1}{N} \sum_{i=1}^N 1(\hat{y}_i = y_i)。$$

(11)

CausalFlip :超越语义匹配的LLM因果判断基准

表 1:基于混杂因素数据集的性能比较

模型	准确率 :正确/总计 有效 :是/否		
朴素的预训练策略	0.529	529 / 1000	1000 / 1000
无CoT	0.524	524 / 1000	1000 / 1000
显式 CoT	0.892	892 / 1000	987 / 1000
隐性因果推理	0.900	900 / 1000	997 / 1000

表 2:链数据集上的性能比较

模型	准确率 :正确/总计 有效 :是/否		
朴素的预训练策略	0.612	612 / 1000	1000 / 1000
无CoT	0.639	639 / 1000	1000 / 1000
显式 CoT	0.690	690 / 1000	989 / 1000
隐性因果推理	0.757	757 / 1000	998 / 1000

表 3:在 Collider 数据集上的性能比较

模型	准确率 :正确/总计 有效 :是/否		
朴素的预训练策略	0.629	629 / 1000	1000 / 1000
无CoT	0.655	655 / 1000	1000 / 1000
显式 CoT	0.856	856 / 1000	1000 / 1000
隐性因果推理	0.849	849 / 1000	999 / 1000

其中,是测试样本的数量, $\in \{是,否\}$ 是真实标签, $\in \{是,否\}$ 是模型的预测标签 (最终答案),其中 $1[\cdot]$ 是指示函数。为了测量我们报告了所有模型在干净输入数据上的准确率。以及在下述的噪声前缀设置下。

5.3.4噪声前缀评估。为了测试模型侧重于因果推理还是语义,我们注入噪声前缀。

在训练样本的中间因果推理步骤之前。前缀是一段固定的自然语言句子,旨在起到语义干扰的作用,同时保持因果关系。

无关紧要,这既不违反中间推理过程,也不改变潜在的因果结构。我们应用

为确保一致性,所有问题都使用相同的前缀。这样做还可以避免……不同噪声前缀语义之间的虚假相关性以及标签。

我们比较显式因果推理和隐式因果推理,因为它们代表了利用中级水平的两种训练策略。因果推理。显式CoT在训练过程中让模型接触完整的中间因果推理步骤,这可能会增加依赖于虚假的语义相关性,使得其最终决策对噪声前缀更加敏感。相比之下,隐式因果关系推理逐渐掩盖了因果推理步骤中的标记。训练。我们在噪声前缀下评估这两种策略。

5.4 CausalFlip 的性能（研究问题 1）

我们首先通过比较四种策略的表现来回答研究问题1。关于 CausalFlip :朴素预训练策略、标准仅答案微调（无 CoT）、显式 CoT微调 和隐式因果推理微调。我们报告了Confounder、Chain和Collider在干净（不含噪声前缀）输入上的准确率。数据集（表 1,2,3）

在所有三个数据集上,我们都观察到朴素算法的性能较低。预训练和无CoT微调策略,因为这些策略从根本上依赖语义关联而非基础在因果结构中训练 LLM。关于混杂因素,朴素/无 CoT。接近概率值 (0.529/0.524),而显式 CoT 和隐式达到 0.892/0.900;在链上,无CoT (0.639)仅带来微小的收益。与朴素方法 (0.612)相比,显式CoT/隐式方法 (0.690/0.757)更为有效;在 Collider 上,no-CoT 仅比 naive 略高 (0.655 对比 0.655) 。0.629),而显式CoT/隐式CoT分别达到0.856/0.849。这些结果表明中间因果推理步骤是主要驱动因素在因果判断题上的表现有所提高。同时,隐式因果推理的性能仍然具有竞争力,并且在混淆变量和链数据集上超越了显式因果推理。虽然显式因果推理和隐式因果推理偶尔会产生无效的最终答案格式,但我们的人工检查表明所有这些无效答案无法匹配任何已知的格式。是或否（例如,“是”、“否!”）,或其他可识别的决策关键词。此外,无CoT微调的性能有限表明在 CausalFlip 上取得成功需要训练策略有效地将预测建立在因果结构之上,而不是利用虚假的语义相关性。

5.5 噪声前缀下的性能（RQ2）

接下来,我们通过评估显式因果关系和隐式因果关系来回答研究问题2。推理在 CausalFlip 上的表现（使用noisy-prefix）注射（定义见 5.3.4 节）。此前缀旨在表示与因果关系无关,但不违反现有的因果结构。由于潜在的因果结构没有改变,性能下降表明模型的预测能力较弱。

是语义上的,而不是基于因果结构的。如图 3 所示,在所有三个数据集上,添加噪声前缀始终会导致显式CoT的准确率下降幅度更大。与隐性因果推理相比,平均下降幅度约为显式因果推理的 CoT 值为 0.161,隐式因果推理的 CoT 值为 0.092。此外,在噪声前缀设置下,隐式因果推理在混杂因素、链上,比显式CoT实现了更高的准确率,以及碰撞器 (0.769 > 0.699,0.692 > 0.547,0.768 > 0.710)。总体而言,在噪声语义前缀设置下,退化程度越大。显式CoT表明,它仍然依赖于预测答案。过于注重语义而非潜在的因果结构。相比之下,隐性因果推理在以下情况下保持着更高的准确性:同样的干扰,表明在因果关系相关问题上具有更强的稳健性,并且对语义的依赖性降低。

6 相关工作

线性线性模型中的因果推断 :最近的研究探讨了……线性逻辑模型（LLM）可以进行因果推断[11, 15, 33]。在这一研究方向中,目标是评估依赖于线性逻辑模型的因果效应判断。例如,基于潜在的因果结构,评估是否模型可以推断不同结构下的因果关系。假设[10]。一种常见的做法是用自然语言提出因果问题,同时假设其背后存在一个因果模型。问题[10, 15]。先前的工作也探讨了如何引出因果关系从逻辑逻辑模型（LLM）中推断行为,包括因果图和程序指导,这些指导实现了因果推理过程的部分环节。




图 3:在干净输入和噪声前缀条件下,CausalFlip 数据集上显式因果推理与隐式因果推理的准确率对比。注入噪声前缀后,隐式因果推理的性能下降幅度始终小于显式因果推理,且表现更佳,表明其对虚假语义相关性的依赖性更低。

[10, 15] 在此研究背景下,我们的工作从两个方面补充了先前关于使用逻辑逻辑模型 (LLM)进行因果推理的研究。首先,我们引入了一种训练策略,旨在降低LLM在因果关系相关任务中对语义的依赖。其次,我们提出了一种评估模型因果推理能力的基准:它针对事件三元组构建因果判断问题,构造语义相似但标签相反的问题对,并使用成对的训练集-测试集划分,从而系统地惩罚语义匹配。

LLM 的因果基准:先前的研究提出了一系列基准来评估 LLM 中的因果理解:(i)常识因果基准测试模型是否能够在日常知识的基础上选择合理的因果关系[25]。(ii)

因果文本理解基准测试旨在检验模型能否将一段文本中的因果知识应用于新的情境[18]。(iii) 基于图的因果推理基准测试利用因果图和形式化的因果问题来评估模型的因果判断能力[10]。(iv) 综合因果推理基准测试则提供更广泛的因果推理覆盖范围,涵盖文本、数学等领域[33]。最后,(v) 通用逻辑学习模型 (LLM) 评估,例如BIG-bench,包含与因果关系相关的推理任务,通常用于评估模型的一般推理能力[28]。然而,由于已有研究一致发现,模型可以通过利用标签的虚假相关性而非基于潜在因果结构进行推理来获得高准确率[17, 22, 31],因此,此类基准测试的准确率可能并非衡量真实因果推理能力的可靠指标。CausalFlip旨在通过成对训练集和测试集划分,使用语义相似但标签互换的样本对来解决这个问题,依赖于虚假语义相关性的模型性能有限;因此,正确的预测需要建立在因果结构之上。

7 结论

在这项工作中,我们解决了评估 LLM 因果判断中的一个关键差距,即标准的自回归训练模型可以依靠标签相关的语义模式来回答因果问题,而不是将决策建立在潜在的因果结构之上。

为了弥合这一差距,我们引入了基于因果关系的CausalFlip。

基准测试涵盖了混淆因素、链式和碰撞因素等因果结构。实证结果表明,严重依赖语义模式的策略在我们的基准测试中表现不佳,而对中间因果推理步骤进行监督则能提高准确率。更重要的是,我们提出的隐式因果推理策略通过逐步屏蔽中间因果推理步骤的标记,从而降低模型对显式生成的中间推理步骤中可能存在的虚假语义相关性的依赖,展现出明显的优势。

8. 伦理与公平

CausalFlip 不收集用户数据,也不涉及人类受试者,不包含任何私人记录或需要征得同意的信息来源,例如可识别身份的信息、医疗或财务记录等。在数据集构建过程中,我们人工检查了数据,以降低文本中包含敏感信息、冒犯性语言或潜在有害的刻板印象和偏见的风险。我们对整个数据集始终如一地进行此项审查,以确保发布的基准测试尽可能避免此类内容。最后,此基准测试旨在用于研究评估,我们鼓励负责任地使用,包括清晰地说明其局限性,并在开发下游应用程序时遵守既定的伦理准则。

参考

[1] Yoshua Bengio, Réjean Ducharme, Pascal Vincent 和 Christian Janvin. 2003 年. 神经网络语言模型。《机器学习研究杂志》3, null (2003 年 3 月), 1137–1155 年。

[2] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever 和 Dario Amodei. 2020 年。《语言模型是少样本学习器》。arXiv:2005.14165 [cs.CL] <https://arxiv.org/abs/2005.14165>

[3] Tianqi Chen, Bing Xu, Chiyuan Zhang 和 Carlos Guestrin. 2016. Training Deep Nets with Sublinear Memory Cost. arXiv:1604.06174 [cs.LG] <https://arxiv.org/abs/1604.06174>

[4] Jeffrey Cheng 和 Benjamin Van Durme. 2024. 压缩思维链:通过密集表示进行高效推理。arXiv :2412.13171 [cs.CL]

CausalFlip :超越语义匹配的LLM因果判断基准

https://arxiv.org/abs/2412.13171 [5]邓云天,崔艺珍,Stuart Shieber. 2024. 从显式认知训练到隐式认知训练:逐步学习内化认知训练.arXiv :2405.14838 [cs.CL] https://arxiv.org/abs/2405.14838

[6] Nouha Dziri,Ximing Lu,Melanie Sclar,Xiang Lorraine Li,Liwei Jiang,Bill Yuchen Lin,Peter West、Chandra Bhagavatula,Ronan Le Bras,Jena D. Hwang,Soumya Sanyal,Sean Welleck,Xiang Ren、Allyson Ettinger,Zaid Harchaoui和 Yejin Choi.2023 年。《信仰与命运:Transformer 对组合性的限制》。arXiv :2305.18654 [cs.CL] https://arxiv.org/abs/2305.18654 [7] Angela Fan,Mike Lewis 和 Yann Dauphin.2018 年。《分层神经故事生成》。arXiv:1805.04833

[cs.CL] https://arxiv.org/abs/1805.04833 [8] Ari Holtzman,Jan Buys,Li Du,Maxwell Forbes 和 Yejin Choi.2020 年。《神经文本退化的奇特案例》。arXiv :1904.09751 [cs.CL] https://arxiv.org/abs/1904.09751

[9] Edward J. Hu,Yelong Shen,Phillip Wallis,Zeyuan Allen-Zhu,Yuanzhi Li,Shean Wang,Lu Wang 和 Weizhu Chen. 2021. LoRA:大型语言模型的低秩自适应.arXiv :2106.09685 [cs.CL] https://arxiv.org/abs/2106.09685 [10] Zhijing Jin,Yuen Chen,Felix Leeb,Luigi Gresele,Ojasv Kamal,Zhiheng Lyu、Kevin Blin,Fernando Gonzalez Adauto,Max Kleiman-Weiner,Mrinmaya Sachan 和 Bernhard Schölkopf. 2024. CLadder :评估语言模型中的因果推理。arXiv:2312.04350 [cs.CL] https://arxiv.org/abs/2312.04350 [11] Zhijing Jin, Jiarui Liu, Zhiheng Lyu, Spencer Poff, Mrinmaya Sachan, Rada Mihalcea, Mona Diab 和 Bernhard Schölkopf. 2024. 大型语言模型能否从相关性推断因果关系? arXiv:2306.05836 [cs.CL] https://arxiv.org/abs/2306.05836

[12] Adam Tauman Kalai,Ofir Nachum,Santosh S. Vempala 和 Edwin 张。2025. 为什么语言模型会产生幻觉.arXiv :2509.04664 [cs.CL] https://arxiv.org/abs/2509.04664

[13] Dhiraj Kalamkar,Dheevatsa Mudigere,Naveen Mellempudi 等。2019. BFLOAT16 用于深度学习训练的研究。arXiv:1905.12322 [cs.LG] https://arxiv.org/abs/1905.12322

[14] Takeshi Kojima,Shixiang Shane Gu,Machel Reid,Yutaka Matsuo 和 Yusuke Iwasawa. 2023. 大型语言模型是零样本推理器.arXiv :2205.11916 [cs.CL] https://arxiv.org/abs/2205.11916 [15] Emre Kıcıman,Robert Ness,Amit Sharma 和 Chenhao Tan. 2024. 因果推理和大型语言模型 :开启因果关系的新前沿.arXiv :2305.00050 [cs.AI] https://arxiv.org/abs/2305.00050 [16] Jinqi Lai,Wensheng Gan,Jiayang Wu,Zhenlian Qi 和 Philip S. Yu. 2024. 法律领域的大型语言模型 :综述。AI Open 5 (2024) ,181-196. doi:10.1016/j.aiopen.2024.09.002 [17]赖宇轩,张晨,冯岩松,黄曲哲,赵东岩。

2021. 为什么机器阅读理解模型会学习捷径? arXiv:2106.01024 [cs.CL] https://arxiv.org/abs/2106.01024 [18] Kevin Lin,Oyvind Tafjord,Peter Clark 和 Matt Gardner. 2019. 情境中段落效应的推理.arXiv :1908.05852 [cs.CL] https://arxiv.org/abs/1908.05852

[19] Stephanie Lin,Jacob Hilton 和 Owain Evans.2022 年。TruthfulQA:衡量模型如何模仿人类的谎言。arXiv :2109.07958 [cs.CL] https://arxiv.org/abs/2109.07958 [20] Ilya Loshchilov 和 Frank Hutter. 2019. 解耦权重衰减正则化.arXiv :1711.05101 [cs.LG] https://arxiv.org/abs/1711.05101 [21] Joshua Maynez,Shashi Narayan、Bernd Bohnet 和 Ryan McDonald。

2020. 论抽象式摘要中的忠实性和事实性.arXiv :2005.00661 [cs.CL] https://arxiv.org/abs/2005.00661 [22] R. Thomas McCoy,Ellie Pavlick 和 Tal Linzen. 2019. 因错误的原因而正确 :诊断自然语言推理中的句法启发式。arXiv:1902.01007 [cs.CL] https://arxiv.org/abs/1902.01007 [23] Daniel McDuff,Mike Schaeckermann,Tao Tu,Anil Palepu,Amy Wang,Jake Garrison,Karan Singhal,Yash Sharma,Shekoofeh Azizi,Kavita Kulkarni,Le Hou,Yong Cheng,Yun Liu、S Sara Mahdavi,Sushant Prakash,Anupam Pathak、Christopher Semturs,Shwetak Patel,Dale R Webster,Ewa Dominowska,Juraj Gottweis,Joelle Barral,Katherine Chou,Greg S Corrado,Yossi Matias,Jake Sunshine,Alan Karthikesalingam 和 Vivek Natarajan. 2023. 使用大型语言模型实现精确的鉴别诊断。arXiv:2312.00164 [cs.CV] https://arxiv.org/abs/2312.00164 [24] Alec Radford 和 Karthik Narasimhan. 2018. 通过生成式预训练提高语言理解能力。https://api.semanticscholar.org/CorpusID:49313245 [25] Melissa Roemmele,Cosmin Adrian Bejan 和 Andrew S. Gordon。

2011年。 选择合理的替代方案 :对常识因果推理的评估.载于 AAAI 春季研讨会 :常识推理的逻辑形式化,斯坦福大学- http://ict.usc.edu/pubs/Choice%20of%20Plausible%20Alternatives- sity.%20An%20Evaluation%20of%20Commonsense%20Causal%20Reasoning.pdf [26] Junhan Shi,Yijia Zhu,Zhenning Shi,Dan Zhao,Qing Li 和 Yong Jiang. 2025 年。SpecCoT 通过推测性探索加速思维链推理.载于《计算语言学协会研究成果 :EMNLP 2025》,Christos Christodoulopoulos,Tanmoy Chakraborty,Carolyn Rose 和 Violet Peng (编) 。计算语言学协会,苏州,中国。

24405-24415. doi:10.18653/v1/2025.findings-emnlp.1326 [27] Karan Singhal,Shekoofeh Azizi,Tao Tu、S. Sara Mahdavi,Jason Wei,Hyung Won Chung,Nathan Scales,Ajay Tanwani,Heather Cole-Lewis,Stephen Pfohl、Perry Payne,Martin Seneviratne,Paul Gamble,Chris Kelly、Nathaneal Scharli、Aakanksha Chowdhery,Phillip Mansfield,Blaise Aguera y Arcas,Dale Webster、Greg S. Corrado,Yossi Matias,Katherine Chou,Juraj Gottweis,Nenad Tomasev、Yun Liu,Alvin Rajkomar,Joelle Barral,Christopher Semturs,Alan Karthike、salingam 和 Vivek Natarajan. 2022. 大型语言模型编码临床知识。arXiv :2212.13138 [cs.CL] https://arxiv.org/abs/2212.13138 [28] Aarohi Srivastava,Abhinav Rastogi,Abhishek Rao 等.2023 ,超越模仿游戏 :量化和外推语言模型的能力.arXiv :2206.04615 [cs.CL] https://arxiv.org/abs/2206.04615 [29] Ilya Sutskever,Oriol Vinyals 和 Quoc V. Le.2014.基于神经网络的序列到序列学习.arXiv :1409.3215 [cs.CL] https://arxiv.org/abs/1409.3215

[30] Mirac Suzgun,Nathan Scales,Nathanael Schärli,Sebastian Gehrmann,Yi Tay、Hyung Won Chung,Aakanksha Chowdhery,Quoc V. Le,Ed H. Chi,Denny Zhou 和 Jason Wei.2022 年。"挑战性 BIG-Bench 任务以及思维链能否解决它们"。arXiv :2210.09261 [cs.CL] https://arxiv.org/abs/2210.09261

[31]唐瑞祥,孔德涵,黄龙涛,薛辉. 2023. 大型语言模型可能是惰性学习者 :分析上下文学习中的捷径.载于《计算语言学协会年会论文集 :ACL 2023》。计算语言学协会,4645-4657,doi :10.18653/v1/2023.findings-acl.284 [32] Ashish Vaswani,Noam Shazeer,Niki Parmar,Jakob Uszkoreit,Llion Jones,Aidan N. Gomez,Lukasz Kaiser 和 Illia Polosukhin.2023.《注意力机制就是你所需要的一切》。arXiv :1706.03762 [cs.CL] https://arxiv.org/abs/1706.03762 [33]汪泽宇.2024。《CausalBench:评估大型语言模型因果推理能力的综合基准测试》。载于第十届SIGHAN中文语意处理研讨会 (SIGHAN-10)论文集 ,Kam -Fai Wong,Min Zhang,Ruifeng Xu,Jing Li,Zhongyu Wei,Lin Gui,Bin Liang和 Runcong Zhao (编) 。计算语言学协会,泰国曼谷,143-151,https://aclanthology.org/2024.sighan-1.17/[34] Jason Wei,Xuezhi Wang,Dale Schuurmans,Maarten Bosma,Brian Ichter,Fei Xia,Ed Chi、Quoc Le 和 Denny Zhou.2023。"思维链提示引发大型语言模型中的推理"。arXiv :2201.11903 [cs.CL] https://arxiv.org/abs/2201.11903

[35]吴世杰,Ozan Irsoy,Steven Lu,Vadim Dabravolski,Mark Dredze,Sebastian Gehrmann,Prabhanjan Kambadur,David Rosenberg 和 Gideon Mann. 2023 年。BloombergGPT :大型金融语言模型。arXiv:2303.17564 [cs.LG] https://arxiv.org/abs/2303.17564 [36] Hongyang Yang,Xiao-Yang Liu 和 Christina Dan Wang. 2025. FinGPT :开源金融大语言模型。arXiv:2306.06031 [q-fin.ST] https://arxiv.org/abs/2306.06031

[37]张敦,李家成,曾紫阳,王福龙。2025. Jasper 和 Stella:SOTA 嵌入模型的精炼。arXiv:2412.19048 [cs.IR] https://arxiv.org/abs/2412.19048

附录 A.1 减少数据偏见

管具有相反因果答案的成对因果问题经过专门设计,使其语义彼此接近,但整个数据集仍然可能包含语义特征和标签之间的偏斜相关性,而逻辑学习模型 (LLM) 可能会将这些相关性学习为虚假的捷径[17, 31]。此处,“偏斜”指的是分布不平衡,即特定事件在某些类别中出现的频率过高。例如,某些事件在一个类别中的出现频率可能高于其他类别,例如某些产品的销售或某些天气状况在“基本对”类别中比在“相反对”类别中更常见。这种不平衡会产生捷径信号,使模型能够在不基于因果结构的情况下预测标签。

我们从两个角度检测这种偏斜。首先,我们分析每个数据集中的事件数量,计算它们在不同标签和类别中的频率,并标记出低于阈值的分布极不平衡的事件。此外,我们还进行基于相似性的分析,以识别占主导地位样本。

王宇哲、朱耀辰、李俊东

数据集的语义空间。具体来说,我们使用 stella-400M 模型 [37] 对每个问题进行嵌入,并计算余弦相似度;对于每个示例,我们检索其在数据集集中的前 5 个最近邻。

然后,我们统计某个示例在其他示例的前 5 个邻居列表中出现的次数。在这些前 5 个列表中出现频率异常高的示例表明存在近乎重复的聚类或高度通用的模式,这些模式可能会放大与标签相关的捷径。

为了缓解这些偏差,我们迭代地对两种分析方法识别出的前 5 个案例进行过滤和替换。对于基于计数的偏差,我们将过度出现的事件 (在、或 中)替换为替代事件,以使事件频率在各个类别中分布更加均匀。对于基于相似性的分析,我们替换那些

异常频繁地出现在许多其他的前 5 个邻居中,从而减少了相似性引起的偏差,并防止高度重复的模式主导训练捷径。

A.2 超参数对于所有微调策略 (无CoT、显式CoT和隐式因果推理),我们应用低秩自适应 (LoRA) [9],其中 $r=4$, $\alpha=8$,dropout = 0.05,目标函数为 q_proj 和 v_proj 。我们微调批大小为4,最大值

使用分页 AdamW [20] 8 位优化器、bf16 训练[13]和,梯度检查点[3],以 1×10^{-4} 的学习率和 256 的序列长度进行 3 个 epoch 的训练,并采用固定的随机种子进行公平比较。