

基于大型语言模型的因果代理

韩凯荣

 , 匡坤,赵子玉

 , 叶俊建

 , 和飞武

 , IEEE高级会员

摘要 大型语言模型 (LLM)已在多个领域取得了显著成功.然而,因果问题和因果理论固有的复杂性使得用自然语言准确描述它们面临挑战,导致LLM难以理解和有效运用这些问题.因果方法难以通过自然语言表达,这限制了LLM准确应用这些方法的能力.此外,因果数据集通常以表格形式呈现,而LLM擅长处理自然语言数据,这种结构上的不匹配阻碍了其对表格数据进行有效推理.这种因果推理能力的不足限制了LLM的发展。

为了应对这些挑战,我们为LLM配备了基于代理框架的因果工具,称为因果代理,使其能够处理因果问题.因果代理包含工具模块、内存模块和推理模块.在工具模块中,因果代理调用Python代码,并使用封装的因果函数模块将表格数据与自然语言对齐。

在推理模块中,因果智能体通过工具进行多次迭代推理.在内存模块中,因果智能体维护一个字典实例,其中键是唯一的名称,值为因果图.为了验证因果智能体的因果能力,我们构建了一个因果表格问答 (CausalTQA)基准测试,该测试包含四个层次的因果问题:变量层、边层、因果图层和因果效应层.CausalTQA 包含约 1400 个问题,涵盖这四个层次.因果智能体在这四个层次的因果问题上表现出卓越的性能,准确率均高于 80%.通过在真实世界数据集 QRData 上的验证,因果智能体的性能比当前最先进的算法 (SOTA) 提高了 6%,证明了其在真实场景中强大的泛化能力.更多见解和实现细节,请访问此处的匿名 GitHub 代码库。

索引词 因果推断、因果发现、主体
大型语言模型

一、引言

近年来,生成式人工智能技术取得了显著成功,在自然语言处理[16][20][23]、图像合成、音频合成等领域[7][53]取得了令人瞩目的成就.这一进展为推动通用人工智能的研究奠定了基础[16],无论是在框架开发还是实际应用方面.然而,由于因果问题的复杂性,大型语言模型 (LLM)的因果推理能力仍然不足.因果理论难以用LLM能够准确理解的自然语言进行描述.研究人员评估了LLM的纯因果推理能力,发现其纯因果推理接近于随机推理[18].此外,研究人员认为,当前的LLM仅仅是“因果鹦鹉”,只能模仿而无法真正理解因果关系[58].这种固有的局限性严重阻碍了大型模型在需要因果推理的任务中的性能.此外,因果数据集通常是表格数据,而大型模型则擅长处理自然语言数据.尽管

诸如 TableGPT [22]、[43] 等方法已被提出用于处理表格数据,它们主要侧重于简化的表格操作 (例如,复制或交换行).当我们需要基于表格数据分析得出因果结论时,并非专门设计的逻辑推理模型 (LLM)无法直接利用表格数据进行推理。

这种结构异质性阻碍了逻辑推理模型 (LLM)有效地处理表格数据.这两个局限性限制了LLM有效解决因果问题的能力。

为了解决提升LLM因果能力方面的两个难题,我们从LLM的角度提出了一种因果问题建模方法,并通过引导LLM调用因果工具,提出了一个因果智能体框架.我们将因果问题建模为四个层次:变量层、边层、因果图层和因果效应层.变量层侧重于智能体对相关性的判断和理解;边层侧重于智能体对变量间因果关系的考察;因果图层侧重于智能体生成因果图的能力;因果效应层侧重于智能体对变量间因果效应的估计,以进行定量表达。

基于上述因果问题,我们构建了一个基于LLM的因果智能体.该因果智能体使用因果图作为中介,在该领域进行因果推理。

通过利用因果发现算法生成因果图并对这些图进行推理,该方法将下游因果任务的复杂性与表格数据问答的挑战联系起来.具体而言,如图 1 所示,因果代理由工具、内存和计划模块组成.在工具模块中,因果代理调用 Python 编程工具中的因果分析库,例如 causal-learn [62] 和 EconML [8].因此,因果代理可以接收表格数据和数据因果问题描述作为输入.通过调用因果分析工具,该工具处理表格数据并生成因果代理可以理解的自然语言结论。

在规划模块中,因果智能体利用其文本理解和推理能力,通过多次迭代来获得因果问题的答案.在记忆模块中,因果智能体可能需要多种工具来解决问题.为了在规划过程中保存中间结果,智能体维护一个实例化的字典,其中键是名称,值是因果图.这种特殊方法允许智能体使用键检索所需的因果图。

一方面,记忆内容以更具信息量的方式表达.另一方面,使用数据结构而非文本作为记忆载体,可以有效简化推理过程中提示设计的复杂性。

为了验证因果代理的因果能力,我们建立了一个因果表格问答 (CausalTQA)基准测试,该测试包含四个级别的因果问题:vari —




图 1. 因果代理的工作流程图。第一步,用户输入一对表格数据和因果问题;第二步,因果代理调用因果工具(工具模块),并使用 ReAct 框架(计划模块)对表格数据进行多轮分析,其中因果代理维护一个包含因果图名称及其实例的字典作为内存(内存模块);第三步,因果代理将分析过程与用户的问题相结合,生成相应的答案。

CausalTQA 包含四个层次的问题:变量层、边层、因果图层和因果效应层。这四个层次的问题数量约为 1.4K。在受控的合成数据环境下,该因果代理在四个层次的问题上均表现出很高的准确率,能够正确调用工具并生成预期答案。在变量层确定相关性的三个子问题中,准确率均超过 95%;在边层确定相关性的三个子问题中,准确率均超过 89%;在因果图层确定相关性的三个子问题中,准确率均超过 81%;在因果效应估计层,准确率高 达 98%。

通过在真实世界数据集 QRData 上的验证,因果代理的性能比原始 SOTA 高出 6%,证明了其在真实世界场景中具有强大的泛化能力。

此外,我们的设计兼具灵活性和可靠性:它允许因果代理集成并调用不同的内置算法,从而连接因果推理和逻辑逻辑模型(LLM)领域。这种方法确保了模型推理过程的可控性,同时能够无缝适应这两个领域的发展。详细的中间推理过程使模型的决策过程透明且可靠。我们的贡献总结如下:

本文提出了一种基于层级建模的逻辑学习模型(LLM)视角来解决因果问题。这是一个全新的设定,问题被设定为数据驱动型,即当用户输入表格数据和因果问题时,LLM 需要回答关于表格数据的因果问题。我们重点关注因果代理需要解决的 四层问题,分别表示为变量层、边层、因果图层和因果效应层。我们提出了 CausalTQA 基准测试,其规模约为 1.4K。

问题分为四个层次,共包含四个层次的九个子问题;

因果代理的提出旨在赋予语言学习模型(LLM)解决因果问题的能力。在该框架中,我们使用 LLM 调用因果工具,并多次迭代以分析和解决因果问题。因此,实现了大型模型自然语言输入与因果问题表格数据输入之间的异构数据对齐。此外,因果图被用作不同工具交互的核心,以增强因果推理的推理能力。通过因果工具增强因果推理能力的因果代理框架具有良好的可解释性和可靠性。

在 CausalTQA 基准测试中,因果代理在四个级别的因果问题中均取得了较高的准确率。

具体来说,变量级别的三个子问题准确率均超过 95%,边级别的三个子问题准确率均超过 89%,因果图级别的三个子问题准确率均超过 81%,因果效应级别的两个子问题准确率均超过 98%。

通过在真实数据集 QRData [24] 上的验证,因果代理的性能比原始 SOTA 高 6%,证明了其在真实场景中具有很强的泛化能力;

它展示了因果代理在表格数据上进行自动因果推理的潜力,促进了因果工具的使用,并对因果理论的广泛普及产生了积极影响;

二、材料与方法

A. 从法学硕士的角度对因果问题进行建模

尽管 LLM 像 GPT 一样发展迅速,展现出强大的自然语言理解和问答能力,但数据驱动因果关系侧重于表格数据,而 LLM 侧重于自然语言处理领域,两者在问题范式上仍然存在显著差距。

此外,LLM 难以真正理解和处理复杂数据中国有的错综复杂的因果关系。

因此,从逻辑逻辑模型 (LLM)的角度重建因果问题框架具有重要意义。这对于评估逻辑逻辑模型的因果能力和提升其因果能力具有重要影响。为了在逻辑逻辑模型领域内构建因果问题模型,我们定义如下:设 $T \in R^{n \times c}$ 为一个具有 n 行 c 列的表格数据,其中每一行 t_i 代表一个数据,每一列 c_i 代表一个变量。

$$T = \{t_i\}_{i=0}^n$$

我们将因果问题空间形式化为一个问题集 Q ,其中 $q_i \in Q$ 是一个以自然语言形式表示的问题。我们通过笛卡尔积将表格数据和问题描述结合起来,创建数据集 D ,其中每个元素 $d_i \in R^{n \times c} \times Q$ 。

$$D = \{d_i\} = \{(T_i, q_i) \in R^{n \times c} \times Q\}$$

用户输入来自数据集 D 的一对样本 (T_i, q_i) ,然后因果代理分析表格数据 T_i 和因果问题 Q ,生成合理的答案 A 。答案 A 的格式不限于自然语言,也可以是因果图或其他非文本数据,以便清晰地解释问题。

由于因果问题的复杂性和多样性,我们对问题进行简化并进行必要的建模。根据问题粒度和对象的差异,我们将因果问题分为四个主要层次:变量层次、边层次、因果图层次和因果效应层次。

变量层级对应于因果阶梯的第一层级 相关性,旨在赋予LLM推断和理解表格数据中变量间相关性的能力。边层级在相关性的基础上更进一步,旨在赋予LLM理解和分析变量间因果边关系的能力。因果图层级则将视角转移到更宏观的维度,考察LLM生成因果图的能力。

因果效应层级旨在赋予LLM量化变量间因果效应的能力。下文将详细讨论四种建模方法。

1)变量层面 :在变量层面,我们关注的是确定不同变量之间的相关性,这是因果关系的第一层。为了从表格数据中获得相关性,我们将相关性检验问题转化为独立性检验问题。也就是说,给定变量 V_i 和 V_j ,确定它们在变量 $\{V_k\}$ 的条件下是否独立或条件独立。

$$\bigwedge_{k=1}^N \quad \text{如果两个变量相关,则它们在}$$

统计上是相关的,反之亦然。
通过此类建模方法,我们旨在检验具有分析相关性能力的因果主体。具体而言,

我们将相关性问题的分为两类:直接独立性检验和条件独立性检验。二者的区别在于判断独立性时是否给定条件变量。具体而言,直接独立性检验可以理解为条件变量的数量为零。为了更精细地衡量模型的性能,我们将条件独立性检验进一步细分为单条件独立性检验和多条件独立性检验,区别在于条件的数量是否为一。

2)因果图层面 :在因果图层面,关注点更为宏观,考察因果智能体是否具备生成因果图的能力。因果图是一种有向无环图 (DAG),在DAG中,边的方向代表因果关系。本文选择PC算法[41]作为生成因果图的方法,该算法生成因果图的马尔可夫等价类,而无需考虑未观测变量的存在及其影响。在因果图层面构建智能体能力模型包含两类:一是生成包含表格数据中所有变量的因果图,二是生成仅包含表格数据中部分变量的局部因果图。生成因果图并基于这些图进行推理的能力,能够有效地引导智能体理解因果关系,并在虚假相关性的迷雾中辨别真正的因果联系。

3)边级建模 :在边级建模中,我们仍然考虑变量之间的关系。与统计相关性不同,我们从因果角度出发,关注变量之间更深层次的因果关系。与因果效应的定量估计不同,边级建模提供的是定性分析结果,需要反映从表格数据重建的因果图中边的真实关系。我们考虑以下三种关系:直接因果关系、碰撞关系和混淆关系。如第二节A2部分所述,我们使用PC算法为因果图生成马尔可夫等价类,因此我们将这三种关系形式化如下:

设 G 为由 PC 算法从表格数据生成的马尔可夫等价类,包含边集 $\{< V_i, V_j >\}$ 。边有两种类型:有向边, $V_j > \in \{ \rightarrow, - \}$,以及无向边,因此 $< V_i >$ 。我们将直接因果关系表示为 V_i 直接导致 V_j ,这在因果图 G 中表现为边 $V_i \rightarrow V_j$ 。我们将碰撞关系表示为 V_i 和 V_k ,这在因果图中表现为边 $V_i \rightarrow V_k$ 和 V_j 直接导致共同变量 $V_j \rightarrow V_k$ 。我们将混淆关系表示为 V_i 和 V_j 之间存在畅通无阻的后门路径,这在因果图中表现为 $V_i \leftarrow \dots \rightarrow V_j$ 。4) 因果效应水平 :因果效应水平试图量化个体或系统在经历某种干预后其结果会发生怎样的变化。我们预期因果主体不仅会利用因果解释进行定性分析,还会运用经典的因果推断方法。

定量解释。为简化问题,在因果效应层面,我们仅考虑从表格数据中定量计算平均效应量 (ATE),记为 $E(Y(T = t_1) - Y(T = t_0))$ 。在因果效应粒度上进行建模可以赋予因果主体更精细的因果感知能力。

B. 基于LLM的因果代理框架

因果代理框架由三个模块组成:工具模块、内存模块和计划模块。在工具模块方面,为了将表格数据与自然语言相匹配,我们调用了能够接受表格数据作为输入的因果分析工具。对于工具的输出,我们使用提示信息来解释和说明结果,从而使因果代理能够理解输出结果。

在规划方面,受 ReAct 框架 [55] 的启发,我们通过多轮反思,不断调用因果分析工具并反思其输出,思考能否基于智能体对因果问题的理解推导出原始问题的答案。如果无法推导出答案,我们将继续迭代反思,直至获得最终答案或达到预设的迭代次数。此外,为了更好地理解工具的使用,我们利用上下文学习和单次示例来增强因果智能体的能力。我们设计了一个手写示例,指导因果智能体调用和理解所有工具。在记忆方面,我们将因果分析工具的输出存储在内存中的一个字典中作为短期记忆,确保智能体在获得最终答案之前能够持续访问因果图。

1)工具:如图 2 所示,因果代理调用因果分析工具来分析表格数据,从而弥补 LLM 在处理表格数据方面的不足。这种方法将表格数据与因果结论相匹配,并通过工具调用增强了 LLM 的因果分析能力。具体而言,我们的因果分析工具选择 causal-learn 库 [63] 进行因果发现,并选择 EconML 库 [8] 进行因果推断。从 LLM 建模因果问题的角度出发,我们设计了变量层、边层、因果图层和因果效应层的特定工具函数。为了便于 LLM 调用这些工具函数,我们重新封装了接口,将工具输入更改为 JSON 字符串格式,并使用手动规则和手写提示模板来帮助大型模型更好地理解工具输出的含义。

提示详情可在代码库中找到。以下是一个示例:

独立条件检验

当您测试变量 A 和变量 B 在变量 C 条件下的独立性或分离性时,此功能非常有用。输入应为 JSON 格式,如下所示:

```
{ filename : ..., interesting var : [...], condition : [...] }
```

感兴趣的变量是指用户感兴趣的变量列表。例如,如果用户想要检验 X 和 Y 条件之间的独立性 (d-separate),则可以使用“感兴趣的变量”列表。

对于 Z、W、Q,感兴趣的变量是 [- X , Y],条件是 [Z , W , Q]。如果没有提供条件,则条件为 []。

在变量层面,我们调用 causal-learn 中的条件独立性检验类,并使用 Fisherz [10] 作为独立性检验方法。在因果图层面,由于我们的数据假设中不存在未观测变量,我们调用 PC 算法生成因果图的马尔可夫等价类。需要注意的是,在生成部分因果图时,我们仍然使用 PC 算法。

然而,在这种情况下,论证中未包含的变量是部分因果图中的未观测变量。

我们认为,这种情况应该由用户控制,而不是由智能体主动改变因果发现算法,例如能够处理未观测到的混杂因素的FCI[42]算法。这种设计既能保持智能体行为的可靠性,又能方便用户与智能体进行交互。

在边级别,我们使用工具的提示模板引导LLM使用因果图生成算法,获得因果图的马尔可夫等价类,然后判断边之间的关系。对于PC算法无法确定的无向边,工具会明确讨论边的方向并得出结论。

我们重点关注边缘层面的三个子问题:直接因果关系、混淆因素和碰撞因素。为了判断因果关系,我们考虑在PC算法的输出G中是否存在一条直接连接两个变量的有向边。

为了判断混淆,我们考虑两个节点之间是否存在未被阻塞的后门路径。为了判断碰撞,我们只考虑碰撞“V”结构,例如 $\neg V_i \rightarrow V_k \leftarrow V_j$ 。

在因果效应层面,因果代理调用 EconML 库中的 LinearDML 算法,用户需要指定哪些变量是协变量。因果代理首先使用 LinearDML 算法训练数据。

在训练阶段,我们选择 EconML 库中 LinearDML 算法的默认参数,协变量由用户提示输入指定。训练阶段结束后,该工具会输出同一模型的平均因果效应估计值,使用的协变量与训练阶段使用的协变量一致。

2)计划流程:受 ReAct 框架的启发,因果智能体采用迭代式多轮对话方法,利用提示模板促进因果智能体与工具之间的交互和理解。在调用因果分析工具的过程中,智能体必须不断思考和试验,以确定下一步行动。

对于因果主体而言,这一过程至关重要,因为解决复杂的因果问题可能需要使用多种因果工具,并观察和整合这些工具的不同输出结果。因此,因果主体需要反复调用这些工具,观察其输出结果,并进行深入思考才能找到解决方案。

具体而言,在对话的每一轮中,用户都会提供问题描述 q 和待分析的表格数据 T。




图 2. 因果代理工具使用图:使用不同的工具来解决四个层次的因果问题。

作为输入 (q,T) 。在提示的指导下,从每一轮 i 的第一轮开始,因果代理将生成一个想法Ot并使用一个工具作为行动ai。

该工具将接收人工智能输入并生成观测值Oobs。基于此观测值,因果智能体尝试回答原始问题描述。如果仍然无法回答,它会将本轮的观测值作为输入继续下一轮。下一轮的输入为(q, T, Ot),直到因果智能体得出最终答案或达到最大迭代次数。具体示例如下:

1, 2, n

体重与……之间关系的基础因素
癌症。

行动:确定混杂因素

操作输入: { "cg 名称": "数据", "感兴趣的变量": ["体重", "癌症"] }

观察: (多次迭代器)

最终答案:不存在直接的因果关系
癌症带来的体重增加。

计划流程

输入提示:考虑以下四个因素:年龄、体重、睡眠时间,以及……是否存在直接的因果关系癌症

癌症相关数据。CSV 数据存储在 data.csv 文件中。

输入数据: data.csv

想法:我们应该首先生成一个因果图来分析这些变量之间的关系。

操作:生成因果操作输入:

```
{ filename : data.csv , analyze relationship : True }
```

观察结果:名为 "data" 的因果图已成功生成!

思考:既然我们已经生成了因果图,我们可以用它来确定年龄是否是一个因素。

3)记忆:在因果智能体的推理和交互过程中,它需要维护当前生成的因果图,并在后续的因果关系判断中使用该图。因此,在因果智能体的记忆实现中,记忆并非文本形式的数据,而是与因果图Python类实例对应的数据。因果智能体维护一个字典作为记忆,在写入记忆时添加条目并建立名称索引,并在多轮对话中使用该索引读取相应的因果图信息,如图3所示。因果智能体的记忆模块与传统的基于LLM的智能体记忆的不同之处在于,其存储的数据结构并非自然语言,而是更具信息量的记忆抽象表达。通过维护因果图并对其推理,记忆模块充当连接不同因果工具的中介。

这使得工具能够形成调用链,从而促进复杂的推理过程。




图 3. 因果代理记忆模块示意图:在推理过程中,因果代理在其记忆中维护一个记忆索引。索引名称采用自然语言形式,而索引内容则包含因果图实例等数据结构,其中包含更丰富的信息。

三、结果

为了测试因果代理,我们对 CausalTQA 进行了合成数据实验,并对真实数据 QRData 进行了验证。数据生成过程如第三部分A节所示。CausalTQA实验结果如第三部分B节所示,QRData 上的真实数据验证结果如第三部分D节所示。我们使用gpt-3.5-turbo作为因果代理的默认决策核心,并在第三部分B5节中计算因果代理的成本。

第三节 C 部分展示了使用不同模型作为因果代理决策核心,并与现有的多代理方法进行了比较。

A. 数据生成过程

1)表格数据:为了生成测试数据集所需的表格数据,我们采用了[31]工作中使用的方法。具体来说,我们的数据遵循非线性加性高斯噪声模型, $X \in \mathbb{R}^d$ 使用以下模型生成:

$$X_i = f_i(\text{pai}(X)) + \epsilon_i$$

$i = 1, \dots, d$,它们是 , 其中 $\text{pai}(X)$ 选择 X 的坐标 某个有向无环图中节点 i 的父节点。

$$\epsilon_i \sim N(0, \sigma^2)$$

假设函数 f_i 在每个分量上都是二阶连续可微且非线性的。

也就是说,如果我们用 $X_{k1}, X_{k2}, \dots, X_{kl}$ 表示 X_j 的父节点 $\text{pai}_j(X)$,那么对于所有 $a = 1, \dots, X_{k1}, \dots, X_{k2}, \dots, X_{kl} \dots$, 函数

对于节点数相同的表格,我们生成一系列边数不同的表格数据,边数范围为 $[0, C2 \text{ 节点数}]$ 。这模拟了真实因果图的不同稀疏性和密度情况。我们将所有生成的表格数据作为一个数据池。之后生成特定测试样本时,我们会从数据池中随机抽取一个与问题所需变量节点数相同的表格,以此来量化变量之间的关系。

2) 因果问题描述 :为了模拟真实场景中的因果问题,我们为第二节 A 部分中建模的四级因果问题生成了一个自然语言模板 T_q 。

然后,我们选取医疗领域和市场领域这两个常见的因果推断领域作为问题来源,生成问题的真实场景。首先,我们生成100个与医疗和市场相关的关键词,组成关键词列表 L_q 。然后,我们迭代地遍历节点数从3到10的情况。对于节点数为 i 的情况,我们从关键词列表中随机抽取 i 个关键词作为种子。

$$K_1, \dots, K_i, \dots, K_q$$

随后,我们使用了问题模板 t T_q 允许 GPT-3.5 使用种子关键词构建一个可能的真实场景,从而形成一段数据。

$$\text{描述} = \text{GP T}(K_1, \dots, K_i, \dots, K_q, t_i)$$

请注意,列表中的关键词是随机抽取的,因此它们之间可能不存在因果关系。

这种特殊设计使得因果代理在因果分析过程中专注于表格数据,从而产生数据驱动而非语义驱动因果信息。

用于因果分析的变量。

表一
数据集统计信息。

属性	#数字
问题模板	81
变量池大小	311

3) CausalTQA 的统计信息 :如表 I 所示,CausalTQA 由 81 个问题模板生成,数据取自包含 311 个变量的变量池,以确保问题的多样性。关于问题长度的分布,我们合成数据集中的大多数问题长度在 100 到 150 字之间,而超过 200 字的问题较少,从而有助于评估集的多样性,如图 5 所示。




B. CausalTQA上的因果问题测试结果 该因果智能体由GPT-3.5

构建。具体来说,我们使用gpt-3.5-turbo模型的默认设置,并在因果智能体推理时将温度参数设置为0.5。为了约束LLM的输出,并便于在测试过程中与实际真实值进行比较,我们引导模型根据变量层级和边层级的问题输出“是”、“否”和“不确定”。

对于因果图级别的问题,智能体会在推理过程中生成因果图,我们会直接评估因果图是否正确生成。

对于因果效应水平问题,我们考虑了代理人对平均因果效应的计算是否准确。

为了与未专门设计的因果工具的原始LLM进行比较,并验证因果代理框架的有效性,我们还设计了一个基线 (称为code-LLM)对比实验。在code-LLM中,我们让code-LLM为因果问题编写代码并运行。



该代码-LLM可以遵循它。

1)变量水平的结果:在变量水平上,我们的结果如表二所示。我们使用IT来表示独立性检验,CIT表示以一个变量作为条件变量的条件独立性检验,以及MCIT表示一个超越一的条件独立性检验将变量作为条件变量。因果主体达成三个子问题的准确率均超过95%。变量水平。值得注意的是,在条件独立性检验中,该特工正确使用了工具,并达到了正确的目标。几乎所有问题都得出了结论,其中一项得分达到了99.4%。条件独立性检验和多条件检验中的99.4%独立性检验表明,我们的因果代理表现非常出色。在这个级别表现不错。

我们对失效样本进行了相关分析。

因果主体的错误。因果主体的错误可能是由工具的 (1)参数传递错误引起例如,该问题需要进行独立性检验。对于“肾脏病学”和“普通外科”,并非有条件限制。独立性检验。然而,因果主体错误地将其理解为条件独立性检验,导致

在因果代理中,将条件参数设置为其他调用问题时出现的变量

变量级工具。此外,由于误解

工具方面,因果主体可能 (2)误用或过度使用太多使用工具进行推理会导致逻辑链过长。

误导因果主体的推理,并导致最终结果。

结果有误。

表二

因果主体在变量级问题 (IT,CIT,MCIT)、因果图级 (总体、部分)上的测试结果,以及因果效应水平。												
#节点	它		中联运		MCIT		全部的		部分的		因果效应水平	
	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM	CA (我方)代码-LLM
3	95.0	50.0	100.0	18.2	100.0	22.7	90.9	50.0	-	-	100.0	30.0
4	95.0	35.0	100.0	31.8	100.0	9.1	63.6	54.5	95.5	40.9	100.0	35.0
5	95.0	30.0	100.0	40.9	100.0	31.8	100.0	59.1	77.3	22.7	100.0	35.0
6	95.0	15.0	100.0	36.4	100.0	40.9	90.9	54.5	95.5	36.4	100.0	40.0
7	100.0	35.0	95.4	22.7	95.5	22.7	77.3	72.7	95.5	27.3	85.0	50.0
8	95.7	43.5	100.0	21.1	100.0	36.4	86.4	45.5	86.4	36.4	100.0	35.0
9	95.0	30.0	100.0	40.9	100.0	50.0	63.6	68.2	95.5	36.4	100.0	25.0
10	90.0	55.0	100.0	22.7	100.0	59.1	81.8	68.2	95.5	27.3	100.0	35.0
平均值	95.1	36.8	99.4	29.4	99.4	34.1	81.8	59.1	91.6	32.5	98.1	35.0

与code-LLM相比,精度提升

我们的模型在变量层面上是显著的。代码-LLM 它不具备因果工具,但可以直接让LLM编写用于处理表格数据的 Python 代码。这是合理的。代码 LLM 的性能甚至比随机方法还要差,因为在我们的实验表明,代码 LLM 难以将表格数据与……对齐自然语言,而且经常犯基本的输入错误,即使当我们使用情境学习来指导代码学习领导力硕士 (LLM)时通过示例处理表格输入。

具体而言,代码 LLM 错误主要由以下两方面引起:

错误。(1)上下文一致性错误。当代码 LLM 为编写代码时,可能会错误地使用参数名称。传递函数参数时。例如,名称

传递参数时,“AB”错误地被识别为“AB”。

此外,还使用了未定义和引用的库函数,例如,在未定义范数函数的情况下使用它。即使如果我们指示 LLM 直接使用已加载的数据框文件不会像磁盘那样进行读写操作。即使文件未被导入或加载,LLM 仍会重新加载该文件。错误地导致 I/O 问题。(2)代码逻辑错误和语法错误。即使代码的一致性

即使保持上下文,代码本身也可能产生逻辑错误。以及语法错误。例如,括号不匹配。

生成的代码可能会导致语法错误等问题。此外,目前,数学能力是法学硕士 (LLM)难以掌握的课题。LLM在理解过程中会产生数学错误

统计学相关公式及其含义。

表三

边缘级问题上因果代理的测试结果。				
#节点	原因	列	确认	
3	95.0	100.0	95.5	
4	95.0	95.0	100.0	
5	90.0	95.0	100.0	
6	80.0	95.7	100.0	
7	88.9	100.0	95.5	
8	83.3	94.4	86.4	
9	88.9	100.0	95.5	
10	94.4	100.0	86.4	
平均的	89.5	97.4	94.6	

2)边缘层的结果:在边缘层,我们测试了代理人判断直接因果关系的准确性 (由 CAUSE 表示),混杂因素 (由 CONF),以及对撞机 (用 COL 表示),结果

如表三所示。具体而言,该代理达到了 89.5% 平均而言,判断直接因果关系的准确性 平均而言,判断碰撞体的准确率为 97.4%,而 94.6% 判断混杂因素的准确性。

与变量水平相同,因果代理的失效情况 边缘级误差主要来源于参数传递错误。工具调用。

需要指出的是,与我们的模型相比,代码LLM 在这个层面上,这种方法几乎无效。因为缺乏因果分析工具的代码学习方法 (code-LLM)知识不足。他对因果场不太了解,难以理解如何在这个层面上,通过代码分析和解决因果问题。这个过程需要在长链推理中进行。因果领域对于代码LLM来说很困难,而因果主体也是如此。通过模块化封装实现更佳性能 因果工具。

3)因果图层面的结果:在因果图层面 在图层面,我们测试了智能体生成因果关系的能力。包含所有变量 (用 TOTAL 表示)的图表 一个包含部分因果图 (用 PARTIAL 表示) 一些变量。具体结果如表二所示: 生成因果图的准确率为 81.8%。所有节点均达到 91.6% 的生成准确率 由一些节点组成的部分因果图。

为了将代码 LLM 输出的因果图约束为 与之类似,我们将代码 LLM 限制为使用 PC 算法 通过提示使用 ICL 获取 causallearn 包的库 提供一个简单的代码示例来启发代码学习 LLM。实验表明,我们的因果代理在生成因果图方面明显优于代码 LLM。在此任务中,代码 LLM 这表明在生成方面仍然存在很大的局限性。因果图。

分析因果代理和代码LLM的错误, 主要原因是对问题理解不足, 导致参数传递和工具使用出现错误。当 生成完整的因果图,生成方法 有时会错误地选择部分因果图。 导致参数传递顺序错乱,从而产生差异。 从真实的因果图中。关于代码 LLM 的错误情况,一方面是因为,即使我们提供

IO示例代码正确,但仍然无法按照说明操作。 并输出正确的结果。另一方面,这是由于…… 参数错误。与上一节类似,参数 名称错误或参数顺序混乱。

4)因果效应水平的结果:在以下水平上
在因果效应方面,因果主体回答了160个问题中的157个。
答对了所有问题,准确率达到 98.1%,如图所示。
如表二所示。这些例子涵盖了市场营销的两个领域。
以及药物,覆盖 3-10 个节点。

该层级的致因因素出现了三个失效案例,原因如下:
调用因果函数时意外传递参数错误
工具。与代码 LLM 中的严重幻觉相比,
因果代理有效地提高了模型使用的可靠性
通过工具的模块化。虽然代码 LLM,即使我们
请提供输入和输出的示例以及因果关系。
ICL 的 EconML 效应函数用例仍然难以实现。
为了让代码 LLM 能够很好地遵循指令并输出结果
代码正确,但结果却下降了。

5)因果代理成本计算:我们进行间接费用计算。
对变量层级、边缘层级和问题的分析
因果图层面。在 CausalTQA 的实验中,我们设置
最大迭代次数设为 15。我们随机抽取了 100 个样本。
用于测试的数据点。此外,我们对问题进行了分类。
将模型分成不同类型,以检验 LLM 的计算成本和迭代次数是否因类别而异。

结果如表四所示。

表四	
不同任务级别的总体统计数据 and 迭代次数	
指标	价值
总体平均值	
平均运行时间	3.37 秒
平均迭代次数	2.51
平均令牌数	5308
按任务级别迭代	
变量级别	2.35
边缘级别	3.00
CG等级	2.11

随着任务变得越来越复杂,平均数量
迭代次数也随之增加。因此,复杂任务需要更多迭代次数。
通过反复分析得出答案。

平均迭代次数为 2.5。在实际应用中,
无需动态设计约束条件
最大迭代次数,因为此迭代级别为
可以接受,而且不会带来太多额外成本。
影响证明了我们框架的稳定性。

表五						
对答案和问题进行分层后的测试结果 图中显示了各个领域。蓝色代表医学领域,并且 红色代表市场领域。						
回答	它	CIT	MCIT	CAUSE	CONF	COL
是的	94.2	100.0	97.7	100.0	72.7	90.9
	97.6	96.4	100.0	100.0	92.9	60.0
不	92.3	100.0		100.0	87.3	100.0
			97.7		91.2	98.5
不确定	-	-	-	100.0	72.7	100.0
	-	-	-	100.0	75.0	100.0
平均的	95.0	100.0	95.2	100.0	86.1	94.5
	98.8		98.8		92.5	93.8

6)问题领域类型和答案类型的影响
关于结果:此外,我们还研究了相关性和
问题的真实情况与
答案准确率,并探讨不同类型域的影响
涉及因果关系的问题会影响正确性。我们进行了
基于所涉领域的分层探索
我们的测试集中存在一些问题,这些问题属于医学领域。
市场领域。通过分层,我们可以看到其影响。
问题领域和结果的答案,如
如表五所示。不同的问题领域会导致不同的结果。
问题的复杂性和不同描述,
影响因果分析工具的使用以及问题的答案。
但这两个领域的正确率差异很小。
此外,代理的准确性也存在差异。
对这些问题的不同回答。这表明代理人
在……过程中,可能会表现出对某些类型答案的输出偏好。
问答过程。如何纠正这种偏见将
留作未来工作的方向。

C. 关于多智能体系统和不同LLM的讨论

因果代理专注于特定因果领域中的工具交互流程,并利用因果图作为记忆。

以及在不同层面上将因果问题答案联系起来的中介机构
利用各种因果工具进行层级分析。这是目前所具备的能力。
工具框架的不足之处。在我们的因果代理中,我们不仅调用
现有的因果工具库,例如 causal-learn 和 EconML,
但我们的贡献也体现在专门的互动中。
设计和一些手动调整。

为了更全面地探讨不同因素的影响
关于表格因果推理能力的框架
为了处理数据,我们选择使用 RestGPT [40] 框架。
对 API 进行封装和测试,这是主流的基本做法。
在新框架下进行工具调用研究的模型。
基于我们工作中使用的工具,我们构建了一个代理。
并从 CausalTQA 中随机选择 100 个数据点
测试结果如表六所示。请注意

表六							
从随机选择的100 个数据点上得到的 RESTGPT结果 CAUSALTQA。							
模型	IT	CIT	MCIT	原因	COL	CONF	全部 部分
RestGPT	0.00	0.21			0.00	0.20	0.50 0.27 1.00 0.53

所使用的工具并非完全来自现有工具,而是
包括我们手动调整并与因果关系一致的那些
本文中的图。换句话说,因果图仍然有用。
作为工具短期记忆的中介和
工具间的信息交换。如果我们只使用函数
基于现有的 causal-learn 库和 EconML 库,
代理人将无法继续进行深入分析。
因果图的边级别,这是因为
当前库函数缺少可以直接使用的接口。
实现这些功能。
我们的分析表明,该框架的复杂性,
再加上缺乏因果逻辑和知识,实际上
这使得法学硕士更难解决因果问题。
在多个主体之间的交互中,该模型存在不足。

稳定性差,容易出现逻辑混乱。我们无法
将现有的因果库无缝集成到强大的系统中
工具调用框架,而这方面的差距值得进一步探讨。
调查。

探讨不同模型对因果主体的影响
当它们是决策的核心时,我们使用
使用 ChatGLM-4-air 和 ChatGLM-4-Plus 模型对市场问题进行实验分析。详细结
果如下:
如表七和表八所示。

随着我们所用模型的基础能力不断提升,其在不同层面对因果问题的回答准
确性也随之提高。
已显著改善。这证明了其有效性。
该框架可以随着……而不断改进
法学硕士的基础能力得到扩展。这验证了……
利用LLM实现自动化因果分析的理由
推理。

表七
CHATGLM-4-AIR在 CAUSALTQA 上的结果。

#节点 IT CIT MCIT 原因 COL CONF 全部 部分								
3	1.00	1.00	0.90	1.00	0.89	0.89	0.46	1.00
4	0.91	1.00	1.00	1.00	0.78	0.67	0.46	0.82
5	0.90	1.00	1.00	1.00	0.67	0.89	0.09	0.91
6	1.00	1.00	0.91	1.00	0.56	0.78	0.28	1.00
7	1.00	1.00	0.70	1.00	0.78	0.89	0.36	0.91
8	1.00			1.00	0.56	0.89	0.27	1.00
9				1.00	0.78	0.89	0.27	0.82
10				1.00	0.33	1.00	0.45	0.91
平均值 0.94 0.98								

表八
CHATGLM-4-PLUS在 CAUSALTQA 上的结果。

#节点 IT CIT MCIT 原因 COL CONF 全部 部分								
3	0.93	1.00	0.70	1.00	1.00	1.00	1.00	1.00
4	1.00	0.90	1.00	1.00	1.00	1.00	0.73	1.00
5	0.90	1.00	0.90	1.00	1.00	1.00	1.00	1.00
6	1.00	0.80	1.00	1.00	1.00	1.00	1.00	1.00
7	0.80	1.00	0.90	1.00	1.00	1.00	1.00	1.00
8	1.00			1.00	1.00	1.00	0.91	1.00
9				1.00	1.00	1.00	0.91	1.00
10				1.00	1.00	1.00	1.00	1.00
平均值 0.85 1.00								

D. 基于真实世界表格数据的测试

我们扩大了实验范围,将公开评估纳入其中。
可用于因果推断的QRData子集数据集
基于表格数据,涵盖一系列不同的问题,
与多种主流基准模型相比。
如表 IX 所示。我们的模型展现出良好的鲁棒性。
在真实世界的场景数据中,值得注意的是,尽管
我们使用的基础模型不如 GPT-4 强大,但它仍然
优于当前最先进的结果。如果我们使用 GLM-4-plus
我们的模型与 GPT-4 相当,性能高出 6%。
比SOTA还要好。

四、相关工作

因果关系。作为一种数据分析工具,因果关系旨在……
准确识别和量化特定因素的实际影响
复杂系统中影响结果变量（效应）的因素（原因）
系统环境。它无处不在,渗透到我們日常生活的方方面面。

表九
致病因素与其他基准的性能比较
关于QRDATA 数据。该符号表示来自[24] 的结果。 “+”

模型	尺寸	结果
随机的+	-	27.2
表格问答+		
TableLlama [60]	7B	12.6
思维链提示+		
Llama-2-chat [46]	7B	23.0
AgentLM [57]	7B	27.1
WizardMath [25]	7B	28.6
CodeLlama-instruct [32]	7B	21.9
Deepseek-coder-instruct [13]	6.7B Gemini-	20.4
Pro [45]	-	35.3
GPT-4 [1]	-	42.8
思维引导程序+		
Llama-2-chat	7B	1.5
AgentLM	7B	0.4
WizardMath	7B	8.9
CodeLlama-instruct	7B	16.0
Deepseek-coder-instruct	6.7B	32.3
双子星专业版	-	20.1
GPT-4	-	36.8
ReAct 式提示+		
Llama-2-chat	7B	15.2
AgentLM	7B	13.4
WizardMath	7B	18.2
CodeLlama-instruct	7B	15.6
Deepseek-coder-instruct	6.7B	21.2
双子星专业版	-	37.5
GPT-4	-	51.3
代码解释助手+		
GPT-3.5 Turbo	-	31.2
GPT-4	-	46.8
因果主体（我们的）		
因果代理（GPT-3.5）	-	52.4 (+1.1%)
因果代理（GLM-4-Plus）	-	57.3 (+6.0%)
人类+	-	68.8

例如统计学[2]、[6]、[14]、经济学、计算机科学，
流行病学[12]、[48]和心理学[5]。珍珠的“阶梯”
因果关系理论将因果关系分为三个渐进阶段。
层级[28]:关联、干预和反事实。
研究因果关系的核心目的是揭示真正的因果关系。
厘清事物之间的因果关系,摒弃那些令人困惑的伪因果关系。因果场问题可以简述
如下:
分为两大方向:因果发现和因果关系
推理。因果发现基于有向无环图。
以及贝叶斯模型,重点在于获得因果关系-

基于观测数据的船舶模型,其方法可分为基于约束的方法[42][47] (例如C、PC、FCI) 、基于函数的方法[15][37][38] (例如LiNGAM和ANM)以及结合上述两种方法优势的混合方法[4]。因果推断的常用框架包括结构因果模型和潜在结果框架[33]。研究人员使用结构因果模型和Rubin因果模型来模拟变量之间的交互作用,并计算因果效应估计值,例如平均处理效应 (ATE)和条件处理效应 (CATE)。

基于LLM的智能体。自主智能体长期以来被认为是实现通用人工智能 (AGI)的一种很有前景的方法,它通过自主规划和行动来完成任务[56][59]。类人智能展现出了巨大的潜力[1][46],并且已经有大量研究将LLM作为智能体的决策和推理中心[30][34][36],并在自然科学[3][44]、工程科学[27][29][52]和人类模拟[9][21]等领域取得了显著的成功。LLM智能体由四个部分组成,分别是角色模块、行动模块、规划模块和记忆模块。角色模块为智能体赋予一个虚拟角色,例如教师或诗人。规划模块帮助智能体利用思维链分解任务,并采用不同的搜索方法在问题空间中获取解决方案,例如CoT[50]、ToT[54]、AoT[35]、反射[39]等。记忆模块分为短期记忆和长期记忆两类。动作模块是智能体在物理或虚拟环境中执行特定动作的关键。

结合大型语言模型 (LLM)和因果关系。自LLM出现以来,一些研究人员已经评估和分析了LLM的因果能力[23]、[26]、[49]、[51]、[61]、[64]。[18]引入了一个新的任务CORR2CAUSE,该任务可以从相关性中推断因果关系,以评估大型模型的因果推断能力。实验结果表明,版本更高或推理能力更强的LLM在因果推断任务中并未表现出正相关性,其性能与随机性相近。[17]进一步研究了大型语言模型是否能够进行因果推理,并提出了一个新的自然语言处理 (NLP)任务:自然语言中的因果推断。他们构建了一个包含1万个样本的大型数据集CLADDER。然而,该问题是用自然语言描述的,因此无法处理表格数据。 [11] 对 ChatGPT 的因果推理能力进行了全面评估。他们发现 ChatGPT 并非优秀的因果推理器,但擅长因果解释,并且 ChatGPT 存在严重的因果幻觉问题,而上下文学习 (ICL) 和思维链技术会进一步加剧这一问题。[58] 认为大型语言模型无法进行因果推理,并定义了一个新的结构因果模型子集,称为元结构因果模型 (meta-SCM)。他们的实证分析提供了有力的证据,表明当前的语言模型甚至只能算是弱“因果鹦鹉”。[19] 发现语言模型在确定成对因果关系方面可以取得具有竞争力的性能,准确率高达 97%,但其性能会因……而异。

提示词工程的质量。[24] 提出了 QRData,这是首次尝试从处理表格数据的 LLM 的角度对因果和统计问题进行建模。然而,他的重点在于评估,并没有提出增强 LLM 处理表格数据中因果问题的能力的方法。

这项工作的独特之处在于:(a) 我们首次从逻辑逻辑模型 (LLM)的角度,构建了基于表格的因果问答模型,涵盖四个层级,并将逻辑逻辑模型视为自动化因果推理的智能体。(b) 我们着重研究工具间的交互流程,并提出了一种系统化的因果智能体。(c) 我们提出了CausalTQA,它包含约1400个问题,涵盖四个层级的因果问题。

五. 结论

在这项工作中,我们利用LLM构建了一个因果智能体。该智能体通过调用因果工具,在因果域四个层次上对因果问题进行建模,并赋予该大型模型这四个层次的因果能力。为了测试其处理表格数据上的因果问答的能力,我们提出了CausalTQA基准测试集,该测试集包含四个因果问题层次的1400个问题。因果智能体在CausalTQA上的实验结果表明,其性能非常出色。

通过对多智能体框架的比较、错误案例分析、不同基于LLM的决策核心的使用以及成本评估,我们系统地分析了因果智能体的优势及其潜在的未来研究方向。

通过与来自 QRData 的真实世界数据进行比较,该因果代理展现出强大的泛化能力。该因果代理框架为提升大型模型的因果能力以及在真实场景中实现自动化因果推理提供了一种可行的解决方案。

参考

[1] J. Achiam,S. Adler,S. Agarwal,L. Ahmad,I. Akkaya,FL Aleman,D. Almeida,J. Altenschmidt,S. Altman,S. Anadkat 等人,“Gpt-4 技术报告” ,arXiv 预印本 arXiv:2303.08774,2023。

[2] C. Berzuini,P. Dawid and L. Bernardinell,《因果关系:统计视角和应用》。John Wiley & Sons 出版社,2012 年。

[3] DA Boiko,R. MacKnight and G. Gomes,“大型语言模型的涌现自主科学研究能力” ,arXiv 预印本 arXiv:2304.05332,2023 年。

[4] DM Chickering,“使用贪婪搜索的最优结构识别” ,机器学习研究杂志,第 3 卷,11 月,第 507-554 页,2002 年。

[5] W. Child,《因果性、解释与心灵》。克拉伦登出版社。1994年。

[6] C. Chilvers and H. Goldstein,“皇家统计学会杂志 A 系列 (社会统计学)” ,皇家统计学会杂志 A 系列:社会统计学,第 151 卷,第 1 期,第 1-1 页,1988 年。

[7] Y. Cui, W. Che, T. Liu, B. Qin and Z. Yang,“使用全词掩码进行中文 BERT 预训练” ,IEEE/ACM 音频、语音和语言处理汇刊,第 29 卷,第 3504-3514 页,2021 年。

[8] KB 等,“Econml:用于基于机器学习的异质性处理效应估计的 python 包” ,https://github.com/py-why/EconML,2019 年,版本 0.x。

[9] KA Fischer,“反思性语言编程 (rlp):社会感知敏捷 (socialagi)的垫脚石” ,arXiv 预印本 arXiv:2305.12647,2023 年。

[10] RA Fisher 等人,“014:关于从小样本推导出相关系数的‘可能误差’。” 1921 年。

[11] J. Gao,X. Ding,B. Qin and T. Liu,“chatgpt 是一个好的因果推理器吗?” 2023 年的全面评估。

[12] G. Gottlieb and CT Halpern,“正常和异常发展中因果关系的关联观点” ,《发展与精神病理学》,第 14 卷,第 3 期,第 421-435 页,2002 年。

[13] D. Guo, Q. Zhu, D. Yang, Z. Xie, K. Dong, W. Zhang, G. Chen, X. Bi, Y. Wu, Y. Li 等, “Deepseek-coder:当大型语言模型遇到编程 代码智能的兴起”,arXiv 预印本 arXiv:2401.14196,2024 年。

[14] JJ Heckman 和 R. Pinto, “因果关系和计量经济学”,国家经济研究局技术报告,2022 年。

[15] P. Hoyer,D. Janzing,JM Mooij,J. Peters 和 B. Scholkopf, “具有加性噪声模型的非线性因果发现”,神经网络处理系统进展,第 21 卷,2008 年。

[16] F. Jin,Y. Liu 和 Y. Tan, “大型语言模型中低秩自适应的无导数优化”,IEEE/ACM 音频、语音和语言处理汇刊,第 32 卷,第 4607-4616 页,2024 年。

[17] Z. Jin,Y. Chen,F. Leeb,L. Gresele,O. Kamal,Z. Lyu,K. Blin,FG Adauto,M. Kleiman-Weiner,M. Sachan 和 B. Scholkopf, “Cladder:评估语言模型中的因果推理”,2024 年。

[18] Z. Jin,J. Liu,Z. Lyu,S. Poff,M. Sachan,R. Mihalcea,M. Diab 和 B. Scholkopf, “大型语言模型能否从相关性推断因果关系?” 2023 年。

[19] E. K. C. man,R. Ness,A. Sharma 和 C. Tan, “因果推理和大型语言模型:为因果关系开辟新领域”,arXiv 预印本 arXiv:2305.00050,2023 年。

[20] J. Kocou,J. Cichecki,O. Kaszycza,M. Kochanek,D. Szyd o,J. Baran,J. Bielaniewicz,M. Gruza,A. Janz,K. Kanclerz 等人, “Chatgpt:万事通,一无是处”,信息融合,卷. 99,p. 101861,2023。

[21] G. Kovac,R. Portelas,PF Dominey 和 P.-Y. Oudeyer, “社会人工智能学派:从发展心理学到人工社会文化代理的见解”,arXiv 预印本 arXiv:2307.07871,2023 年。

[22] P. Li,Y. He,D. Yashar,W. Cui,S. Ge,H. Zhang,DR Fainman,D. Zhang 和 S. Chaudhuri, “Table-gpt:针对各种表格任务调整的表格 gpt”,arXiv 预印本 arXiv:2310.09263,2023 年。

[23] H. Liu,Y. Cai,Z. Lin,Z. Ou,Y. Huang 和 J. Feng, “用于半监督任务导向对话系统的变分潜在状态 gpt”,IEEE/ACM 音频、语音和语言处理汇刊,第 31 卷,第 970-984 页,2023 年。

[24] X. Liu, Z. Wu, X. Wu, P. Lu, K.-W. Chang 和 Y. Feng, “大型语言模型是否能够进行基于数据的统计和因果推理? 使用数据对高级定量推理进行基准测试”,2024 年.[在线].可获取: <https://arxiv.org/abs/2402.17644> [25] H. Luo, Q. Sun, C. Xu, P. Zhao, J. Lou, C. Tao, X. Geng, Q. Lin, S. Chen 和 D. Zhang, “Wizardmath:通过强化进化指令增强大型语言模型的数学推理能力”,arXiv 预印本 arXiv:2308.09583,2023 年。

[26] Y. Masuyama,K. Yamaoka,Y. Kinoshita,T. Nakashima 和 N. Ono, “用于在线目标源提取的因果和松弛无失真响应波束形成”,IEEE/ACM 音频、语音和语言处理汇刊,第 32 卷,第 310-324 页,2024 年。

[27] N. Mehta,M. Teruel,PF Sanz,X. Deng,AH Awadallah 和 J. Kise-leva, “通过帮助反馈与代理互动,提高协作环境中的扎根语言理解”,arXiv 预印本 arXiv:2304.10750,2023 年。

[28] J. Pearl 和 D. Mackenzie, 《为什么之书:因果关系的新科学》,基础书籍出版社,2018 年。

[29] C. Qian,X. Cong,C. Yang,W. Chen,Y. Su,J. Xu,Z. Liu 和 M. Sun, “用于软件开发的通信代理”,arXiv 预印本 arXiv:2307.07924,2023 年。

[30] Y. Qin, S. Liang, Y. Ye, K. Zhu, L. Yan, Y. Lu, Y. Lin, X. Cong, X. Tang, B. Qian 等, “Toollm:帮助大型语言模型掌握 16000 多个真实世界的 API”,arXiv 预印本 arXiv:2307.16789,2023 年。

[31] P. Rolland,V. Cevher,M. Kleindessner,C. Russel,B. Scholkopf,“ D. Janzing 和 F. Locatello, “分数匹配能够实现非线性加性噪声模型的因果发现”,2022 年.[在线].可获取: <https://arxiv.org/abs/2203.04413> [32] B. Roziere,J. Gehring,F. Gloeckle,S. Sootla,J. Gat,XE Tan,Y. Adi,J. Liu,R. Sauvestre,T. Remez 等, “Code llama:代码的开放基础模型”,arXiv 预印本 arXiv:2308.12950,2023 年。

[33] DB Rubin, “估计随机和非随机研究中治疗的因果效应。”教育心理学杂志,第 66 卷,第 5 期,第 688 页,1974 年。

[34] T. Schick,J. Dwivedi-Yu,R. Dess ,R. Raileanu,M. Lomeli,E. Ham-bro-L. Zettlemoyer,N. Cancedda 和 T. Scialom, “Toolformer:语言模型可以自学使用工具”,神经网络处理系统进展,第 36 卷,2024 年。

[35] B. Sel,A. Al-Tawaha,V. Khattar,L. Wang,R. Jia 和 M. Jin, “思想算法:增强大型语言模型中思想的探索”,arXiv 预印本 arXiv:2308.10379,2023 年。

[36] Y. Shen, K. Song, X. Tan, D. Li, W. Lu 和 Y. Zhuang, “Hugginggpt:使用 chatgpt 及其在 hugging face 中的朋友解决人工智能任务”,神经网络处理系统进展,第 36 卷,2024 年。

[37] S. Shimizu,PO Hoyer,A. Hyvarinen,A. Kerminen 和 M. Jordan, “用于因果发现的线性非高斯无环模型。”机器学习研究杂志,第 7 卷,第 10 期,2006 年。

[38] S. Shimizu,T. Inazumi,Y. Sogawa,A. Hyvarinen,Y. Kawahara,T. Washio,PO Hoyer,K. Bollen 和 P. Hoyer, “Directlingam:一种学习线性非高斯结构方程模型的直接方法”,机器学习研究杂志-JMLR,第 12 卷,4 月,第 1225-1248 页,2011 年。

[39] N. Shinn,F. Cassano,A. Gopinath,K. Narasimhan 和 S. Yao, “Re-flexion:具有言语强化学习的语言代理”,神经网络处理系统进展,第 36 卷,2024 年。

[40] Y. Song, W. Xiong, D. Zhu, W. Wu, H. Qian, M. Song, H. Huang, C. Li, K. Wang, R. Yao 等人, “Restgpt:将大型语言模型与真实世界的 restful apis 连接起来”,arXiv 预印本 arXiv:2306.06624,2023 年。

[41] P. Spirtes,CN Glymour 和 R. Scheines,因果关系、预测和搜索,麻省理工学院出版社,2000 年。

[42] PL Spirtes,C. Meek 和 TS Richardson, “存在潜在变量和选择偏差时的因果推断”,arXiv 预印本 arXiv:1302.4983,2013 年。

[43] M. Sun,R. Han,B. Jiang,H. Qi,D. Sun,Y. Yuan 和 J. Huang, “基于大型语言模型的统计和数据科学代理调查”,arXiv 预印本 arXiv:2412.14222,2024 年。

[44] M. Swan,T. Kido,E. Roland 和 RP d. Santos, “数学代理:计算基础设施、数学嵌入和基因组学”,arXiv 预印本 arXiv:2307.02502,2023 年。

[45] G. Team,R. Anil,S. Borgeaud,J.-B. Alayrac,J. Yu,R. Soricut,J. Schalkwyk,AM Dai,A. Hauth,K. Millican 等人, “Gemini:一系列功能强大的多模态模型”,arXiv 预印本 arXiv:2312.11805,2023 年。

[46] H. Touvron,T. Lavril,G. Izacard,X. Martinet,M.-A. Lachaux,T. Lacroix,B. Roziere,N. Goyal,E. Hambro,F. Azhar,A. Rodriguez,A. Joulin,E. Grave 和 G. Lample, “Llama:开放高效的基础语言模型”,2023 年。

[47] R. Tu,C. Zhang,P. Ackermann,K. Mohan,H. Kjellstrom 和 K. Zhang, “存在缺失数据时的因果发现”,载于第 22 届人工智能与统计学国际会议论文集,Pmlr,2019 年,第 1762-1770 页。

[48] A. Vlontzos,D. Rueckert 和 B. Kainz, “医学图像分析中学习算法的因果关系综述”,arXiv 预印本 arXiv:2206.05498,2022 年。

[49] X. Wang, H. Zhang, S. Zhao, H. Chen, Z. Ding, Z. Wan, B. Cheng 和 Y. Lan, “利用因果推理消除多轮对话推理中的反事实上下文偏差”,IEEE/ACM 音频、语音和语言处理汇刊,第 32 卷,第 1125-1132 页,2024 年。

[50] J. Wei, X. Wang, D. Schuurmans, M. Bosma, F. Xia, E. Chi, QV Le, D. Zhou 等, “思维链提示引发大型语言模型中的推理”,神经网络处理系统进展,第 35 卷,第 24824-24837 页,2022 年。

[51] A. Wu,K. Kuang,M. Zhu,Y. Wang,Y. Zheng,K. Han,B. Li,G. Chen,F. Wu 和 K. Zhang, “大型语言模型的因果关系”,arXiv 预印本 arXiv:2410.15319,2024 年。

[52] H. Wu,Z. He,X. Zhang,X. Yao,S. Zheng,H. Zheng 和 B. Yu, “Chateda:一个基于大型语言模型的自主代理,用于 eda”,IEEE集成电路与系统计算机辅助设计学报,2024 年。

[53] J. Xue,Y. Deng,Y. Gao 和 Y. Li, “Auffusion:利用扩散和大型语言模型的力量进行文本到音频的生成”,IEEE/ACM 音频、语音和语言处理学报,第 32 卷,第 4700-4712 页,2024 年。

[54] S. Yao,D. Yu,J. Zhao,J. Shafran,T. Griffiths,Y. Cao 和 K. Narasimhan, “思维树:使用大型语言模型进行深思熟虑的问题解决”,神经网络处理系统进展,第 36 卷,2024 年。

[55] S. Yao,J. Zhao,D. Yu,N. Du,J. Shafran,K. Narasimhan 和 Y. Cao, “React:在语言模型中协同推理和行动”,2023 年。

[56] Y. Yao,P. Yang,G. Zhao 和 G. Yin, “Kgagent:学习用于关键词生成的深度强化代理”,IEEE/ACM 音频、语音和语言处理汇刊,第 32 卷,第 1928-1940 页,2024 年。

[57] A. Zeng,M. Liu,R. Lu,B. Wang,X. Liu,Y. Dong 和 J. Tang, “代理调整:启用 llms 的广义代理能力”,arXiv 预印本 arXiv:2310.12823,2023。

[58] M. Zecevi v c.M. Willig,DS Dhami 和 K. Kersting, “Causal parrots:大型语言模型可能会谈论因果关系,但实际上并非因果关系。” 2023 年。

[59] B. Zhang, X. Li, X. Xu, K.-C. Leung, Z. Chen 和 Y. Ye, “基于方面的情感分析的知识引导胶囊注意力网络”,
IEEE/ACM 音频、语音和语言处理学报,第 28 卷,第 2538-2551 页,2020 年。

[60] T. Zhang,X. Yue,Y. Li 和 H. Sun, “Tablellama:面向开放的大型通用表格模型”,arXiv 预印本 arXiv:2311.09206,2023 年。

[61] Y. Zheng,G. Chen 和 M. Huang, “对话系统中自然语言理解的域外检测”,IEEE/ACM 音频、语音和语言处理汇刊,第 28 卷,第 1198-1209 页,2020 年。

[62] Y. Zheng, B. Huang, W. Chen, J. Ramsey, M. Gong, R. Cai, S. Shimizu, P. Spirtes 和 K. Zhang, “Causal-learn:Python 中的因果发现”,arXiv 预印本 arXiv:2307.16405,2023 年。

[63] _____, “Causal-learn:Python 中的因果发现”,《机器学习研究杂志》,第 25 卷,第 60 期,第 1-8 页,2024 年。

[64] J. Zhou, Y. Lin, Q. Chen, Q. Zhang, X. Huang 和 L. He, “Causalabsc:基于方面的情感分类中方面去偏的因果推理”,IEEE/ACM 音频、语音和语言处理汇刊,第 32 卷,第 830-840 页,2024 年。