

CRAwDAD:基于双智能体的因果推理增强

辩论

芬恩·G·瓦莫西,卡尔加里大学计算

机科学系,加拿大卡尔加里,finn.vamosi@ucalgary.ca

尼尔斯·D·福克特,放射科、霍奇基

斯脑研究所和阿尔伯塔儿童医院研究所,卡尔加里大学,加拿大卡尔加里,nils.forkert@ucalgary.ca

抽象的

人们在思考因果关系时,通常会考虑许多相互竞争的“假设”情景,然后再决定哪种解释最合适。类似地,能够进行因果推理的高级语言模型可以考虑多种干预措施和反事实,以判断因果主张的有效性。关键在于,这种推理与其说是一次简单的计算,不如说是不同假设之间的内部对话。本文通过一个双主体辩论框架来明确这种对话:一个模型提供结构化的因果推理,另一个模型则批判性地审查该推理是否存在逻辑缺陷。当出现分歧时,两个主体会尝试说服对方,挑战彼此的逻辑并修正结论,直到达成双方都认可的答案。为了充分利用这种审议过程,我们特意使用了推理语言模型。与标准大型语言模型相比,推理语言模型在因果推理和对抗性辩论方面的优势尚未得到充分挖掘,因为标准大型语言模型无法像推理语言模型那样充分运用多步骤逻辑推理。我们在 CLadder数据集上评估了我们的方法。CLadder 数据集是一个基准数据集,它将自然语言问题与正式定义的因果图关联起来,涵盖了 Pearl因果阶梯的所有三个层级。我们使用 Qwen3 和 DeepSeek-R1 作为辩论智能体,结果表明,多智能体辩论将 DeepSeek-R1在因果推理方面的整体准确率从 78.03% 提高到 87.45%,其中反事实类别的准确率从 67.94% 提高到 80.04%。同样,Qwen3 的总体准确率从 84.16% 提升至 89.41%,反事实问题的准确率也从 71.53% 提升至80.35%,这表明即使是更强大的模型也能从与较弱智能体的辩论中获益匪浅。我们的结果凸显了推理模型作为多智能体系统因果推理构建模块的潜力,并展示了在因果问题解决中多元视角的重要性。我们的代码可在<https://github.com/finnvamosi/CRAwDAD> 获取。

ACM 参考文献格式: Finn G. Vamosi

和 Nils D. Forkert. 2026. CRAwDAD:基于双智能体辩论的因果推理增强。载于第 25 届国际自主智能体与多智能体系统会议 (AAMAS 2026) 论文集,塞浦路斯帕福斯,2026 年 5 月 25 日至 29 日,IFAAMAS,12 页。<https://doi.org/10.65109/DVBN4652>

Talent and effort both have **direct effects** on elite institution admission status. For students accepted to elite institutions, the **correlation** between talent and being hard-working is **-0.66**. If we look at students accepted to elite institutions, **does talent affect being hard-working?**



The causal graph shows $X > V3 < Y$ with no $X > Y$ path. Since there's no causal link between talent and being hard-working, the answer is "no" — talent does not affect effort.

The correlation is -0.66, which is substantial and negative. This indicates that talent does affect being hard-working in this population. Therefore, the answer is "yes".





You're conflating correlation with causation. The -0.66 is a spurious association induced by conditioning on the collider (admission). Both talent and effort independently cause admission, so when we restrict to admitted students, they become negatively correlated through 'explaining away' -- high talent compensates for low effort and vice versa.

You're right -- the correlation only exists because of selection bias and conditioning on the collider, so the answer is "no".



图 1:两个推理模型之间因果推理辩论的示例。Qwen3 被随机选为第一个发言者,并成功说服 DeepSeek-R1 修改其初始结论,最终得出正确答案 (“否”)。

关键词

多智能体辩论;因果推断;合作;大型语言模型;推理模型



本作品采用知识共享署名国际4.0 许可协议进行许可。

第25届国际自主代理与多代理系统会议 (AAMAS 2026)论文集, C. Amato, L. Dennis, V. Mascardi, J. Thangarajah (编), 2026年5月25-29日,塞浦路斯帕福斯。© 2026 国际自主代理与多代理系统基金会 (www.ifaamas.org) <https://doi.org/10.65109/DVBN4652>

1 引言

因果推理是智人最大的进化优势之一,使人类能够理性地思考我们的行为和他人行为如何影响我们周围的世界[13, 36]。

从分析史前狩猎失败到设计科学实验,人类自然而然地会问“如果事情有所不同会怎样?”,并根据自身情况想象反事实情景。

511.22854v2

情境的因果模型。这种推理通常通过对话集体进行,人们质疑既有假设并讨论其他解释。这种反事实思维能力在统计学和人工智能领域已被形式化为“因果推断”,它研究干预和假设性变化如何影响观察到的结果[33, 34]。由于这一过程依赖于对显式因果模型的操作[32],而非语言相关性,因此对人类而言的直觉对于大多数大型语言模型(LLM)来说仍然具有挑战性[16]。然而,新开发的推理语言模型(RLM)[9, 39]旨在进行逐步、系统性的问题解决,这使得它们成为检验更强大的内部推理能力是否能够支持因果推断的理想候选模型。

RLM的这种审议特性表明,它们可能特别适合于相互竞争的假设之间进行协作对话。然而,近期文献综述显示,此前尚无研究探讨多智能体辩论(MAD)能否提升LLM或RLM中的因果推理能力[23, 29, 44, 45, 50]。在MAD范式中,多个智能体参与结构化讨论,提出解决方案,互相批判对方的论点,并根据反馈完善自身的推理。这种方法已在许多非因果领域展现出优于单智能体表现的显著提升[3, 5, 6, 10, 12, 22, 25, 27, 48, 51, 58]。虽然辩论似乎天然契合因果推理中固有的假设检验,但使用严谨的数据集进行评估对于准确评价任何改进都至关重要。

Jin 等人[16]认为,先前用于评估语言模型中常识因果关系理解的数据集[56, 57]缺乏正式的构造规则,因此无法确定模型是在执行真正的因果推理,还是采取一种称为“摊销因果推理”的捷径。本质上就像“因果鹦鹉”一样重复训练数据模式[54]。

为了弥补这一不足,Jin等人构建了CLadder数据集,该数据集将每个自然语言问题与一个形式化的因果模型关联起来,其正确答案由一个受Pearl[因果推理引擎]启发的预言机计算得出[35]。其中一些问题有意与现实世界的知识相悖,而另一些问题则使用随机生成的变量,迫使语言模型依赖形式推理而非记忆。在他们的评估中,Jin等人发现ChatGPT-4[30]在使用链式思维(CoT)提示[49]时达到了70.40%的总体准确率,但对于反事实问题,准确率仅为62.05%。

自CLadder于2023年发布以来,RLM的出现为重新审视这些基准提供了新的契机。与传统的LLM在单次前向传播中生成响应不同,RLM使用强化学习结合人类反馈(RLHF)进行训练,从而在产生最终答案之前进行更深入的思考[9, 39]。这种训练范式明确地奖励模型推理步骤而非立即得出结论,鼓励它们探索多种解决方案路径,在遇到矛盾时回溯,并迭代地完善其思维[19]。这些行为补充了因果推理和MAD:通过提供更连贯、更自洽的推理链,RLM为智能体阐明、评估和完善相互竞争的因果假设提供了更坚实的基础。反过来,这增加了RLM之间的MAD收敛于更准确、更易于解释的结论的可能性。

据我们所知,此前仅有一项研究尝试在单智能体环境下评估和比较RLM的形式化因果推理能力[53]。更具体地说,该研究在CLadder数据集上评估了DeepSeek-R1和OpenAI的RLM,以及一系列标准LLM。然而,由于“成本和时间限制”,对所研究的RLM的分析和比较仅限于从数据集中总共10,112个问题中随机抽取的100个样本。在这100个样本上,RLM的性能结果显著高于ChatGPT-4[30],其中DeepSeek-R1[9]、OpenAI o1[31]和OpenAI o3-mini的总体准确率分别达到了92.0%、89.0%和92.2%。然而,由于CLadder数据集被分为难度差异巨大的三个类别,因此,如果不提供样本构成方面的详细信息,总体准确率可能是一个具有误导性的指标。因此,需要进一步研究,以在单智能体场景和多智能体设计(MAD)框架下,对完整数据集上的RLM进行严格评估。

在本文中,我们通过在RLM之间进行辩论,明确地展现了因果推断过程中假设之间的对话,并将此框架应用于完整的CLadder数据集。为了鼓励模型之间更直接、对抗性的互动,我们采用了双代理方法,并选择了最先进的开源RLM:DeepSeek-R1[9]和Qwen3[39]。

我们的研究结果表明,通过辩论进行协作推理能够显著提升因果推理任务的性能,尤其是在最具挑战性的反事实查询任务中,提升最为显著。我们首次在完整的CLadder数据集上对RLM进行了全面评估,并为单智能体和多智能体性能建立了强有力的基准,从而为未来因果推理和协作式人工智能系统交叉领域的研究提供了基准。

因此,本文的主要贡献可以概括如下:

- (1)我们对两个开源RLM在完整的CLadder数据集上的因果推理能力进行了深入分析和比较,并按Rung对性能进行了分类。
- (2)我们实施了一种新颖的双智能体辩论框架,鼓励RLM之间更直接的互动,包括置信度估计、提前停止策略和改进的提示。
- (3)我们评估所有辩论的关键结果,以探索双人辩论是否能提高CLadder数据集所有类别的最终答案准确性。

2 相关工作

迄今为止,已有许多研究探讨了LLM在因果任务中的单智能体性能[1, 7, 15, 17, 20, 50, 60]。然而,据我们所知,此前唯一将多智能体辩论应用于形式因果关系的研究是为了发现因果关系,而非进行因果推断[21]。不过,作者也承认他们的方法仅限于观测数据,无法进行因果推理。

干预措施限制了其在实践中的应用。此外,最近的批评质疑了使用标准线性线性模型(LLM)进行因果发现的有效性,指出其基于相关性的训练和优化使其在确定因果关系方面不可靠。

单独来看图结构[52]。相比之下,我们的工作重点是因果推理,这是一个不同的问题,其任务是基于已知的因果图来回答干预性和反事实性查询。

一项相关研究将多智能体辩论应用于与因果关系相关的语境中,重点评估由标准逻辑逻辑模型 (LLM)生成的推理链中的因果一致性[43]。在该框架下,评估智能体判断来自多个推理者的论证的逻辑连贯性。重要的是,这些智能体并非逻辑逻辑模型 (RLM),且评估是在常识和知识密集型基准上进行的,这些基准不需要像我们研究那样对干预或反事实进行正式的因果推理。

此外,这两篇论文对所有代理都使用了相同的基本模型,这可能会导致对话中出现共同的偏见[21, 43]。

为了克服我们工作中的这一局限性,我们从最近的研究中汲取灵感,这些研究表明,通过使用不同的基础模型进行辩论可以取得显著的好处,而不是依赖对所有代理使用相同的基础模型 (例如 GPT-4)进行辩论[4, 47]。

目前大多数多属性决策 (MAD)方法都要求辩论经过预定的讨论轮数才能得出结论。然而,先前的研究表明,如果仅当第一位发言者的置信度低于某个阈值时才启动辩论,则可以在大幅减少模型调用次数的情况下达到类似的最终答案准确率[11]。在我们的工作中,我们借鉴了这一思路,但采用了一种新颖的设置,该设置始终确保每个参与者至少做出一次回应,并且仅当他们对答案存在分歧时才启动辩论。这种设置是我们方法论的关键组成部分,我们将在以下章节中详细介绍。

3 材料与方法

3.1 数据集

我们在这项工作中用于评估的 CLadder 数据集包含-
该数据库包含 10,112 道题,每道题都是一道正式的因果推理题,需要运用严谨的推理、算术以及对因果关系概念和公式的理解才能正确作答。这些题目主要分为三个难度等级[35],难度逐级递增。其中,第三等级包含 3,792 个样本,第一等级和第二等级各包含 3,160 个样本。

第一层级 (“观察”)问题询问变量之间的统计关联,例如“学生喝咖啡与考试成绩之间是否存在正相关关系?”。第二层级 (“行动”)问题需要对现实世界进行积极干预,例如“如果让学生在考试前喝咖啡,他们的成绩会提高吗?”。最后,第三层级 (“想象”)问题涉及反事实,需要对与现实相悖的替代情景进行推理。换句话说,这类问题询问世界可能存在的不同之处。例如:“鲍勃喝了咖啡后考试得了85分。

如果他没喝咖啡,他的分数会更低吗?

数据拆分的第二种方式是通过三种符合常识的对齐方式。第一种符合常识的对齐方式是将数据与源自因果关系文献的常规经验性问题对齐。在第二种符合常识的对齐方式中,一个变量被随机替换为一个与该变量无关的概念。

语句中的其他因果变量:例如,这可能会生成诸如“耳形影响肺焦油沉积”或“满月影响疫苗接种率”之类的提示。最后,在第三个常识对齐类别中,所有因果变量都被替换为随机的无意义词语:例如,模型可能会被告知“zory 影响 gwet”。

3.2 辩论设置如上所述,文献中

最常见的 MAD 配置包含三个辩手模型,或两个辩手模型和一个裁判模型[23, 45]。然而,由于我们特别想探究 RLM 之间相互说服改变答案的能力,因此我们决定只包含两个直接相互互动的智能体。这种设置允许智能体之间进行更具对抗性的互动,并允许使用更具体的语言来指出逻辑或计算中的错误。虽然使用裁判与此目标并不冲突,但最近的研究表明,语言模型在被指定为裁判时会表现出一些偏见[25, 40],例如倾向于偏袒最后发言者[28]。此外,最近的研究表明,强制模型捍卫其被赋予的立场可能会降低性能,而允许它们根据相反的观点改变意见可能会带来更好的结果,而无需裁判[18]。因此,我们选择不引入评判者,允许各智能体直接辩论,并在被对方模型说服时改变答案。这种模式也避免了引入第三个智能体带来的计算开销,并且无需定义哪个模型必须担任评判者。

在确定了数据集内容和辩论框架的总体结构之后,我们现在来描述具体的实现细节。每个问题自然都会引发一场辩论,为了更公平地评估每个 RLM 的性能,第一轮辩论必须随机选择一个模型作为第一位发言者。此时,我们不会向模型解释辩论形式,以尽可能保持提示设置与 Jin 等人的原始论文[16] 中的设置相似。他们提出的提示策略 (称为 CausalCoT)详细说明了 RLM在最终答案中必须遵循的正式因果推理的每个步骤,包括形式化因果图以及从选项列表中识别查询类型。在提供这些指令之后,我们会向 RLM 提供 CLadder 数据集中与问题相关的背景信息 (例如因果关系)和概率。该模型还被要求给出最终的“是/否”答案,并且与CausalCoT 不同的是,它还需要估计自身的置信度,这与其他几种 MAD 方法类似[2, 26]。此外,我们指示该模型更加自信,并接受由于数据集的性质,其答案可能与其常识相悖。这种设置源于初步实验,在这些实验中,我们发现模型倾向于过度思考问题并怀疑自己的答案,这导致响应时间显著延长。

一旦收到完整的提示 (如附录 B 所示),第一个 RLM 便开始执行因果推理步骤,解析问题中提供的数据,并从中生成公式。

预训练知识库,以及执行所需的算术和因果演算[41]。大部分的思考过程发生在内部的“推理轨迹”中,但由于其冗长且包含被丢弃的信息,我们只将智能体的简洁理由和最终答案发送给其对手。然而,我们仍然保存了该推理轨迹以供后续的人工分析。第一位发言者的回答完成后,第二轮开始。为了鼓励对手模型更直接地参与到第一个模型的工作中,我们不会引导它再次遵循所有形式推理步骤。相反,我们会向它提供关于辩论形式以及随之而来的新期望的信息,即仔细审查对手的回答,找出推理中的任何缺陷,并形成适当的反驳(完整提示见附录C)。但是,如果第一个模型的回答中不存在缺陷,我们不会强制第二个模型去寻找。

因此,如果两个模型的结果一致,那么该结果将被接受为最终结果。

然而,如果第二个模型不同意第一个模型的答案,则开始第三轮,并将批评意见反馈给第一个模型。我们不会强迫第一个模型坚持其先前的立场,而只是指示它考虑批评意见,并可以根据对方的论点捍卫其最初的答案或进行修改。如果第一个模型拒绝批评意见并捍卫其最初的答案,则该反驳意见将反馈给第二个模型进行第四轮,其后续的回复将被记录为该问题的最终答案,即使两个模型之间仍然存在分歧。图 1 和附录 D 提供了两个智能体之间进行四轮辩论的示例。在初步实验中,我们发现增加轮数收效甚微,因为当两个模型都已陈述完各自的观点并保持立场一致时,辩论就结束了。

他们的回答不太可能因进一步讨论而改变。这之前对标准学习逻辑模型的研究结果一致,该研究表明,超过一定阈值的持续讨论会导致答案准确性停滞甚至下降[3]。

3.3 模型

遵循开放科学和可复现性的原则,我们将评估范围限定于权重公开的开源 RLM模型,排除了 OpenAI Anthropic (Claude)、Google (Gemini)等供应商的专有模型。在实施时,免费的 Ollama 平台上只有三个 RLM 模型:Qwen3、DeepSeek-R1 和 Magistral。由于硬件限制,我们选择了 Qwen3-32B 和 DeepSeek-R1-Distill-Qwen-32B 进行这项工作,它们在推理能力和显存需求之间取得了最佳平衡。初步测试证实, Magistral-24B 的性能远低于这两个 32B 模型,进一步支持了我们的选择。

值得注意的是,所使用的 DeepSeek-R1-Qwen-32B 模型源自 Qwen2.5 基础模型,而 Qwen2.5 基础模型又基于 DeepSeek-R1-671B 模型的推理输出进行了微调。然而, Qwen3 的训练样本数量是 Qwen2.5 的两倍,并且在模型架构方面进行了多项改进,这应该会在两个模型之间引入显著的异质性。正如之前的研究[4, 47] 所表明的,这种模型多样性对于有效的讨论至关重要,我们认为在讨论因果推理时尤其如此,因为它增加了智能体之间相互理解的可能性。

会提出相互竞争的因果假设,而不是强化共同的偏见。

在初步测试中,我们观察到这两个 RLM 对结构化输出的要求响应不佳。更准确地说,如果启用 Ollama 的结构化输出功能,它们要么忽略提示中的这部分内容,要么完全跳过思考阶段。

这一发现与近期研究结果一致,该研究发现推理模型在遵循指令方面不如标准逻辑推理模型 (LLM) [24, 42]。为此,我们在流程中添加了一个 Granite3.3-2B 模型,用于从主要逻辑推理模型 (RLM)的响应中提取最终的“是/否”答案和置信度估计。在对 50 个随机抽取的辩论输出进行人工检查后, Granite 模型始终能够准确提取出相应的结果。

3.4 实验我们的主要评估方法是

比较辩论前后模型的准确率,准确率的衡量标准是 RLM 响应与 CLadder 中真实标签匹配的比例。为了更全面地评估辩论效果(而不仅仅是准确率),我们对所有模型输出进行了额外的分析,如下所述。

说服动态。为了评估辩论是改进还是破坏了初始回答,我们追踪了所有需要辩论(3轮及以上)的问题中,从第一个模型的初始回答到最终共识答案的变化。对于每个模型,我们将结果分为四类:正确到正确(保持准确性)、错误到正确(被说服倾向于正确)、正确到错误(被同伴影响)和错误到错误(未能改进)。我们按模型和难度等级对这些结果进行分层,以确定说服模式是否因模型能力或问题难度而异,从而揭示哪个模型在辩论过程中更具影响力。接下来,我们对模型的回答进行了情感分析,以确定其语言的平均积极性或消极性;包括其在形成初始答案时以及与同伴辩论时的表现。为此,我们删除了模型输出中的所有格式,并将它们传递给流行的 VADER 库 [14] 的 SentimentIntensityAnalyzer。

置信度校准。对于每个模型,我们比较了正确答案和错误答案的置信度分布,包括初始回答和受到同伴质疑后的回答。这项分析旨在解答三个问题:置信度是否与正确性相符(校准),问题难度(难度等级)如何影响这种一致性,以及面对高自信的对手会增加还是降低改变答案的可能性。

回应特征。我们测量了初始回答和辩论轮次的回应长度分布,以评估参与深度并识别不同模型间论证努力的潜在不对称性。最后,我们可视化了在不同难度级别(Rungs)下达成共识所需的轮次分布,以及最终轮次的共识率,从而深入了解辩论效率以及问题复杂性对讨论时间的影响程度。

4 个结果

表1所示结果表明,辩论实质

DeepSeek-R1 和 RLM 最终都提高了两种 RLM 的性能。

表 1:所有模型在 CLadder 数据集上的性能。我们报告了总体准确率 (Acc.) 和细粒度准确率。常识一致性的层次和程度,从常识 (Comm.)、荒谬 (Nonsens.)到反常识 (滑稽。)。

	总体准确率	参考 Rung			根据常识对齐	
		1	2	3. 通信无意义	滑稽。	
GPT-4 [16]	62.03	63.01	62.82	60.55	62.27	63.09
+ CausalCoT [16]	70.40	83.35	67.47	62.05	69.25	71.58
Qwen3 (首字母)	84.16	93.77	89.80	71.53	84.96	83.10
Qwen3 (最终版)	89.41	96.24	93.51	80.35	89.52	87.91
DeepSeek-R1 (初始版)	78.03	90.67	77.29	67.94	77.63	77.24
DeepSeek-R1 (最终版)	87.45	94.62	89.06	80.04	87.83	86.94
人类[53]	94.8	-	-	-	-	-

Qwen3 的准确率分别达到了 9.42% 和 5.25%。辩论结束后，Qwen3 在所有题型中均取得了最高的准确率。紧随其后的是 DeepSeek-R1。总体而言，Qwen3 能够在第一级和第二级相对问题中保持较高的分数与 CausalCoT 基线结果相比。然而，第 3 级问题与其他方法相比，准确率显著下降。两个阶梯，但这些问题也从中受益最多。两种模型的辩论结果：Qwen3 和 DeepSeek-R1 均增长了 8.82% 和准确率分别为 12.10%。

虽然我们主要使用每个模型在辩论前的准确率作为……以此类推，我们还进行了一项规模较小的基准评估。使用 500 个常识性查询（250 个来自）对每个模型进行查询根据 Yu 等人的提示[53]，Rung-1 和 Rung-3 中的 250，不允许他们与同伴辩论。简而言之，这项二次分析的结果与上述结果基本一致。图 1 显示了初始精度：在 Rung-1 上，Qwen 达到了 89.20% (223/250) 和 DeepSeek 90.00% (225/250)，而在 Rung-3 上，Qwen 的准确率为 72.40% (181/250)，DeepSeek 的准确率为 67.60% (169/250)。这些差异中的大多数在统计学上无法区分。我们报告的初始准确率。然而，Qwen 的下降幅度为 4.6%。使用 Yu 等人的提示时，准确性显著提高（p 值 = 0.007）。

4.1 说服

图 2 展示了辩论框架带来的净积极影响。当模型对初始结果存在分歧时，会对最终答案的准确性产生影响。答案。简而言之，结果表明它远比这更……辩论很可能会将错误的答案改为正确的答案。反之则不然。结果还表明，DeepSeek-R1 更容易被说服，因为它更有可能接受Qwen3的观点。面对质疑，要给出答复。尽管如此，Qwen3 仍然从中受益匪浅。通过与 DeepSeek-R1 的辩论，纠正了它最初的许多错误。错误的应对方式，却在捍卫自身权益方面做得更好。正确答案。这有助于解释图中所示的发现。表1显示，DeepSeek-R1模型的初始值较低。得分高于 Qwen3，同时也从辩论中获益更多。过程。换句话说，Qwen3 模型在这两方面似乎都表现更好。推理与说服。




图2 :对于最初存在分歧的问题,进行辩论它改进答案的次数远比使答案变差的次数多。

对一些以无结果告终的辩论进行定性分析经过四轮讨论，我们发现Qwen3的论点倾向于达成共识。篇幅更长，对对方的回应也更加直接。并拥有更积极主动的发言权。相比之下，DeepSeek-R1 提供简短的回答（通常只有“是”或“否”）倾向于保持中立，在某些情况下几乎显得完全与对话脱节。通常，对于非专业人士而言，Qwen3 模型答案似乎更正确、更有说服力。因为它表达观点的方式，即使观点是错误的。为了更详细地探讨这个问题，我们进行了一项简单的情感分析。使用 VADER [14]分析所有代理反应，发现虽然这两个模型在初始反应中都表现出中立情绪，在随后的辩论中，Qwen3模型变得更加负面。其情感值为-0.239，而DeepSeek-R1的情感值为-0.239。中性情绪值为0.015。考虑到……，这是意料之中的。




图 3:两个模型在每个层级上的初始置信度。随着层级复杂度的增加,模型的置信度逐渐降低,并且通常对错误答案和正确答案的置信度相同。

Qwen3 使用了更直接的语言来批评 DeepSeek-R1 的回应,这种回应自然会倾向于负面,即使没有明确地“刻薄”也如此。

4.2 置信度

图 3 显示,两个模型通常都非常自信,置信度从未低于 60%。考虑到我们明确要求模型保持自信,这是合理的。但我们发现,难度越高,模型的初始置信度往往越低,这表明它们并没有完全抑制不确定性。问题的常识性与模型的置信度之间似乎没有明显差异(即,反常识性的问题并不会使模型更加谨慎)。值得注意的是,两个模型似乎都不愿输出 65-80% 范围内的置信度,并且它们的置信度分布相似,尽管 Qwen3 的置信度往往略高一些。

图 3 的第二列显示了两个模型一致认为的最终答案的置信度显著提高,

1先前的工作通过让三名训练有素的研究生解答 100 个随机抽取的问题,获得了这一人类基准。[53]




图 4:当对手更有信心时,模型更容易被说服改变答案。




图5:当模型捍卫自己的答案时,面对批评它们不会表现出不确定性。然而,如果被说服改变答案,它们往往会对对方的答案更加自信。

该模型结合了初始一致和初始不一致的情况。在第二个模型立即同意第一个模型的情况下,即使第一个模型并不自信,第二个模型也会对答案充满信心。当模型最初意见不一致时,辩论会显著提升它们的信心。图 5 显示,当模型被对方说服时,它们的信心可能会大幅提高;而当模型捍卫其先前的答案时,它们的信心并不会降低。这些模式与之前的研究结果一致,这些研究表明,即使没有被要求提高信心,LLM 和 RLM 也存在系统性的过度自信[37]。此外,图 4 显示,两个模型都倾向于更容易被更有信心的论证所说服,尽管尚不清楚更有信心的批评是否真的更具说服力,或者模型是否只是对信心评分做出了直接反应。

在对初始置信度的分析中,我们发现了577个案例,其中第一位发言者给出了错误的答案,但置信度很高(>90%),不过随后与同伴的辩论纠正了他们的错误。一般来说,在更高、更难的层级中,对自信答案的纠正更为常见。此外,我们发现Qwen3模型在这项任务中表现更佳,而DeepSeek-R1的准确率较低,因此更受益于同伴对其自信错误答案的纠正。




图 6:随着 Rungs 的推进,辩论结束所需的轮数单调增加。

4.3 轮

如图 6 所示,进一步分析表明,难度更高的 Rung 问题平均需要比第一 Rung 问题更多的辩论轮次。在第一 Rung 问题中,93% 的情况下两个模型都能立即达成一致意见。相比之下,大约四分之一的 Rung 3 问题存在争议,但大多数争议在第三轮中得到解决,第一位发言者被对方的论点说服。有趣的是,研究发现,当 Qwen3 作为第一位发言者时,Rung 2 问题的解决速度比 DeepSeek-R1 作为第一位发言者时更快。然而,这是唯一一个发现第一位发言者与辩论轮次之间存在这种相关性的 Rung 问题。在数据集中的 10112 个问题中,只有 148 个问题最终未能由两个模型达成共识。

因此,即使这两个模型在这些情况下能够就正确答案达成一致 (例如,通过更多讨论或更好的决胜策略),总准确率也只会提高 0.55%。

4.4 响应长度评估结果表明, DeepSeek-R1 模型在辩论中倾向于提供非常简短的响应。

更准确地说,我们观察到,DeepSeek - R1 的辩论回复中有 22.60% (1412/6247) 的回复长度为 100 个字符或更少,而Qwen3 的这一比例仅为 0.40% (11/5986)。如图 7a 所示,即使剔除这些极短的回复,DeepSeek-R1 模型的平均回复长度也远短于 Qwen3 。更准确地说,DeepSeek-R1的回复中位数为 249 个字符,而 Qwen3 的回复中位数为 739 个字符。图 7b 显示, DeepSeek-R1 的初始回复虽然没有如此短,但平均长度仍然更短,中位数为 735 个字符,而 Qwen3 的初始回复中位数为 1012 个字符。

有趣的是,我们发现两个模型的底层推理轨迹实际上具有非常相似的字符数分布 (图 7c)。对几个选定的推理轨迹进行人工检查后发现,DeepSeek-R1 的确考虑了问题及其对手的回答,但在生成最终回答时却莫名其妙地忽略了提示的指示,没有对其推理过程进行任何外部阐述。这可能导致即使 DeepSeek-R1 的答案正确,它在说服 Qwen3 方面也比 Qwen3 更差,这可能也是辩论整体效果不佳的原因,因为 DeepSeek-R1 在这些特定情况下没有提供任何实质性的内容或论证。

案例。

5 讨论

我们的研究表明,RLM之间的辩论可以考虑以下因素: 显著提高了最终答案的准确率,尤其是在最难的问题上,提升幅度最大。根据我们的结果,可以得出结论:与 DeepSeek-R1 相比, Qwen3 通常更适合这项因果推理任务。然而,有趣的是,与 DeepSeek-R1 辩论仍然能够改进其答案,尤其是在第三级问题上,改进幅度相当显著。

同样令人费解的是,尽管辩论轮数大致相同, DeepSeek-R1 模型的准确率却未能达到 Qwen3 模型的水平。这一发现表明,初始答案会对后续结果产生影响,导致最终答案倾向于最初给出的答案。另一个可能的原因是,与人类类似,这些模型可能倾向于忽略论证过程并予以支持,而不是试图找出标注、逻辑或算术中的具体错误。尽管如此,这也体现了辩论模式的优势:即使是较弱的模型也能促进较强模型的改进,而较强的模型反过来又能提升较弱模型的性能,使其超越自身的初始水平。

虽然我们的结果表明,与 2023 年 CLadder 论文中描述的万亿参数 GPT-4模型相比, RLM 的性能有了显著提高,并且第1级和第2级的问题在很大程度上是可以解决的,但这种规模的开源推理模型似乎仍然难以解决第3级的问题。

此外,尽管Qwen3模型在与DeepSeek-R1模型辩论后,能够在第一级查询中达到人类水平,但在第二级查询中,即使经过辩论,其表现也略逊一筹,而在第三级查询中,其表现则远逊于人类,甚至不如DeepSeek-R1模型。虽然先前研究[53]中报告的人类准确率并未因级别而异,但RLM模型似乎仍然无法匹敌人类对反事实进行推理的能力。如果这是基于相关性的LLM和RLM模型固有的局限性,那么一个可能的解决方案是创建一个外部工具,供模型查询以精确计算反事实场景,例如DVerma等人[46]最近实现的工具。虽然我们的结果表明,在不使用此类工具的情况下,LLM 和 RLM 还不能被信任来回答反事实问题,但我们仍然证明了推理模型作为因果推理中多智能体系统的构建模块的潜力,并强调了在因果问题解决中多样化视角的重要性。

我们研究中DeepSeek-R1的准确率与Yu等人的研究结果存在显著差异。他们表现的提升表明,他们要么使用了更大的DeepSeek-R1-671B模型进行评估,要么他们的随机抽样主要来自第一阶段 (Rung 1)的问题,在这种情况下,他们的准确率与我们评估的 DeepSeek-R1 在与Qwen3辩论之前的准确率相当。然而,我们的研究表明,即使在与同伴辩论之后,推理模型在处理第三阶段 (Rung 3)的问题时仍然面临挑战。

置信度分析的结果显示出与人类倾向的有趣契合之处。首先,当一个模型与对立模型的结果一致时,它更有可能对其最终答案充满信心。其次,所研究的模型似乎在决定是否根据对立模型的结果调整自身答案时,会考虑其置信度。这些模型倾向于将自身的置信度估计在 65% 到 80% 的范围内。




图 7:a) DeepSeek-R1 的辩论回复比 Qwen3 短得多,而且少于 100 个字符的回复数量异常多。b) 当被指定为第一位发言者时,这两个模型的初始回复长度差异不大。c) DeepSeek-R1 短辩论回复的底层推理轨迹的字符长度与 Qwen3 的推理轨迹的字符长度相当。

这可能表明他们的训练数据中缺乏这些置信度,或者存在一个二元内部值(高/低置信度),然后将其转换为任意百分比。如果我们不询问第二个模型的答案,仅仅依赖第一个说话者的初始置信度会导致准确率下降 5.7%。这说明

要求两个模型至少给出一个答案的好处是,与预先设定辩论时长的传统方法相比,这仍然大大减少了模型调用次数。

5.1 局限性

鉴于 CLadder 的创建日期为 2023 年[16],我们不能排除DeepSeek-R1 或 Qwen3 (均于 2025 年初发布)在训练期间接触到其内容的可能性。

虽然我们考虑过使用 Cladder 的生成代码生成一套全新的数据,但我们担心,如果我们偶然生成了更简单或更难的问题,这可能会以不同的方式影响与 Jin 等人结果的直接比较。

本研究的另一个潜在局限性与CLadder的合成特性有关:与现实世界的因果推理问题相比, CLadder的问题更为简化、清晰且文本统一,而现实世界的因果推理问题通常涉及混乱的自然语言、模糊的因果结构或不完整的数据。然而,如果没有合成数据,就很难建立精确的真实值,也难以在这种粒度上可靠地衡量模型的正确性。

其次,RLM较长的响应时间与MAD固有的额外模型调用相结合,会引入相当大的广告。

我们的模型需要额外的资源和时间成本,仅 CLadder 的 10,112 个问题就需要 380 小时才能回答完毕。由于时间限制,我们无法进行一些可能具有启发性的消融研究,例如:替换标准LLM、使用三个或更多 RLM、实施评判框架、省略置信度估计以及移除提高置信度的指令。然而,利用我们的框架,所有这些研究都可以在未来进行。

此外,由于开源模型的选择有限,我们仅对一对智能体进行了实验。因此,不同的智能体组合可能会产生不同的结果。

讨论的结果各不相同,当然,不同的模型也会取得不同的初始准确率。特别是,由于我们缺乏对OpenAI 模型的评估,因此无法将其与其他采用单智能体范式的研究成果进行直接比较。

5.2 未来工作

由于硬件限制,32B 参数模型是我们实验中能够使用的最大模型。因此,未来的工作应该评估Qwen3 和 DeepSeek-R1 系列中更大的模型,以研究模型大小和形式因果推理能力之间是否存在缩放规律,正如之前在其他几个领域发现的那样 [8, 38, 55, 59]。

未来关于因果推断与多智能体系统交叉领域的研究也应探索不同的辩论或协作框架。使用三个智能体,或者两个智能体加一个评委,都是比较直接的起点,但更复杂的范式可能会带来更大的收益。

6 结论

本文证明,RLM (推理逻辑模型)之间的辩论能够提升它们在CLadder数据集上进行因果关系形式化推理的集体能力。我们发现,即使独立应用,相对轻量级的开源推理模型也能超越GPT-4 70.40%的准确率基准,而当鼓励它们相互批判推理时,Qwen3-32B的整体准确率提升至89.41%,DeepSeek-R1-Distill-Qwen-32B的总体准确率则提升至87.45%。这些令人鼓舞的结果促使我们进一步研究用于解决因果推理任务的多智能体框架的实现。

参考

[1] Abdolmahdi Bagheri,Matin Alinejad,Kevin Bello 和 Alireza Akhondi-Asl,2024 年。 $\text{\textit{ConfidenceCal}}$:具有因果推理的大型语言模型。https://doi.org/10.48550/arXiv.2407.18069 arXiv:2407.18069 [cs].

[2] 白一林. 2024. ConfidenceCal:通过多智能体辩论中的置信度校准增强LLM的可靠性. 2024年第十届大数据与信息分析国际会议 (BigDIA) . 221–226. https://doi.org/10.1109/BigDIA63733.2024.10808396 ISSN: 2771-6902。

[3]陈志强,陈伟泽,苏雨生,于建轩,薛伟,张尚航,付杰,刘志远。 2023.ChatEval:通过多代理辩论迈向更好的基于 LLM 的评估者。 <https://doi.org/10.48550/arXiv.2308.07201> [cs]。

[4] Justin Chih-Yao Chen,Swarnadeep Saha 和 Mohit Bansal. 2023. ReConcile:圆桌会议通过不同法学硕士之间的共识改进推理。<https://arxiv.org/abs/2309.13007v3>

[5]陈伟泽,苏雨生,左经纬,杨程,袁鹏飞,陈志强,于和阳,路雅熙,洪一航,钱陈,秦雨佳,丛欣,谢若冰,刘志远,孙茂松,周杰。 2024. Agentverse:促进多代理协作和探索紧急行为。 (2024)。

[6] Jina Chun,Qihong Chen, Jiawei Li 和 Iftekhar Ahmed. 2025. 多智能体辩论 (MAD) 是灵丹妙药吗?MAD 在代码摘要和翻译中的实证分析。<https://doi.org/10.48550/arXiv.2503.12029> arXiv:2503.12029 [cs]。

[7]崔少波,金志京,伯恩哈德·舍尔科普夫和博伊·法尔廷斯。2024。《常识因果关系的奥德赛:从基础基准到前沿推理》。<https://doi.org/10.48550/arXiv.2406.19307> arXiv:2406.19307 [cs]。

[8] DeepSeek-AI. 2024. DeepSeek LLM:利用长期性扩展开源语言模型。<https://doi.org/10.48550/arXiv.2401.02954> [cs]。

[9] DeepSeek-AI. 2025. DeepSeek-R1:通过强化学习激励LLM中的推理能力。<https://doi.org/10.48550/arXiv.2501.12948> arXiv:2501.12948 [cs]。

[10] Yilun Du,Shuang Li, Antonio Torralba, Joshua B. Tenenbaum 和 Igor Mordatch。2023年。通过多智能体辩论改进语言模型中的事实性和推理能力。<https://doi.org/10.48550/arXiv.2305.14325> arXiv:2305.14325 [cs]。

[11] Sugyeong Eo, Hyeonseok Moon, Evelyn Hayoon Zi, Chanjun Park 和 Heuiseok Lim. 2025. 仅在必要时进行辩论:用于高效 LLM 推理的自适应多智能体协作。<https://doi.org/10.48550/arXiv.2504.05047> arXiv:2504.05047 [cs]。

[12]马兆鹏,苏佳媛,郑佳美,任佳涵,张艳,吴健,王宏伟,刘作柱。 2025.M-MAD:高级机器翻译评估的多维多智能体辩论。 <https://doi.org/10.48550/arXiv.2412.20127> arXiv:2412.20127 [cs]。

[13]尤瓦尔·诺亚·哈拉里,《人类简史》,2015年,哈珀柯林斯出版社。出版社,纽约州纽约市。

[14] C. Hutto 和 Eric Gilbert. 2014. VADER:一种用于社交媒体文本情感分析的简约规则模型。国际 AAAI 网络与社交媒体会议论文集 8, 1 (2014 年 5 月), 216–225。<https://doi.org/10.1609/icwsm.v8i1.14550> [15] Haitao Jiang, Lin Ge, Yuhe Gao, Jianian Wang, and Rui Song. 2024. LLM4Causal: Democratized Causal Tools for Everyone via Large Language Model. <https://doi.org/10.48550/arXiv.2312.17122> arXiv:2312.17122 [cs]。

[16]金志静、陈元、Felix Leeb、Luigi Greselo、Ojasv Kamal、Zhiheng Lyu、Kevin Blin、Fernando Gonzalez Aduato、Max Kleiman-Weiner、Mrinmaya Sachan 和 Bernhard Schölkopf。 2024. Cladder:评估语言模型中的因果推理。 <https://doi.org/10.48550/arXiv.2312.04350> arXiv:2312.04350 [cs]。

[17] Thomas Jiralerspong, Xiaoyin Chen, Yash More, Vedant Shah 和 Yoshua Bengio。 2024. 使用大型语言模型进行高效的因果图发现。<https://doi.org/10.48550/arXiv.2402.01207> arXiv:2402.01207 [cs]。

[18] Harvey Bonmu Ku, Jeongyeol Shin, Hyoun Jun Lee, Seonok Na 和 Insu Jeon。 2025. 多智能体语言学习模型辩论揭示未言明的前提。载于第十二届论证挖掘研讨会论文集, Elena Chistova, Philipp Cimiano, Shohreh Haddadan, Gabriella Lapesa 和 Ramon Ruiz-Dolz (编), 计算语言学协会, 维也纳, 奥地利, 58–73。<https://doi.org/10.18653/v1/2025.argmining-1.6>

[19] Komal Kumar, Tajamal Ashraf, Omkar Thawakar, Rao Muhammad Anwer, Hisham Cholakkal, Mubarak Shah, Ming-Hsuan Yang, Phillip HS Torr, Fa-had Shabbaz Khan 和 Salman Khan。 2025. 法学硕士后培训:深入探讨大型语言模型的推理。 <https://doi.org/10.48550/arXiv.2502.21321> arXiv:2502.21321 [cs]。

[20] Emre K. C. man, Robert Ness, Amit Sharma 和 Chenhao Tan。2024 年。因果推理和大型语言模型:开启因果关系的新前沿。<https://doi.org/10.48550/arXiv.2305.00050> arXiv:2305.00050 [cs]。

[21] Hao Duong Le, Xin Xia 和 Zhang Chen。 2025. 使用大型语言模型的多智能体因果发现。 <https://doi.org/10.48550/arXiv.2407.15073> arXiv:2407.15073 [cs]。

[22]李韩,施玉玲,林少新,顾晓东,连恒,王欣,贾艳涛,黄涛,王千祥。 2025.SWE-Debate:软件问题解决的竞争性多代理辩论。 <https://doi.org/10.48550/arXiv.2507.23348> arXiv:2507.23348 [cs]。

[23]李新,蔡卓,王守金,于坤,陈方。 2025.关于增强大型语言模型因果推理能力的调查。 <https://doi.org/10.48550/arXiv.2503.09326> arXiv:2503.09326 [cs]。

[24]李晓敏,周宇,张志伟,陈旭鹏,张子庄,庄莹莹, Narayanan Sadagopan, Anurag Beniwal。 2025. 当思考失败时: LLM 中指令遵循推理的陷阱。<https://doi.org/10.48550/arXiv.2505.11423> arXiv:2505.11423 [cs]。

[25]梁田,何志伟,焦文祥,王兴,王艳,王锐,杨玉九,史书明,涂兆鹏。 2024.通过多智能体辩论鼓励大型语言模型中的发散思维。 <https://doi.org/10.48550/arXiv.2305.19118> arXiv:2305.19118 [cs]。

[26] Zijie Lin 和 Bryan Hooi. 2025.通过置信度表达增强多智能体辩论系统性能。 <https://doi.org/10.48550/arXiv.2509.14034> arXiv:2509.14034 [cs]。

[27]凌帅,廖丽子,蒋冬梅,关伟丽。 2025.MeMAD:用于增强多智能体推理的结构化辩论记忆。 (2025)。

[28]刘欣怡,刘品欣,何航峰。 2024.辩论评估中大型语言模型的实证分析。 <https://doi.org/10.48550/arXiv.2406.00050> arXiv:2406.00050 [cs]。

[29]刘晓宇,徐派恒,吴俊达,袁嘉欣,杨一凡,周宇航,刘福瑞,关天瑞,王浩亮,于童,朱利安·麦考利,艾伟,黄芙蓉。 2025.大型语言模型和协作中的因果推理:一项调查。 <https://doi.org/10.48550/arXiv.2403.09606> arXiv:2403.09606 [cs]。

[30] OpenAI. 2024. GPT-4 技术报告。<https://doi.org/10.48550/arXiv.2303.08774> arXiv:2303.08774 [cs]。

[31] OpenAI. 2024. OpenAI o1 系统卡。<https://doi.org/10.48550/arXiv.2412.16720> [cs]。

[32] JUDEA PEARL. 1995. 因果图在实证研究中的应用。Biometrika 82, 4 (1995年12月), 669–688。 <https://doi.org/10.1093/biomet/82.4.669> [33] Judea Pearl. 2009. 统计学中的因果推断。概述。Statistics Surveys 3, 无 (2009 年 1 月)。<https://doi.org/10.1214/09-SS057>

[34] Judea Pearl. 2022. 因果关系:模型、推理和推断 (第二版, 修订重印版)。剑桥大学出版社, 剑桥, 纽约, 墨尔本, 新德里, 新加坡。

[35] Judea Pearl 和 Dana Mackenzie. 2020. 《为什么之书:因果关系的新科学》(第一版平装本)。纽约:Basic Books 出版社。

[36] Derek C. Penn 和 Daniel J. Povinelli. 2007. 人类和非人类动物的因果认知:一项比较性批判性综述。《心理学年评》 58 (2007), 97–118。<https://doi.org/10.1146/annurev.psych.58.110405.085555> [37] Pradyumna Shyama Prasad 和 Minh Nhat Nguyen. 2025. 当两位法学硕士辩论时,双方都认为自己会赢。<https://doi.org/10.48550/arXiv.2505.19184> arXiv:2505.19184 [cs]。

[38]陈茜,谢子豪,王逸飞,刘伟,朱昆伦,夏汉辰,党宇凡,杜卓云,陈伟泽,杨程,刘志远,孙茂松。 2025. 扩展基于大型语言模型的多智能体协作。<https://doi.org/10.48550/arXiv.2406.07155> arXiv:2406.07155 [cs]。

[39] Qwen 团队. 2025. Qwen3 技术报告。 <https://doi.org/10.48550/arXiv.2505.09388> arXiv:2505.09388 [cs]。

[40]林石,马驰宇,梁文华,刁兴建,马伟成。Soroush Vosoughi. 2025. 评判法官 LLM 作为法官的立场偏见系统研究。<https://doi.org/10.48550/arXiv.2406.07791> arXiv:2406.07791 [cs]。

[41] Ilya Shpitser 和 Judea Pearl. 2012. 条件干预分布的识别。<https://doi.org/10.48550/arXiv.1206.6876> arXiv:1206.6876 [cs]。

[42] Zhi Rui Tam, Cheng-Kuang Wu, Yi-Lin Tsai, Chieh-Yen Lin, Hung-yi Lee, and Yun-Nung Chen. 2024. Let Me Speak Freely? A Study on the Impact of Format Restrictions on Performance of Large Language Models. <https://doi.org/10.48550/arXiv.2408.02442> arXiv:2408.02442 [cs]。

[43] Ziyi Tang, Ruilin Wang, Weixing Chen, Yongsan Zheng, Zechuan Chen, Yang Liu, Keze Wang, Tianshui Chen, and Liang Lin. 2025. Towards CausalGPT: A Multi-Agent Approach for Faithful Knowledge Reasoning via Promoting Causal Concertency in LLMs. <https://doi.org/10.48550/arXiv.2308.11914> arXiv:2308.11914 [cs]。

[44] Arne Tillmann. 2025. 多智能体辩论在问题解决中的文献综述。<https://doi.org/10.48550/arXiv.2506.00066> arXiv:2506.00066 [cs]。

[45] Khanh-Tung Tran, Dung Dao, Minh-Duong Nguyen, Quoc-Viet Pham, Barry O. Sullivan 和 Hoang D. Nguyen。 2025.多代理协作机制:法学硕士调查。 <https://doi.org/10.48550/arXiv.2501.06322> arXiv:2501.06322 [cs]。

[46] Vishal Verma, Sawal Acharya, Samuel Simko, Devansh Bhardwaj, Anahita Haghighat, Dominik Janzing, Mrinmaya Sachan, Zhijing Jin 和 Yongjin Yang。 2025. 因果人工智能科学家:利用大型语言模型促进因果数据科学。发表于 NeurIPS 2025 人工智能科学研讨会。

[47]王俊林,王珏, Ben Athiwaratkun, 张策, James Zou。 2024 年。混合智能体增强大型语言模型的能力。<https://doi.org/10.48550/arXiv.2406.04692> arXiv:2406.04692 [cs]。

[48]王启能,王子豪,苏颖,佟航航,宋扬秋。 2024 年。重新思考 LLM 推理的界限:多智能体讨论是关键吗? <https://doi.org/10.48550/arXiv.2402.18272> arXiv:2402.18272 [cs]。

[49] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le 和 Denny Zhou. 2022. 链式思维提示引发大型语言模型中的推理。神经信息处理系统进展 35 (2022 年 12 月), 24824–24837。<https://proceedings.neurips.cc/paper/2022/>

hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html [50] Anpeng Wu, Kun Kuang,Minqin Zhu,Yingrong Wang,Yujia Cheng,Kairong Han, Baohong Li,Guangyi Chen,Fei Wu and Kun Zhang. 2024.大型语言模型的因果关系. <https://doi.org/10.48550/arXiv.2410.15319> arXiv:2410.15319 [cs].

[51]吴庆云,Gagan Bansal,张杰宇,吴怡然,李北斌,朱尔康,姜丽,张晓云,张少坤,刘家乐,Ahmed Hassan Awadallah, Ryen W. White,Doug Burger 和 Chi Wang. 2023. AutoGen:通过多代理对话启用下一代 LLM 应用程序. <https://doi.org/10.48550/arXiv.2308.08155> arXiv:2308.08155 [cs].

[52]吴星宇,于奎,吴继斌,谭凯晨. 2025. LLM 无法发现因果关系,应限制在因果发现的非决策支持中.<https://doi.org/10.48550/arXiv.2506.00844> arXiv:2506.00844 [cs].

[53]于龙轩,陈德林,熊思恒,吴庆阳,刘庆珍,李大伟,陈志凯,刘晓泽,潘良明. 2025.CausalEval:在语言模型中实现更好的因果推理. <https://doi.org/10.48550/arXiv.2410.16676> arXiv:2410.16676 [cs].

[54] Matej Ze evi ,Moritz Willig,Devendra Singh Dhami 和 Kristian Kersting. 2023 年。因果预测:大型语言模型可能谈论因果关系,但并非因果本身.<https://doi.org/10.48550/arXiv.2308.13067> arXiv:2308.13067 [cs].

[55]张彪,刘忠涛,Colin Cherry 和 Orhan Firat. 2024. 当尺度变换遇上 LLM 微调:数据、模型和微调方法的影响.<https://doi.org/10.48550/arXiv.2402.17193> arXiv:2402.17193 [cs].

[56] Cheng Zhang,Stefan Bauer,Paul Bennett,Jiangfeng Gao,Wenbo Gong,Agrin Hilmkil,Joel Jennings,Chao Ma,Tom Minka,Nick Pawlowski 和 James Vaughan.2023 年。《利用大型语言模型理解因果关系:可行性和机遇》, <https://doi.org/10.48550/arXiv.2304.05524> arXiv:2304.05524 [cs].

[57]李章,吕庆和克里斯·卡利森·伯奇,2020.使用 WikiHow 进行目标、步骤和时间顺序推理.载于 2020 年自然语言处理实证方法会议 (EMNLP) 会议录.计算语言学协会,在线,4630–4639.<https://doi.org/10.18653/v1/2020.emnlp-main.374> [58]张绍伟,熊德义. 2025. Debate4MATH:面向数学细粒度推理的多智能体辩论.载于《计算语言学协会研究成果:ACL 2025》,车万祥,Joyce Nabende,Ekaterina Shutova 和 Mohammad Taher Pilehvar (编)。计算语言学协会,维也

纳,奥地利,16810–16824.<https://doi.org/10.18653/v1/2025.findings-acl.862> [59]赵恩波,沉毅,施书明,黄浩云,陈志浩,王宁,肖恩琪,张健,王凯,连世国. 2025. DeepSeek 模型量化性能下降的定量分析. <https://doi.org/10.48550/arXiv.2505.02390> arXiv:2505.02390 [cs].

[60]周宇,吴星宇,黄北城,吴继斌,冯梁,谭凯陈. 2024. CausalBench: LLM因果学习能力的综合基准测试.<https://doi.org/10.48550/arXiv.2404.06349> arXiv:2404.06349 [cs].

花费的时间

图 8 显示,在第一轮之后,生成回复的中位时间呈下降趋势,两个模型回答第三轮问题所需的时间都明显更长.我们还发现, Qwen3 模型生成回复的平均时间更长,并且在最后一轮发言时比第二轮和第三轮的回复时间更长,而 DeepSeek-R1 模型则没有出现这种变化.此外,我们注意到这两个模型偶尔会陷入循环,其中三个回复的生成时间分别在 40 到 46 分钟之间.另有六个回复的生成时间在 20 到 30 分钟之间,在 36 个耗时超过 500 秒的回复中,26 个来自 Qwen3,10 个来自 DeepSeek-R1.通过分析这些异常值的原始输出,我们发现模型不仅进行了长时间的思考,而且还反复重复相同的片段。

B 初始提示

你将遇到一道因果推理题。你的最终答案应按以下方式组织：




图 8:每个模型生成响应所需的中位时间,按轮次和阶数划分。

步骤 1)提取因果图:确定能够描述场景中关系的因果图.该图应仅由以“var1 -> var2”格式表示的边组成,边之间用逗号分隔。

逗号。

步骤 2)确定查询类型:识别主要问题所隐含的查询类型.选项包括“边际概率”、“条件概率”、“解释效应”、“后门调整集”、“平均处理效应”、“碰撞偏差”、“正态反事实问题”、“对处理组的平均处理效应”、“自然直接效应”或“自然间接效应”。您的答案应

只能是上面列表中的某个术语,并用引号将其括起来。

步骤 3)形式化查询:根据查询的类型,将其转换为形式化的数学表达式,并根据需要使用“do(·)”符号或反事实符号。

步骤 4)收集所有相关数据:提取所有可用数据.你的答案应该只包含边缘概率和条件概率,形式为“P(...)=...”或“P(...)|=...” ,每个概率之间用分号分隔.请遵循前面提到的变量表示方法。

步骤 5)利用因果推断推导出估计量:根据以上所有信息,利用微积分、反事实预测和概率基础知识等技能推导出估计量。

请逐步解答。

步骤 6)计算被估计量:将步骤 4 中的相关数据代入被估计量,进行基本的算术运算,得出最终答案。

步骤 7)对该问题给出最终的“是”或“否”回答。

想象一个自洽的、假想的世界,其中只有以下条件,没有任何未提及的因素或因果关系:需求直接影响供给和价格;每英亩产量直接影响供给;供给直接影响价格;需求是不可观测的。

方法一:我们直接考察供给与价格的总体相关性.方法二:我们根据需求,逐个案例地考察这种相关性。

问题:要了解供给如何影响价格,更重要的是什么?使用方法一比使用方法二更正确吗?

这个问题有明确的“是/否”答案,但有时可能与你的常识直觉相悖。请相信你的思考:虽然答案可能不符合直觉,但这些问题并无陷阱,只要仔细推算,答案就会显而易见。

在阐述完你的理由之后,至关重要,你必须对因果关系问题给出最终的“是/否”答案。不要用数字回答:只能回答“是”或“否”。你还应该明确说明你对答案的置信度(介于 0.0 和 1.0 之间)。

C 辩论提示

你和另一位法学硕士正在被问到一个因果推理问题。

我相信三个臭皮匠顶个诸葛亮,所以我请你与其他法学硕士同学辩论,以达成共识。你将

如果显示查询内容,则会提供您当前的辩论历史记录以供参考。

想象一个自治的、假想的世界,其中只有以下条件,没有任何未提及的因素或因果关系:需求直接影响供给和价格;每英亩产量直接影响供给;供给直接影响价格;需求是不可观测的。

方法一:我们直接考察供给与价格的总体相关性。方法二:我们根据需求,逐个案例地考察这种相关性。

问题:为了理解供给如何影响价格,使用方法 1 是否比使用方法 2 更正确?

这个问题有明确的“是/否”答案,但有时可能与你的常识直觉相悖。请相信你的思考:虽然答案可能不符合直觉,但这些问题并无陷阱,只要仔细推算,答案就会显而易见。

[历史]

仔细阅读因果查询,然后仔细审查对手的解答。如果你发现他们推理中的任何缺陷或计算中的任何错误,你应该指出来并提出更正建议。你应该明确提及对手的……

回复。

在阐述完你的理由之后,至关重要,你必须对因果关系问题给出最终的“是/否”答案。不要用数字回答:只能回答“是”或“否”。你还应该明确说明你对答案的置信度(介于 0.0 和 1.0 之间)。

D 模型响应

QWEN 第 0 轮 答案:
否(置信度:1.0)
推理:

步骤 1)提取因果图:需求 -> 供给,需求 -> 价格、收益率 -> 供给、供给 -> 价格
步骤 2)确定查询类型:“后门调整集”
步骤 3)形式化查询:P(价格 | do(供给)) = 需求
P(价格 | 供给,需求) * P(需求)

步骤 4)收集所有相关数据:[未提供数值数据]

步骤 5)利用因果推断推导出估计量:需求是供给对价格因果效应的混淆因素。为了阻断后门路径(供给←需求→价格),我们必须对需求进行条件化。方法 2(对需求进行条件化)可以得出正确的因果效应,而方法 1(边际相关性)未能调整混淆因素,导致结果有偏。

步骤 6)计算估计量:[未提供数值数据,但分析结论成立]

步骤 7)最终是/否答案:**否** (置信度:1.0)

DEEPSEEK 第一轮 答案:
是(置信度:0.9)
推理:

对方错误地假设了按需条件反射(onDemand)即使无法直接观察也能实现。由于需求无法测量,方法二不适用。因此,方法一是唯一可行的方案,也更正确。

答案:是(置信度:0.9)

QWEN 第二轮 答案:
否(置信度:1.0)
推理:

对方的论点在于方法二由于需求不可观测而导致的实际可行性问题,但题目明确询问的是理论上的正确性,而非可行性。在因果推断中,估计供给对价格的因果效应的正确方法是控制混杂因素(需求),方法二在需求可观测的前提下可以实现这一点。然而,由于需求不可观测,因此方法二无法实现理论上的正确性。

由于未观察到相关因素,方法 2 无法实施,但这并不意味着方法 1 “更正确”
方法 1 本身就存在因混淆因素导致的偏差。问题的关键不在于什么方法*可行*,而在于哪种方法在原则上*正确*。方法 1 未能调整后门路径(供给←需求→价格),因此不适用于因果估计。对方混淆了可行性和正确性,但答案仍然是**否**。

答案:否(置信度:1.0)

DEEPSEEK 第三轮 答案:
否(置信度:0.9)
推理:

问题在于确定在需求是不可观察的混杂因素的情况下,方法 1 还是方法 2 更能正确地理解供给如何影响价格。

分析: - **因果图:** 各变量之间的关系定义如下:需求(D)同时影响供给(S)和价格(P);每英亩产量(Y)影响供给(S);供给(S)直接影响价格(P)。 - **方法:** - 方法 1 检验供给(S)和价格(P)之间的总体相关性,而不控制其他变量。 - 方法 2 通过控制需求(D)来调整这种相关性,因为需求(D)是一个混杂因素。

关键考虑因素: 1. **混杂因素调整:** 为了准确估计供给对价格的因果效应,必须控制需求(D),以阻止供给(S)通过需求(D)对价格(P)的后门路径。
2. **D 的可观测性:** 由于 D 不可观测,方法 2 无法实现。

由于需要对一个不可观测的变量进行条件化,因此无法实现。

结论:虽然方法 2 在理论上是正确的 (假设需求D 可观测),但由于需求D 不可观测,因此其实际应用是不可能的。因此,在这种情况下,尽管方法 1 存在偏差,但它是唯一可行的方法。然而,

问题问的是理论上的正确性,而不是可行性。
因此,即使方法 2 不能应用,但从原则上讲,它仍然是更正确的方法。

最终答案:否 (置信度:0.9)